

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC QUY NHƠN**

HUỲNH TRỌNG PHÚC

**THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC TRƯNG
TUYẾN TÍNH TỪNG PHẦN VÀ ỨNG DỤNG**

**ĐỀ ÁN THẠC SĨ
KHOA HỌC DỮ LIỆU**

Gia Lai – Năm 2026

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC QUY NHƠN**

HUỲNH TRỌNG PHÚC

**THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC TRƯNG
TUYẾN TÍNH TỪNG PHẦN VÀ ỨNG DỤNG**

**Ngành: Khoa học dữ liệu
Mã số: 8460108**

Người hướng dẫn: TS. Lê Quang Thuận

Gia Lai – Năm 2026

LỜI CAM ĐOAN

Tôi xin cam đoan nội dung trong đề án “**Thuật toán SVM với ánh xạ đặc trưng tuyến tính từng phần và ứng dụng**” là do bản thân thực hiện dưới sự hướng dẫn của TS. Lê Quang Thuận. Các nội dung và kết quả sử dụng trong đề án đều có trích dẫn và chú thích nguồn gốc rõ ràng. Mã nguồn và các kết quả thực nghiệm trong đề án do tôi tự thực hiện.

Tác giả đề án

Huỳnh Trọng Phúc

LỜI CẢM ƠN

Lời đầu tiên, tôi xin gửi đến TS. Lê Quang Thuận lời cảm ơn sâu sắc về sự tận tình giúp đỡ của thầy đối với tôi trong suốt khóa học, đặc biệt trong quá trình thực hiện đề án.

Tôi xin bày tỏ lòng biết ơn đến quý thầy cô Trường Đại học Quy Nhơn và các giảng viên Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Thành phố Hồ Chí Minh đã nhiệt tình giảng dạy chúng tôi trong suốt khóa học.

Xin cảm ơn lãnh đạo và chuyên viên Phòng Đào tạo sau đại học, Trường Đại học Quy Nhơn đã tạo điều kiện thuận lợi cho tôi trong suốt quá trình học tập.

Tôi cũng xin cảm ơn gia đình, đồng nghiệp và các bạn học viên cao học khóa 25B đã hỗ trợ, động viên tôi trong suốt thời gian qua.

Cuối cùng, do kiến thức còn hạn chế nên dù đã rất cố gắng, đề án chắc chắn không tránh khỏi thiếu sót. Kính mong quý thầy cô và các bạn đồng nghiệp góp ý để đề án được hoàn chỉnh hơn.

Trân trọng cảm ơn!

MỤC LỤC

Lời cam đoan	i
Lời cảm ơn	ii
Danh mục ký hiệu và chữ viết tắt	vi
Danh mục các bảng	ix
Danh mục các hình	x
MỞ ĐẦU	1
1. Tính cấp thiết của đề tài	1
2. Tổng quan tình hình nghiên cứu	3
3. Mục tiêu và câu hỏi nghiên cứu	5
4. Đối tượng và phạm vi nghiên cứu	5
5. Phương pháp nghiên cứu	6
6. Đóng góp của đề án	6
7. Cấu trúc của đề án	7
Chương 1. Cơ sở toán học	8
1.1. Tập affine, tập lồi và đa diện	8
1.2. Siêu phẳng phân tách và siêu phẳng tựa	11
1.3. Hàm lồi và bài toán tối ưu lồi	13
1.4. Đối ngẫu Lagrange và điều kiện KKT	15
1.5. Hàm tuyến tính từng phần liên tục	18
1.5.1. Định nghĩa và ví dụ	19
1.5.2. Các phép toán bảo toàn tính tuyến tính từng phần	21
1.5.3. Hàm tuyến tính từng phần một biến	22
1.5.4. Biểu diễn hàm tuyến tính từng phần nhiều biến	23
Tiểu kết Chương 1	25
Chương 2. SVM và SVM với ánh xạ đặc trưng tuyến tính từng phần	26
2.1. Bài toán phân loại nhị phân và SVM lề cứng	26

2.2.	SVM lề mềm và hàm mất mát bản lề	30
2.3.	Ánh xạ đặc trưng, hạt nhân và LS-SVM	33
2.3.1.	Ánh xạ đặc trưng và thủ thuật hạt nhân	33
2.3.2.	SVM bình phương tối thiểu	35
2.4.	Tập tuyến tính từng phần và phương trình tuyến tính từng phần	36
2.5.	Ánh xạ đặc trưng tuyến tính từng phần và PWL-SVM	40
2.5.1.	Từ định lý biểu diễn đến ánh xạ đặc trưng	40
2.5.2.	PWL-C-SVM	41
2.5.3.	PWL-LS-SVM	43
2.5.4.	Một cách nhìn khác: PWL-SVM như một mạng nơ-ron hai lớp	44
2.6.	Các dạng ánh xạ đặc trưng và cách chọn tham số	45
2.6.1.	Ba dạng ánh xạ	45
2.6.2.	Chọn tham số	46
2.6.3.	Hai ví dụ	48
2.7.	Quan hệ với các bộ phân loại tuyến tính từng phần khác . . .	50
2.7.1.	SVM hạt nhân giao	50
2.7.2.	AdaBoost với bộ phân loại yếu tuyến tính	51
2.7.3.	Phương pháp láng giềng gần nhất	52
2.7.4.	Ý nghĩa và giới hạn	53
	Tiểu kết Chương 2	53
	Chương 3. Cài đặt, thực nghiệm và ứng dụng	55
3.1.	Cài đặt	55
3.2.	Thực nghiệm minh họa trên dữ liệu hai chiều	57
3.3.	Thực nghiệm trên dữ liệu chuẩn	60
3.3.1.	Tái hiện thí nghiệm trên dữ liệu Cosexp	60
3.3.2.	Mười bộ dữ liệu chuẩn	62
3.3.3.	Ảnh hưởng của số đặc trưng và của quy tắc chọn tham số	66
3.4.	Chi phí tính toán và bộ nhớ	68
3.5.	Ứng dụng: dự báo vỡ nợ thẻ tín dụng	70
3.5.1.	Bài toán và dữ liệu	70

3.5.2. Thiết kế thực nghiệm	72
3.5.3. Kết quả	73
3.5.4. Diễn giải mô hình	76
3.5.5. Ràng buộc đơn điệu	79
3.5.6. Khả năng triển khai	81
3.6. Thảo luận	81
Tiểu kết Chương 3	83
KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	85
Tài liệu tham khảo	88
PHỤ LỤC	92
A. Mã nguồn chính	92
B. Kết quả đầy đủ trên mười bộ dữ liệu chuẩn	94
C. Nguồn dữ liệu	96

DANH MỤC KÝ HIỆU VÀ CHỮ VIẾT TẮT

Ký hiệu

$\mathbb{R}^n$	không gian Euclid n chiều; n là số chiều của dữ liệu đầu vào
$x(i)$	thành phần thứ i của vectơ $x \in \mathbb{R}^n$
x_k, y_k	điểm dữ liệu thứ k và nhãn của nó, $y_k \in \{-1, +1\}$, $k = 1, \dots, N$
N	số điểm dữ liệu huấn luyện
$(t)_+$	hàm bản lề $\max\{0, t\}$
$\text{int } C, \text{ conv } C$	phần trong và bao lồi của tập C
$\Pi_C(x)$	hình chiếu của x lên tập lồi đóng C
Ω, Ω_k	miền xác định và các vùng (đa diện) của một phân hoạch
$\mathcal{B}$	tập (biên) tuyến tính từng phần
$\varphi(x)$	ánh xạ đặc trưng, $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}^M$; φ_m là đặc trưng thứ m
M	số đặc trưng; M/n là số đặc trưng trên mỗi chiều
D	số đặc trưng bản lề, $D = M - n$
p_m, q_m	tham số của siêu phẳng bản lề $p_m^\top x + q_m = 0$ của đặc trưng thứ m
w, w_0	vectơ trọng số và hệ số chặn của bộ phân loại
γ	hằng số chính quy hóa (trọng số của hàm mất mát) trong SVM
$\kappa(x, z)$	hạt nhân, $\kappa(x, z) = \varphi(x)^\top \varphi(z)$
α	vectơ biến đổi ngẫu nhiên (nhân tử Lagrange)
e_k	biến bù của điểm dữ liệu thứ k
N_s	số vectơ hỗ trợ
h_i	hàm đóng góp của biến thứ i trong mô hình cộng tính
$\mathbf{1}$	vectơ có mọi thành phần bằng 1
$\text{sign}(t)$	hàm dấu

Chữ viết tắt

AUC	diện tích dưới đường cong ROC (area under the curve)
C-SVM	SVM lờ mềm với hàm mất mát bản lề
ĐCX-CB	độ chính xác cân bằng (balanced accuracy)
F1	trung bình điều hòa của độ chuẩn xác (precision) và độ nhạy (recall)
GHH	siêu phẳng bản lề tổng quát (generalized hinging hyperplane)
HH	siêu phẳng bản lề (hinging hyperplane)
Ik-SVM	SVM với hạt nhân giao (intersection kernel)
KKT	điều kiện Karush–Kuhn–Tucker
L-BFGS	phương pháp tựa Newton BFGS với bộ nhớ hạn chế
kNN	phương pháp k láng giềng gần nhất
LS-SVM	SVM bình phương tối thiểu (least squares SVM)
MLP	mạng nơ-ron truyền thẳng nhiều lớp (multilayer perceptron)
PWL	tuyến tính từng phần (piecewise linear)
PWL-SVM	SVM với ánh xạ đặc trưng tuyến tính từng phần
RBF	hàm cơ sở bán kính; hạt nhân Gauss
ReLU	đơn vị tuyến tính chỉnh lưu, $\text{ReLU}(t) = \max\{0, t\}$
ROC	đường đặc trưng hoạt động (receiver operating characteristic)
SVM	máy vectơ hỗ trợ (support vector machine)

DANH MỤC CÁC BẢNG

Bảng 2.1.	So sánh C-SVM và LS-SVM	36
Bảng 2.2.	Chi phí lưu trữ và chi phí dự đoán của các mô hình . .	43
Bảng 2.3.	Ba vectơ trọng số cho cùng một ánh xạ HH	50
Bảng 3.1.	Độ chính xác trên dữ liệu hai chiều	58
Bảng 3.2.	Mười bộ dữ liệu chuẩn	63
Bảng 3.3.	Độ chính xác trên mười bộ dữ liệu chuẩn	64
Bảng 3.4.	So sánh theo cặp với PWL-C-SVM cộng tính	66
Bảng 3.5.	Chi phí huấn luyện, dự đoán và bộ nhớ	69
Bảng 3.6.	Các biến của dữ liệu võ nợ thể tín dụng	71
Bảng 3.7.	Kết quả trên dữ liệu võ nợ thể tín dụng	74
Bảng PL.1.	Độ chính xác đầy đủ trên mười bộ dữ liệu chuẩn . . .	95
Bảng PL.2.	Mã số OpenML của các bộ dữ liệu	96

DANH MỤC CÁC HÌNH

Hình 1.1.	Tập lỗi, tập không lỗi và bao lỗi	10
Hình 1.2.	Đa diện, siêu phẳng phân tách và siêu phẳng tựa	13
Hình 1.3.	Khoảng cách đến siêu phẳng và đối ngẫu yếu	18
Hình 1.4.	Hàm bản lề và biểu diễn một hàm PWL một biến bằng các hàm bản lề	20
Hình 1.5.	Một hàm PWL hai biến và phân hoạch đa diện tương ứng	21
Hình 2.1.	SVM lề cứng	30
Hình 2.2.	SVM lề mềm và các hàm mất mát	33
Hình 2.3.	Ánh xạ đặc trưng biến dữ liệu không tách được thành tách được	34
Hình 2.4.	Biên tuyến tính từng phần cho dữ liệu hai mặt trăng . .	37
Hình 2.5.	PWL-SVM nhìn như một mạng nơ-ron hai lớp	45
Hình 2.6.	Phân vùng tuyến tính do ba dạng ánh xạ đặc trưng sinh ra	47
Hình 2.7.	Ba biên phân loại khác nhau sinh bởi cùng một ánh xạ HH	49
Hình 2.8.	Biên của 1-NN và của SVM hạt nhân giao	53
Hình 3.1.	Biên quyết định của năm phương pháp trên dữ liệu hai chiều	59
Hình 3.2.	Tái hiện thí nghiệm Cosexp: ảnh hưởng của số đặc trưng	61
Hình 3.3.	Chênh lệch độ chính xác so với SVM hạt nhân Gauss .	65
Hình 3.4.	Ảnh hưởng của số đặc trưng và quy tắc chọn tham số .	67
Hình 3.5.	Đánh đổi giữa độ chính xác và thời gian dự đoán . . .	70
Hình 3.6.	Hai đặc điểm của dữ liệu tín dụng	72
Hình 3.7.	Đường cong ROC trên dữ liệu tín dụng	75
Hình 3.8.	Các hàm đóng góp của mô hình PWL-SVM cộng tính	77
Hình 3.9.	Mức độ ảnh hưởng của các biến và giải thích một hồ sơ	78
Hình 3.10.	Hàm đóng góp khi có và không có ràng buộc đơn điệu	80

MỞ ĐẦU

1. Tính cấp thiết của đề tài

Phân loại là một trong những bài toán cơ bản nhất của học máy: từ một tập mẫu đã được gán nhãn, ta cần xây dựng một quy tắc gán nhãn cho những mẫu mới. Trong nhiều ứng dụng hiện nay, độ chính xác không còn là yêu cầu duy nhất. Bộ phân loại thường phải chạy trên các thiết bị có tài nguyên hạn chế như điện thoại, cảm biến, camera thông minh hay hệ thống nhúng thời gian thực, hoặc phải chấm điểm hàng triệu hồ sơ mỗi ngày; khi đó thời gian dự đoán và dung lượng bộ nhớ trở thành những ràng buộc cứng. Ở các lĩnh vực như y tế hay tài chính, người sử dụng còn cần hiểu vì sao mô hình đưa ra một quyết định cụ thể.

Các bộ phân loại tuyến tính đáp ứng tốt hai yêu cầu sau. Mô hình chỉ gồm một vectơ trọng số, việc dự đoán chỉ cần một tích vô hướng, và mỗi hệ số cho biết ảnh hưởng của một biến đầu vào. Tuy nhiên, biên quyết định của chúng là một siêu phẳng, nên chúng không tách được cả những cấu trúc phi tuyến rất đơn giản, chẳng hạn hai lớp đan vào nhau như hai mảnh trăng khuyết hay hai vòng tròn đồng tâm. Ở thái cực ngược lại, máy vectơ hỗ trợ (SVM) với hạt nhân Gauss hay mạng nơ-ron nhiều lớp tạo ra những biên quyết định rất linh hoạt. Cái giá phải trả là SVM hạt nhân phải lưu toàn bộ các vectơ hỗ trợ và tính một hàm mũ cho từng vectơ mỗi khi dự đoán, còn huấn luyện mạng nơ-ron là một bài toán tối ưu không lồi mà kết quả phụ thuộc vào cách khởi tạo.

Bộ phân loại tuyến tính từng phần (piecewise linear, viết tắt là PWL) là một lời giải trung gian tự nhiên. Biên quyết định của nó gồm nhiều mảnh siêu phẳng ghép lại với nhau: trên mỗi vùng của không gian, bộ phân loại vẫn là tuyến tính, nhưng nhìn tổng thể thì biên có thể uốn theo hình dạng của dữ liệu. Vì mọi đường cong liên tục đều xấp xỉ được bằng những đường gấp khúc, bộ phân loại PWL có khả năng phân loại phi tuyến đáng kể, trong khi việc dự

đoán chỉ gồm các phép nhân, cộng và so sánh — rất thuận lợi cho cài đặt trên phần cứng [28, 53]. Khó khăn nằm ở khâu huấn luyện: nếu tham số hóa trực tiếp các mảnh của biên, bài toán xác định tham số là không lồi, không trơn, và trên thực tế chỉ giải được với số mảnh nhỏ [5].

Huang, Mehrkanoon và Suykens [26] đề xuất một cách tiếp cận khác. Dựa trên các kết quả biểu diễn hàm tuyến tính từng phần liên tục của Breiman [9] và của Wang và Sun [52], các tác giả xây dựng một *ánh xạ đặc trưng tuyến tính từng phần* sao cho mọi biên PWL đều là tập nghiệm của một phương trình *tuyến tính* theo các đặc trưng mới. Nhờ đó, việc xây dựng bộ phân loại PWL được quy về một SVM tuyến tính trong không gian đặc trưng: bài toán tối ưu là lồi, có nghiệm toàn cục, và mô hình thừa hưởng các tính chất tốt của SVM. Mô hình thu được, gọi là PWL-SVM, đóng vai trò cầu nối giữa phân loại tuyến tính và phân loại phi tuyến.

Hướng tiếp cận này càng có ý nghĩa trong bối cảnh hiện nay. Hàm kích hoạt ReLU, nền tảng của phần lớn các mạng nơ-ron sâu, chính là hàm bản lề $\max\{0, t\}$; hơn nữa, một hàm số biểu diễn được bởi mạng ReLU khi và chỉ khi nó là hàm tuyến tính từng phần liên tục [3]. Vì vậy, hiểu rõ PWL-SVM cũng là hiểu cấu trúc của một lớp mô hình học sâu quan trọng, nhưng trong một khung lý thuyết đơn giản hơn nhiều [45]. Bên cạnh đó, có những lĩnh vực mà khả năng diễn giải là yêu cầu bắt buộc. Trong chấm điểm tín dụng, tổ chức cho vay cần giải thích được vì sao một hồ sơ bị đánh giá rủi ro cao, và các mô hình dạng “thẻ điểm” tuyến tính vẫn được ưa chuộng chính vì lý do này [48]. Một mô hình tuyến tính từng phần cộng tính, trong đó ảnh hưởng của mỗi biến là một đường gấp khúc đọc được, là một lựa chọn trung gian hấp dẫn giữa thẻ điểm tuyến tính và các mô hình hộp đen.

Tuy vậy, bài báo gốc trình bày các chứng minh khá vắn tắt, chỉ đánh giá trên một lần chia dữ liệu, không đo chi phí dự đoán một cách hệ thống và không công bố mã nguồn. Các tài liệu tiếng Việt về SVM mà tác giả tìm hiểu được chủ yếu đề cập đến SVM tuyến tính và SVM hạt nhân [2]; phương pháp PWL-SVM chưa được giới thiệu một cách hệ thống. Vì những lý do trên, tác giả chọn đề tài **“Thuật toán SVM với ánh xạ đặc trưng tuyến tính từng**

phần và ứng dụng”, với ứng dụng là bài toán dự báo vỡ nợ của khách hàng sử dụng thẻ tín dụng.

2. Tổng quan tình hình nghiên cứu

Các bộ phân loại tuyến tính từng phần. Ý tưởng tách hai tập điểm bằng nhiều siêu phẳng đã có từ phương pháp nhiều mặt của Mangasarian [34], trong đó mỗi siêu phẳng được tìm bằng một bài toán quy hoạch tuyến tính. Các nghiên cứu tiếp theo huấn luyện những bộ phân loại tuyến tính cục bộ rồi ghép lại [40], hoặc tìm cách chọn số siêu phẳng phù hợp với dữ liệu [47]. Một hướng khác tham số hóa trực tiếp biên dưới dạng max–min của các hàm affine và tối ưu các tham số đó; phương pháp tách max–min của Bagirov [5] là đại diện tiêu biểu, nhưng bài toán tối ưu thu được không lồi, không trơn và chỉ giải được với vài vùng. Kostin [28] đề xuất một bộ phân loại tuyến tính từng phần nhiều lớp đơn giản và nhanh; multiconlitron của Li và cộng sự [30] xây dựng biên PWL dựa trên SVM nhưng chỉ áp dụng được cho dữ liệu tách được. Luận án của Webb [53] tổng kết hướng nghiên cứu này và nhấn mạnh lợi thế của bộ phân loại PWL trên các hệ thống có tài nguyên hạn chế.

Biểu diễn hàm tuyến tính từng phần. Song song với bài toán phân loại, lý thuyết mạch điện và nhận dạng hệ thống đã phát triển các biểu diễn tường minh cho hàm PWL liên tục: biểu diễn chính tắc của Chua và Kang [12], mô hình siêu phẳng bản lề của Breiman [9], biểu diễn dàn max–min [46, 35] và mô hình siêu phẳng bản lề tổng quát của Wang và Sun [52]. Điểm chung quan trọng của các biểu diễn dạng tổng bản lề là chúng tuyến tính theo các hệ số khi các tham số của bản lề đã cố định — đây chính là tính chất mà PWL-SVM khai thác.

SVM và các ánh xạ đặc trưng tường minh. SVM được Cortes và Vapnik [13] đề xuất cho dữ liệu không tách được, dựa trên thủ thuật hạt nhân [7] và lý thuyết học thống kê [50]; LS-SVM [42, 44] thay bài toán quy hoạch toàn phương bằng một hệ phương trình tuyến tính. Để giảm chi phí của SVM hạt nhân trên dữ liệu lớn, nhiều công trình thay hạt nhân bằng một ánh xạ đặc trưng tường minh hữu hạn chiều rồi giải SVM tuyến tính bằng các bộ giải

hiệu quả như LIBLINEAR [17]; tiêu biểu là đặc trưng ngẫu nhiên [38] và máy học cực trị [25]. PWL-SVM [26] thuộc về họ này, với các đặc trưng là những hàm bản lề. Huang và cộng sự cũng chỉ ra rằng các bộ phân loại láng giềng gần nhất, AdaBoost với bộ phân loại yếu tuyến tính [19] và SVM hạt nhân giao [33] đều biểu diễn được bằng ánh xạ đặc trưng tuyến tính từng phần.

Mạng nơ-ron tuyến tính từng phần. Mạng nơ-ron với hàm kích hoạt ReLU hay maxout [21] biểu diễn đúng lớp hàm PWL liên tục [3]. Tổng quan của Tao và cộng sự [45] trình bày mạng nơ-ron tuyến tính từng phần như một cầu nối giữa các mô hình PWL cổ điển và học sâu. Từ góc nhìn này, PWL-SVM là một mạng hai lớp với lớp ẩn cố định, được huấn luyện bằng nguyên lý cực đại lề [43].

Chấm điểm tín dụng. Các nghiên cứu so sánh quy mô lớn của Baesens và cộng sự [4] và Lessmann và cộng sự [29] cho thấy SVM và LS-SVM nằm trong nhóm phương pháp tốt nhất cho bài toán chấm điểm tín dụng, còn các tổ hợp mô hình dạng cây thường cho độ chính xác cao nhất. Dù vậy, trong thực tế ngành, thẻ điểm xây dựng bằng hồi quy logistic trên các biến đã được rời rạc hóa vẫn là công cụ chuẩn, chính vì tính minh bạch của nó [48]. Dữ liệu vỡ nợ thẻ tín dụng của Yeh và Lien [54] là một trong những bộ dữ liệu công khai được dùng nhiều nhất cho bài toán này.

Tình hình nghiên cứu trong nước. SVM đã được giới thiệu rộng rãi trong các tài liệu tiếng Việt, chẳng hạn [2]. Đỗ Thanh Nghị và Poulet [16] nghiên cứu SVM cục bộ cho dữ liệu lớn: dữ liệu được chia thành các cụm và một SVM được huấn luyện trên từng cụm, cũng là một cách tạo ra bộ phân loại ghép từ nhiều mô hình cục bộ. Theo tìm hiểu của tác giả, phương pháp PWL-SVM chưa được trình bày hay đánh giá trong các công trình trong nước.

Khoảng trống. Từ tổng quan trên, đề án hướng tới ba khoảng trống: chưa có một trình bày hệ thống bằng tiếng Việt về PWL-SVM với các chứng minh đầy đủ; kết quả thực nghiệm của bài báo gốc dựa trên một lần chia dữ liệu và chưa có phép đo chi phí dự đoán một cách hệ thống; và phương pháp chưa được kiểm nghiệm trên một bài toán ứng dụng mà ở đó cả độ chính xác, tốc độ lẫn khả năng diễn giải đều quan trọng.

3. Mục tiêu và câu hỏi nghiên cứu

Đề án không nhằm đề xuất một thuật toán mới. Mục đích là hiểu sâu, cài đặt đúng và đánh giá trung thực một phương pháp đã được công bố, rồi đưa nó vào một bài toán cụ thể. Cụ thể, đề án đặt ra bốn mục tiêu:

- (i) hệ thống hóa cơ sở toán học của PWL-SVM, từ tập lỗi và đối ngẫu Lagrange đến các định lý biểu diễn hàm tuyến tính từng phần, và trình bày đầy đủ các chứng minh mà bài báo gốc viết vắn tắt;
- (ii) cài đặt PWL-SVM bằng Python, tương thích với thư viện scikit-learn, và kiểm chứng tính đúng đắn của cài đặt bằng các phép thử số;
- (iii) đánh giá PWL-SVM trên dữ liệu tổng hợp và dữ liệu chuẩn, với nhiều lần chia dữ liệu, xét đồng thời độ chính xác, thời gian dự đoán và dung lượng mô hình;
- (iv) áp dụng PWL-SVM vào bài toán dự báo vỡ nợ thẻ tín dụng và phân tích khả năng diễn giải cũng như khả năng triển khai của mô hình.

Tương ứng, đề án tìm câu trả lời cho bốn câu hỏi. (CH1) PWL-SVM chính xác đến đâu so với SVM tuyến tính và SVM hạt nhân Gauss? (CH2) Đổi lại, nó tiết kiệm được bao nhiêu thời gian dự đoán và bộ nhớ? (CH3) Loại ánh xạ đặc trưng, số đặc trưng M và quy tắc chọn tham số ảnh hưởng thế nào đến kết quả? (CH4) Trong bài toán dự báo vỡ nợ thẻ tín dụng, PWL-SVM có đạt được độ chính xác cạnh tranh, dự đoán nhanh và cho một mô hình diễn giải được hay không?

4. Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu là các mô hình PWL-C-SVM và PWL-LS-SVM với ba dạng ánh xạ đặc trưng (cộng tính, siêu phẳng bản lề và siêu phẳng bản lề tổng quát), cùng cơ sở toán học của chúng. *Phạm vi nghiên cứu* được giới hạn như sau. Về lý thuyết, đề án tập trung vào bài toán phân loại nhị phân; các tham số của siêu phẳng bản lề được chọn theo quy tắc cố định chứ không được học từ dữ liệu. Về thực nghiệm, đề án dùng dữ liệu dạng bảng công khai từ kho UCI qua OpenML, với số chiều từ 2 đến 60; dạng siêu phẳng bản lề

tổng quát chỉ được thử trên dữ liệu hai chiều vì chi phí tăng nhanh theo số chiều; mạng nơ-ron và tổ hợp cây tăng cường chỉ đóng vai trò đối chứng. Về ứng dụng, đề án dùng dữ liệu công khai của Yeh và Lien [54], không dùng dữ liệu nội bộ của tổ chức tín dụng nào.

5. Phương pháp nghiên cứu

Đề án kết hợp nghiên cứu lý thuyết và thực nghiệm. Về lý thuyết, tác giả tổng hợp tài liệu, tự chứng minh lại các kết quả chính và bổ sung những bước mà bài báo gốc bỏ qua. Về cài đặt, mô hình được lập trình bằng Python trên nền NumPy và scikit-learn [36], và các đẳng thức lý thuyết (chẳng hạn sự trùng nhau giữa nghiệm gốc và nghiệm đối ngẫu) được kiểm tra bằng số. Về thực nghiệm, mỗi cấu hình được lặp lại trên nhiều lần chia dữ liệu ngẫu nhiên với hạt giống cố định, tham số được chọn bằng kiểm định chéo chỉ trên phần huấn luyện, kết quả được báo cáo dưới dạng trung bình $\pm$ độ lệch chuẩn, và các so sánh chính được kiểm định bằng phép kiểm định dấu hạng Wilcoxon theo cặp [15]. Cuối cùng, một nghiên cứu tình huống trên dữ liệu tín dụng đánh giá đồng thời độ chính xác, chi phí và khả năng diễn giải.

6. Đóng góp của đề án

- (1) Trình bày có hệ thống bằng tiếng Việt cơ sở toán học của PWL-SVM. Ngoài các chứng minh được viết lại đầy đủ, đề án đưa ra một chứng minh ngắn hơn cho định lý biểu diễn tập tuyến tính từng phần (Định lý 2.6), chỉ ra rằng hàm xây dựng trong chứng minh đó luôn không âm (Nhận xét 2.8), chứng minh chặt các quan hệ giữa PWL-SVM với SVM hạt nhân giao, AdaBoost và phương pháp láng giềng gần nhất (Mục 2.7), và nêu một giới hạn cơ bản của mô hình cộng tính (Mệnh đề 3.1).
- (2) Một cài đặt mã nguồn mở, tái lập được toàn bộ hình và bảng của đề án, kèm các phép kiểm chứng số.
- (3) Một đánh giá thực nghiệm lặp lại trên mười bộ dữ liệu chuẩn với chín phương pháp, có kiểm định thống kê và phép đo chi phí dự đoán, qua đó làm rõ phần nào trong các nhận định của bài báo gốc được xác nhận.

- (4) Một nghiên cứu ứng dụng cho bài toán dự báo vỡ nợ thẻ tín dụng, trong đó biến thể đặt nút theo phân vị (Nhận xét 2.12) cho một mô hình tuyến tính từng phần cộng tính có thể đọc được như một thể điểm, được so sánh với thể điểm logistic truyền thống, và một cách đưa ràng buộc đơn điệu vào mô hình mà bài toán huấn luyện vẫn là lồi (Mục 3.5.5).

7. Cấu trúc của đề án

Ngoài Mở đầu, Kết luận, Tài liệu tham khảo và Phụ lục, đề án gồm ba chương. Chương 1 trình bày cơ sở toán học: tập lồi, siêu phẳng phân tách, tối ưu lồi, đối ngẫu Lagrange và hàm tuyến tính từng phần. Chương 2 trình bày SVM và xây dựng PWL-SVM, gồm các định lý biểu diễn, hai mô hình PWL-C-SVM và PWL-LS-SVM, ba dạng ánh xạ đặc trưng và quan hệ với các bộ phân loại tuyến tính từng phần khác. Chương 3 trình bày cài đặt, các thực nghiệm trên dữ liệu tổng hợp và dữ liệu chuẩn, phân tích chi phí và nghiên cứu ứng dụng trên dữ liệu tín dụng.

CHƯƠNG 1

CƠ SỞ TOÁN HỌC

Chương này trình bày các công cụ toán học được dùng trong toàn bộ đề án. Mục 1.1 và 1.2 nhắc lại tập lồi, đa diện và các định lý siêu phẳng phân tách, nền tảng hình học của SVM. Mục 1.3 và 1.4 trình bày bài toán tối ưu lồi và lý thuyết đối ngẫu Lagrange, công cụ để dẫn ra các bài toán đối ngẫu ở Chương 2. Mục 1.5 giới thiệu hàm tuyến tính từng phần liên tục, đối tượng trung tâm của đề án. Các khái niệm được chọn theo một nguyên tắc: chỉ trình bày những gì sẽ được dùng lại ở hai chương sau. Nội dung các Mục 1.1–1.4 được trình bày theo [8, 1]; chứng minh chỉ được nêu khi nó ngắn hoặc cho thấy ý tưởng được dùng về sau.

Trong suốt chương, $\mathbb{R}^n$ là không gian Euclid với tích vô hướng $x^\top z$ và chuẩn $\|x\| = \sqrt{x^\top x}$.

1.1. Tập affine, tập lồi và đa diện

Với hai điểm $x_1 \neq x_2$ của $\mathbb{R}^n$, tập các điểm $\theta x_1 + (1 - \theta)x_2$ với $\theta \in \mathbb{R}$ là đường thẳng đi qua x_1 và x_2 ; khi θ chạy trong đoạn $[0, 1]$, ta được đoạn thẳng nối hai điểm đó, ký hiệu $[x_1, x_2]$. Hai khái niệm cơ bản của mục này được định nghĩa qua đường thẳng và đoạn thẳng.

Định nghĩa 1.1. Tập $C \subseteq \mathbb{R}^n$ được gọi là *tập affine* nếu với mọi $x_1, x_2 \in C$ và mọi $\theta \in \mathbb{R}$ ta có $\theta x_1 + (1 - \theta)x_2 \in C$, tức là C chứa trọn đường thẳng đi qua hai điểm bất kỳ của nó. Tập C được gọi là *tập lồi* nếu điều đó đúng với mọi $\theta \in [0, 1]$, tức là C chứa trọn đoạn thẳng nối hai điểm bất kỳ của nó.

Mọi tập affine đều là tập lồi. Không gian con, cả không gian $\mathbb{R}^n$ và tập một điểm là những tập affine; một hình tròn là tập lồi nhưng không affine. Hình 1.1a,b minh họa một tập lồi và một tập không lồi: với tập không lồi, có hai điểm mà đoạn thẳng nối chúng đi ra ngoài tập.

Một điểm dạng $\theta_1 x_1 + \dots + \theta_k x_k$ với $\theta_1 + \dots + \theta_k = 1$ được gọi là một *tổ hợp affine* của $x_1, \dots, x_k$; nếu thêm điều kiện $\theta_i \geq 0$ với mọi i , ta có một *tổ hợp lồi*. Có thể hiểu tổ hợp lồi như một trung bình có trọng số, với θ_i là tỉ trọng của x_i .

Mệnh đề 1.2. *Tập C là tập lồi khi và chỉ khi C chứa mọi tổ hợp lồi của các điểm thuộc C .*

Chứng minh. Chiều ngược lại là hiển nhiên, vì điểm trên đoạn $[x_1, x_2]$ là tổ hợp lồi của hai điểm. Với chiều thuận, ta quy nạp theo số điểm k . Trường hợp $k \leq 2$ là định nghĩa. Giả sử khẳng định đúng với $k - 1$ điểm và xét $x = \sum_{i=1}^k \theta_i x_i$ với $\theta_k < 1$ (nếu $\theta_k = 1$ thì $x = x_k \in C$). Khi đó

$$x = (1 - \theta_k) \sum_{i=1}^{k-1} \frac{\theta_i}{1 - \theta_k} x_i + \theta_k x_k.$$


Điểm $z = \sum_{i=1}^{k-1} \frac{\theta_i}{1 - \theta_k} x_i$ là tổ hợp lồi của $k - 1$ điểm nên thuộc C theo giả thiết quy nạp, và x nằm trên đoạn $[z, x_k]$ nên cũng thuộc C . $\square$

Định nghĩa 1.3. *Bao lồi của tập $C \subseteq \mathbb{R}^n$, ký hiệu $\text{conv } C$, là tập mọi tổ hợp lồi của các điểm thuộc C .*

Bao lồi $\text{conv } C$ là một tập lồi (tổ hợp lồi của các tổ hợp lồi lại là một tổ hợp lồi) và chứa C ; theo Mệnh đề 1.2, mọi tập lồi chứa C đều chứa $\text{conv } C$. Vậy $\text{conv } C$ là tập lồi nhỏ nhất chứa C . Khi $C = \{x_1, \dots, x_N\}$ là một tập hữu hạn, $\text{conv } C$ là một đa giác (đa diện) lồi với các đỉnh thuộc C (Hình 1.1c). Bao lồi của tập các điểm thuộc cùng một lớp sẽ đóng vai trò then chốt khi ta xét khả năng tách tuyến tính ở Mục 1.2 và hình học của SVM ở Mục 2.1.

Ví dụ 1.4. Một số tập lồi sẽ gặp lại nhiều lần trong đề án:

- (a) *Siêu phẳng* $H = \{x : a^\top x = b\}$ với $a \in \mathbb{R}^n \setminus \{0\}$ và $b \in \mathbb{R}$. Đây là một tập affine; vectơ a vuông góc với H và được gọi là vectơ pháp tuyến của H .
- (b) *Nửa không gian* $\{x : a^\top x \leq b\}$ với $a \neq 0$. Nếu $a^\top x_1 \leq b$ và $a^\top x_2 \leq b$ thì $a^\top (\theta x_1 + (1 - \theta)x_2) \leq b$ với mọi $\theta \in [0, 1]$, nên nửa không gian là tập



Hình 1.1. (a) Một tập lồi: đoạn thẳng nối hai điểm bất kỳ nằm trọn trong tập. (b) Một tập không lồi. (c) Bao lồi của một tập hữu hạn điểm là đa giác lồi nhỏ nhất chứa các điểm đó.

lồi. Siêu phẳng $a^\top x = b$ chia $\mathbb{R}^n$ thành hai nửa không gian $\{a^\top x \leq b\}$ và $\{a^\top x \geq b\}$; bộ phân loại tuyến tính chính là quy tắc xếp mỗi điểm vào một trong hai nửa không gian đó.

(c) *Hình cầu Euclid* $B(x_c, r) = \{x : \|x - x_c\| \leq r\}$ với $r > 0$. Nếu $x_1, x_2 \in B(x_c, r)$ và $\theta \in [0, 1]$ thì theo bất đẳng thức tam giác

$$\|\theta x_1 + (1 - \theta)x_2 - x_c\| \leq \theta\|x_1 - x_c\| + (1 - \theta)\|x_2 - x_c\| \leq r,$$

nên hình cầu là tập lồi.

Định nghĩa 1.5. *Đa diện* là tập nghiệm của một hệ hữu hạn phương trình và bất phương trình tuyến tính:

$$P = \{x : a_j^\top x \leq b_j, j = 1, \dots, m; c_j^\top x = d_j, j = 1, \dots, p\}. \quad (1.1)$$

Như vậy, đa diện là giao của hữu hạn nửa không gian và siêu phẳng (Hình 1.2a). Không gian con, siêu phẳng, nửa không gian, đoạn thẳng và bao lồi của một tập hữu hạn điểm đều là đa diện. Một ví dụ quan trọng về sau: với dữ liệu $\{(x_k, y_k)\}$ cố định, tập các cặp $(w, w_0) \in \mathbb{R}^{n+1}$ thỏa mãn $y_k(w^\top x_k + w_0) \geq 1$ với mọi k là một đa diện trong không gian các tham số; đó là miền ràng buộc của bài toán SVM lề cứng ở Mục 2.1. Tính lồi của đa diện là hệ quả của mệnh đề sau.

Mệnh đề 1.6. (i) *Giao của một họ tùy ý các tập lồi là tập lồi.*

(ii) *Nếu $f(x) = Ax + b$ là một ánh xạ affine từ $\mathbb{R}^n$ vào $\mathbb{R}^m$ và $S \subseteq \mathbb{R}^n$, $T \subseteq \mathbb{R}^m$ là các tập lồi, thì ảnh $f(S) = \{f(x) : x \in S\}$ và nghịch ảnh $f^{-1}(T) = \{x : f(x) \in T\}$ là các tập lồi.*

Chứng minh. (i) Nếu x_1, x_2 thuộc mọi tập trong họ thì đoạn $[x_1, x_2]$ cũng vậy. (ii) Ánh xạ affine bảo toàn tổ hợp lồi: $f(\theta x_1 + (1 - \theta)x_2) = \theta f(x_1) + (1 - \theta)f(x_2)$. Do đó nếu $f(x_1), f(x_2) \in f(S)$ thì mọi điểm của đoạn nối chúng có dạng $f(\theta x_1 + (1 - \theta)x_2) \in f(S)$; lập luận tương tự cho nghịch ảnh. $\square$

1.2. Siêu phẳng phân tách và siêu phẳng tựa

Bài toán phân loại tuyến tính đặt ra một câu hỏi hình học: khi nào hai tập điểm có thể được tách bởi một siêu phẳng? Với các tập lồi, câu trả lời được cho bởi định lý siêu phẳng phân tách. Công cụ để chứng minh định lý là phép chiếu lên một tập lồi đóng.

Bổ đề 1.7 (Phép chiếu lên tập lồi đóng). *Cho $C \subseteq \mathbb{R}^n$ là tập lồi, đóng, khác rỗng và $x_0 \in \mathbb{R}^n$. Khi đó tồn tại duy nhất một điểm $c^* \in C$ gần x_0 nhất, ký hiệu $c^* = \Pi_C(x_0)$. Hơn nữa, c^* được đặc trưng bởi bất đẳng thức*

$$(x_0 - c^*)^\top (x - c^*) \leq 0 \quad \text{với mọi } x \in C. \quad (1.2)$$

Chứng minh. Tồn tại. Lấy một điểm $\bar{c} \in C$. Điểm gần nhất, nếu có, phải thuộc tập $C \cap B(x_0, \|x_0 - \bar{c}\|)$; tập này compact và khác rỗng, nên hàm liên tục $x \mapsto \|x - x_0\|$ đạt cực tiểu trên nó.

Đặc trưng. Với $x \in C$ và $t \in (0, 1]$, điểm $c^* + t(x - c^*)$ thuộc C , nên

$$0 \leq \|x_0 - c^* - t(x - c^*)\|^2 - \|x_0 - c^*\|^2 = -2t(x_0 - c^*)^\top (x - c^*) + t^2\|x - c^*\|^2.$$

Chia cho t rồi cho $t \rightarrow 0^+$ ta được (1.2). Ngược lại, nếu $c^* \in C$ thỏa (1.2) thì với mọi $x \in C$, $\|x_0 - x\|^2 = \|x_0 - c^*\|^2 - 2(x_0 - c^*)^\top (x - c^*) + \|x - c^*\|^2 \geq \|x_0 - c^*\|^2$, dấu bằng chỉ khi $x = c^*$. Điều này đồng thời chứng minh tính duy nhất. $\square$

Định lý 1.8 (Siêu phẳng phân tách). Cho C và D là hai tập lồi, khác rỗng và rời nhau trong $\mathbb{R}^n$. Khi đó tồn tại $a \neq 0$ và $b \in \mathbb{R}$ sao cho $a^\top x \leq b$ với mọi $x \in C$ và $a^\top x \geq b$ với mọi $x \in D$. Nếu thêm giả thiết C và D đóng, trong đó ít nhất một tập compact, thì có thể chọn a, b để phân tách là chặt:

$$a^\top x < b < a^\top z \quad \text{với mọi } x \in C, z \in D. \quad (1.3)$$

Chứng minh. Ta chứng minh trường hợp phân tách chặt, là trường hợp sẽ được dùng; trường hợp tổng quát xem [8, Mục 2.5.1]. Tập $E = D - C = \{z - x : x \in C, z \in D\}$ là tập lồi (theo Mệnh đề 1.6(ii), vì nó là ảnh của tập lồi $C \times D$ qua ánh xạ tuyến tính $(x, z) \mapsto z - x$), đóng (vì một trong hai tập compact) và không chứa 0 (vì $C \cap D = \emptyset$). Đặt $u = \Pi_E(0) \neq 0$. Theo (1.2) với $x_0 = 0$, ta có $(0 - u)^\top (e - u) \leq 0$, tức là $u^\top e \geq \|u\|^2$ với mọi $e \in E$. Nói cách khác, $u^\top z - u^\top x \geq \|u\|^2 > 0$ với mọi $x \in C, z \in D$. Chọn $a = u$ và $b = \sup_{x \in C} u^\top x + \frac{1}{2}\|u\|^2$, ta được (1.3). $\square$


Trong chứng minh trên, $u = z^* - x^*$ với $x^* \in C, z^* \in D$ là cặp điểm gần nhau nhất của hai tập, và siêu phẳng tách có pháp tuyến cùng phương với đoạn nối cặp điểm đó (Hình 1.2b). Hình ảnh này sẽ xuất hiện lại khi ta diễn giải bài toán đối ngẫu của SVM ở Mục 2.1.

Định lý 1.9 (Siêu phẳng tựa). Cho C là tập lồi và x_0 là một điểm biên của C . Khi đó tồn tại $a \neq 0$ sao cho $a^\top x \leq a^\top x_0$ với mọi $x \in C$; siêu phẳng $\{x : a^\top x = a^\top x_0\}$ được gọi là siêu phẳng tựa của C tại x_0 .

Định lý được suy ra bằng cách áp dụng Định lý 1.8 cho phần trong của C và tập $\{x_0\}$ (khi phần trong khác rỗng), xem [8, Mục 2.5.2]. Về mặt hình học, siêu phẳng tựa chạm vào C tại x_0 và để toàn bộ C về một phía (Hình 1.2c).

Hệ quả sau chuyển Định lý 1.8 sang ngôn ngữ của dữ liệu và là cầu nối trực tiếp sang SVM lồi cứng. Ta nói hai tập hữu hạn điểm A và B tách tuyến tính được nếu tồn tại (w, w_0) sao cho $w^\top x + w_0 > 0$ với mọi $x \in A$ và $w^\top x + w_0 < 0$ với mọi $x \in B$.

Hệ quả 1.10. Cho dữ liệu $\{(x_k, y_k)\}_{k=1}^N$ với $y_k \in \{-1, +1\}$ và cả hai lớp đều



Hình 1.2. (a) Đa diện P là giao của năm nửa không gian; mũi tên chỉ vectơ pháp tuyến a_j hướng ra ngoài. (b) Siêu phẳng phân tách hai tập lồi rời nhau C và D , dựng từ cặp điểm gần nhau nhất $c \in C, d \in D$ như trong chứng minh Định lý 1.8. (c) Siêu phẳng tựa của tập lồi C tại điểm biên x_0 .

khác rỗng; đặt $A = \{x_k : y_k = +1\}$, $B = \{x_k : y_k = -1\}$. Ba khẳng định sau là tương đương:

- (i) A và B tách tuyến tính được;
- (ii) tồn tại (w, w_0) sao cho $y_k(w^\top x_k + w_0) \geq 1$ với mọi k ;
- (iii) $\text{conv } A \cap \text{conv } B = \emptyset$.

Chứng minh. (i) $\Rightarrow$ (ii): đặt $\mu = \min_k y_k(w^\top x_k + w_0) > 0$ và thay (w, w_0) bởi $(w, w_0)/\mu$. (ii) $\Rightarrow$ (iii): hai nửa không gian $\{x : w^\top x + w_0 \geq 1\}$ và $\{x : w^\top x + w_0 \leq -1\}$ là các tập lồi rời nhau, lần lượt chứa A và B , nên cũng chứa $\text{conv } A$ và $\text{conv } B$; do đó hai bao lồi rời nhau. (iii) $\Rightarrow$ (i): bao lồi của một tập hữu hạn là ảnh của đơn hình chuẩn (compact) qua một ánh xạ tuyến tính, nên compact; áp dụng phân phân tách chặt của Định lý 1.8 cho $\text{conv } A$ và $\text{conv } B$ với $w = -a$, $w_0 = b$. $\square$

1.3. Hàm lồi và bài toán tối ưu lồi

Định nghĩa 1.11. Cho $C \subseteq \mathbb{R}^n$ là tập lồi. Hàm $f : C \rightarrow \mathbb{R}$ được gọi là *hàm lồi* nếu

$$f(\theta x + (1 - \theta)z) \leq \theta f(x) + (1 - \theta)f(z) \quad \text{với mọi } x, z \in C, \theta \in [0, 1];$$

f được gọi là *lồi chặt* nếu bất đẳng thức là chặt khi $x \neq z$ và $\theta \in (0, 1)$. Hàm f là *lõm* nếu $-f$ lồi.

Hàm affine vừa lồi vừa lõm. Mọi chuẩn là hàm lồi, theo bất đẳng thức tam giác; hàm $\|x\|^2$ lồi chặt. Hàm bản lề $t \mapsto \max\{0, t\}$ và hàm mất mát $t \mapsto \max\{0, 1 - t\}$ dùng trong SVM là hàm lồi. Ba phép toán sau cho phép kiểm tra tính lồi của các hàm mục tiêu trong đề án mà không cần tính toán trực tiếp.

Mệnh đề 1.12. (i) Nếu $f_1, \dots, f_m$ lồi và $c_1, \dots, c_m \geq 0$ thì $\sum_i c_i f_i$ lồi; nếu thêm một f_i lồi chặt với $c_i > 0$ thì tổng lồi chặt.

(ii) Nếu $f_1, \dots, f_m$ lồi thì $x \mapsto \max_i f_i(x)$ lồi.

(iii) Nếu f lồi thì $x \mapsto f(Ax + b)$ lồi.

Chứng minh. (i) và (iii) suy trực tiếp từ định nghĩa. Với (ii), với mỗi i ta có $f_i(\theta x + (1 - \theta)z) \leq \theta f_i(x) + (1 - \theta)f_i(z) \leq \theta \max_j f_j(x) + (1 - \theta) \max_j f_j(z)$; lấy cực đại theo i ở vế trái. $\square$

Chẳng hạn, với dữ liệu cố định, hàm $(w, w_0) \mapsto \frac{1}{2}\|w\|^2 + \gamma \sum_k \max\{0, 1 - y_k(w^\top x_k + w_0)\}$ là hàm lồi: mỗi số hạng $\max\{0, 1 - y_k(w^\top x_k + w_0)\}$ là cực đại của hai hàm affine theo (w, w_0) . Đây là hàm mục tiêu của SVM lề mềm (Mục 2.2).

Đối với hàm khả vi, tính lồi có một đặc trưng hình học đơn giản: đồ thị nằm phía trên mọi tiếp diện. Cụ thể, nếu C mở và f khả vi trên C thì f lồi khi và chỉ khi

$$f(z) \geq f(x) + \nabla f(x)^\top (z - x) \quad \text{với mọi } x, z \in C \quad (1.4)$$

[8, Mục 3.1.3]. Hệ quả trực tiếp: nếu $\nabla f(x^*) = 0$ thì x^* là điểm cực tiểu toàn cục của f trên C .

Bài toán tối ưu lồi. Ta xét bài toán dạng chuẩn

$$\begin{aligned} \min_x \quad & f_0(x) \\ \text{với điều kiện} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m; \quad h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned} \quad (1.5)$$

trong đó $f_0, \dots, f_m$ là các hàm lồi và $h_j(x) = g_j^\top x - e_j$ là các hàm affine. Theo Mệnh đề 1.6, tập chấp nhận được của (1.5) là tập lồi. Giá trị tối ưu được ký hiệu là p^* .

Định lý 1.13. *Đối với bài toán (1.5), mọi điểm cực tiểu địa phương đều là điểm cực tiểu toàn cục. Nếu f_0 lồi chặt thì bài toán có không quá một nghiệm.*

Chứng minh. Giả sử x là cực tiểu địa phương nhưng có điểm chấp nhận được z với $f_0(z) < f_0(x)$. Với $\theta \in (0, 1]$, điểm $x_\theta = (1 - \theta)x + \theta z$ chấp nhận được và $f_0(x_\theta) \leq (1 - \theta)f_0(x) + \theta f_0(z) < f_0(x)$. Khi $\theta \rightarrow 0$, x_θ tiến tới x , mâu thuẫn với tính cực tiểu địa phương. Nếu $x \neq z$ là hai nghiệm và f_0 lồi chặt thì trung điểm của chúng chấp nhận được và có giá trị mục tiêu nhỏ hơn p^* , vô lý. $\square$

Ba lớp bài toán lồi sẽ xuất hiện trong đề án. *Quy hoạch tuyến tính:* f_0 và mọi f_i đều affine. *Quy hoạch toàn phương:* $f_0(x) = \frac{1}{2}x^\top Qx + c^\top x$ với Q nửa xác định dương và các ràng buộc affine; bài toán gốc và bài toán đối ngẫu của SVM thuộc lớp này. *Bình phương tối thiểu có chính quy hóa:* $\min_x \|Ax - t\|^2 + \lambda \|x\|^2$ với $\lambda > 0$; hàm mục tiêu lồi chặt, và cho gradient bằng 0 ta được nghiệm duy nhất $x^* = (A^\top A + \lambda I)^{-1} A^\top t$. Lớp thứ ba là dạng của LS-SVM và của hồi quy ridge (Mục 2.5).

1.4. Đối ngẫu Lagrange và điều kiện KKT

Lý thuyết đối ngẫu gắn với mỗi bài toán tối ưu có ràng buộc một bài toán khác, gọi là bài toán đối ngẫu, mà nghiệm của nó cho một cận dưới của giá trị tối ưu. Với SVM, bài toán đối ngẫu có cấu trúc đặc biệt: nó chỉ phụ thuộc vào dữ liệu qua các tích vô hướng, điều dẫn tới thủ thuật hạt nhân ở Mục 2.3.

Định nghĩa 1.14. *Hàm Lagrange của bài toán (1.5) là*

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x), \quad \lambda \in \mathbb{R}^m, \nu \in \mathbb{R}^p;$$

λ_i, ν_j được gọi là các *nhân tử Lagrange*. *Hàm đối ngẫu* là $g(\lambda, \nu) = \inf_x L(x, \lambda, \nu)$, và *bài toán đối ngẫu* là $\max g(\lambda, \nu)$ với điều kiện $\lambda \geq 0$; giá trị tối ưu của nó được ký hiệu là d^* .

Vì g là cận dưới đúng của một họ hàm affine theo (λ, ν) , hàm đối ngẫu luôn lõm, và bài toán đối ngẫu luôn là một bài toán lồi, bất kể bài toán gốc có lồi hay không.

Mệnh đề 1.15 (Đối ngẫu yếu). *Với mọi $\lambda \geq 0$ và mọi ν , ta có $g(\lambda, \nu) \leq p^*$. Do đó $d^* \leq p^*$.*

Chứng minh. Nếu $\tilde{x}$ chấp nhận được thì $\lambda_i f_i(\tilde{x}) \leq 0$ và $h_j(\tilde{x}) = 0$, nên $g(\lambda, \nu) \leq L(\tilde{x}, \lambda, \nu) \leq f_0(\tilde{x})$. Lấy cận dưới đúng theo mọi $\tilde{x}$ chấp nhận được ta được $g(\lambda, \nu) \leq p^*$. $\square$

Hiệu $p^* - d^* \geq 0$ được gọi là *khoảng cách đối ngẫu*. Khi $p^* = d^*$, ta nói có *đối ngẫu mạnh*. Đối với bài toán lồi, đối ngẫu mạnh xảy ra dưới những điều kiện khá nhẹ; điều kiện thông dụng nhất như sau.

Định lý 1.16 (Điều kiện Slater [8, Mục 5.2.3]). *Giả sử bài toán (1.5) là lồi và có một điểm chấp nhận được x sao cho $f_i(x) < 0$ với mọi i mà f_i không phải là hàm affine. Khi đó $d^* = p^*$, và nếu $p^* > -\infty$ thì bài toán đối ngẫu có nghiệm.*

Đặc biệt, khi mọi ràng buộc đều affine, như trong các bài toán SVM, chỉ cần bài toán gốc có điểm chấp nhận được là có đối ngẫu mạnh. Khi có đối ngẫu mạnh, nghiệm của hai bài toán liên hệ với nhau qua hệ điều kiện sau.

Định nghĩa 1.17 (Điều kiện KKT). *Giả sử f_0, f_i, h_j khả vi. Bộ (x, λ, ν) thỏa mãn điều kiện Karush–Kuhn–Tucker nếu*

- (a) $f_i(x) \leq 0$ và $h_j(x) = 0$ với mọi i, j (chấp nhận được đối với bài toán

gốc);

- (b) $\lambda \geq 0$ (chấp nhận được đối với bài toán đối ngẫu);
- (c) $\lambda_i f_i(x) = 0$ với mọi i (điều kiện bù);
- (d) $\nabla f_0(x) + \sum_i \lambda_i \nabla f_i(x) + \sum_j \nu_j \nabla h_j(x) = 0$ (điều kiện dừng).

Định lý 1.18. (i) Nếu có đối ngẫu mạnh, x^* là nghiệm của bài toán gốc và (λ^*, ν^*) là nghiệm của bài toán đối ngẫu, thì (x^*, λ^*, ν^*) thỏa mãn điều kiện KKT.

(ii) Ngược lại, nếu bài toán lồi và $(\tilde{x}, \tilde{\lambda}, \tilde{\nu})$ thỏa mãn điều kiện KKT, thì $\tilde{x}$ và $(\tilde{\lambda}, \tilde{\nu})$ lần lượt là nghiệm của bài toán gốc và bài toán đối ngẫu, và khoảng cách đối ngẫu bằng 0.


Chứng minh. Ta chứng minh (ii); chứng minh (i) xem [8, Mục 5.5.3]. Vì $\tilde{\lambda} \geq 0$, hàm $x \mapsto L(x, \tilde{\lambda}, \tilde{\nu})$ lồi, và theo (d) gradient của nó bằng 0 tại $\tilde{x}$; do (1.4), $\tilde{x}$ là điểm cực tiểu toàn cục của nó. Vậy

$$g(\tilde{\lambda}, \tilde{\nu}) = L(\tilde{x}, \tilde{\lambda}, \tilde{\nu}) = f_0(\tilde{x}) + \sum_i \tilde{\lambda}_i f_i(\tilde{x}) + \sum_j \tilde{\nu}_j h_j(\tilde{x}) = f_0(\tilde{x}),$$

trong đó đẳng thức cuối dùng (a) và (c). Theo Mệnh đề 1.15, $f_0(\tilde{x}) = g(\tilde{\lambda}, \tilde{\nu}) \leq d^* \leq p^* \leq f_0(\tilde{x})$, nên mọi bất đẳng thức đều là đẳng thức. $\square$

Điều kiện bù (c) có một ý nghĩa sẽ được dùng nhiều lần: nếu $\lambda_i^* > 0$ thì ràng buộc thứ i phải *chặt*, $f_i(x^*) = 0$. Trong SVM, điều này có nghĩa là chỉ những điểm dữ liệu nằm đúng trên lề mới có nhân tử dương; đó là các vectơ hỗ trợ. Hai ví dụ dưới đây minh họa lý thuyết trên những bài toán nhỏ mà ta sẽ gặp lại.

Ví dụ 1.19 (Khoảng cách từ một điểm đến một siêu phẳng). Cho siêu phẳng $H = \{x : w^\top x + b = 0\}$ với $w \neq 0$ và một điểm x_0 . Xét bài toán min $\frac{1}{2} \|x - x_0\|^2$ với điều kiện $w^\top x + b = 0$. Hàm Lagrange là $\frac{1}{2} \|x - x_0\|^2 + \nu(w^\top x + b)$; điều kiện dừng cho $x = x_0 - \nu w$, và thay vào ràng buộc ta được $\nu = (w^\top x_0 + b) / \|w\|^2$.



Hình 1.3. (a) Hình chiếu x^* của điểm x_0 lên siêu phẳng $w^\top x + b = 0$ (Ví dụ 1.19). (b) Hàm đối ngẫu của Ví dụ 1.20 luôn nằm dưới giá trị tối ưu p^* và chạm tới p^* tại $\lambda^* = 2$.

Vì bài toán lồi, theo Định lý 1.18(ii) nghiệm là

$$x^* = x_0 - \frac{w^\top x_0 + b}{\|w\|^2} w, \quad \text{và} \quad \text{dist}(x_0, H) = \|x_0 - x^*\| = \frac{|w^\top x_0 + b|}{\|w\|}.$$

Công thức này (Hình 1.3a) là cơ sở của khái niệm lề trong SVM.

Ví dụ 1.20 (Một bài toán đối ngẫu tường minh). Xét bài toán min x^2 với điều kiện $1 - x \leq 0$, có nghiệm $x^* = 1$ và $p^* = 1$. Hàm Lagrange $L(x, \lambda) = x^2 + \lambda(1 - x)$ đạt cực tiểu theo x tại $x = \lambda/2$, nên $g(\lambda) = \lambda - \lambda^2/4$. Bài toán đối ngẫu $\max_{\lambda \geq 0} g(\lambda)$ có nghiệm $\lambda^* = 2$ và $d^* = 1 = p^*$ (Hình 1.3b). Điều kiện bù $\lambda^*(1 - x^*) = 0$ thỏa mãn vì ràng buộc chặt tại nghiệm.

1.5. Hàm tuyến tính từng phần liên tục

Hàm affine $\ell(x) = a^\top x + b$ là loại hàm đơn giản nhất: đồ thị của nó là một siêu phẳng trong $\mathbb{R}^{n+1}$. Bước mở rộng tự nhiên tiếp theo là chia miền xác định thành hữu hạn vùng đa diện và cho phép hàm là affine trên từng vùng, với điều kiện các mảnh được “dán” liên với nhau dọc theo biên chung. Lớp hàm thu được đủ phong phú để xấp xỉ mọi hàm liên tục trên một tập compact,

nhưng vẫn giữ được phần lớn sự đơn giản của hàm affine. Đây là đối tượng trung tâm của đề án: biên quyết định của các mô hình PWL-SVM ở Chương 2 chính là tập không điểm của những hàm như vậy.

1.5.1. Định nghĩa và ví dụ

Định nghĩa 1.21 (Phân hoạch đa diện). Cho $\Omega \subseteq \mathbb{R}^n$. Họ hữu hạn các đa diện $\{\Omega_1, \dots, \Omega_K\}$ được gọi là một *phân hoạch đa diện* của Ω nếu

$$\Omega = \bigcup_{k=1}^K \Omega_k \quad \text{và} \quad \text{int } \Omega_k \cap \text{int } \Omega_l = \emptyset \quad \text{với mọi } k \neq l.$$

Các vùng của một phân hoạch có thể có chung biên, nhưng phần trong của chúng không giao nhau. Chẳng hạn, ba dải ngang $\{x : 0 \leq x(2) \leq \frac{1}{3}\}$, $\{x : \frac{1}{3} \leq x(2) \leq \frac{2}{3}\}$ và $\{x : \frac{2}{3} \leq x(2) \leq 1\}$ của hình vuông đơn vị ở Hình 2.4 là một phân hoạch đa diện của hình vuông đó.


Định nghĩa 1.22 (Hàm tuyến tính từng phần liên tục). Hàm $f : \Omega \rightarrow \mathbb{R}$ được gọi là *hàm tuyến tính từng phần liên tục*, gọi tắt là *hàm PWL*, nếu f liên tục trên Ω và tồn tại một phân hoạch đa diện $\{\Omega_1, \dots, \Omega_K\}$ của Ω cùng các hàm affine $\ell_k(x) = a_k^\top x + b_k$ sao cho

$$f(x) = \ell_k(x) \quad \text{với mọi } x \in \Omega_k, \quad k = 1, \dots, K. \quad (1.6)$$

Các hàm $\ell_1, \dots, \ell_K$ được gọi là các *mảnh* (hay các hàm affine cục bộ) của f .

Nhận xét 1.23. Theo nghĩa chặt, các hàm trong Định nghĩa 1.22 nên gọi là *affine* từng phần, vì mỗi mảnh là một hàm affine chứ không nhất thiết là hàm tuyến tính. Đề án dùng thuật ngữ “tuyến tính từng phần” theo thói quen trong tài liệu học máy và theo bài báo gốc [26]. Điều kiện liên tục là thiết yếu: một hàm bậc thang cũng bằng hằng số trên từng mảnh nhưng không thuộc lớp hàm đang xét. Trong toàn bộ đề án, “hàm PWL” luôn được hiểu là hàm tuyến tính từng phần *liên tục*.

Ví dụ 1.24. Một số hàm PWL sẽ gặp lại nhiều lần trong đề án:




Hình 1.4. (a) Hàm bản lề $h(t) = \max\{0, t\}$ và bản dịch chuyển của nó. (b) Hàm PWL một biến $f(t) = 0,3 + 0,8t - 2(t - 0,35)_+ + 2,5(t - 0,7)_+$ là tổng của một hàm affine và hai hàm bản lề đặt tại hai điểm gãy; hệ số của mỗi bản lề bằng độ thay đổi hệ số góc tại điểm gãy đó (Mệnh đề 1.27).


- (a) Hàm giá trị tuyệt đối $|t| = \max\{t, -t\}$ là hàm PWL trên $\mathbb{R}$ với hai mảnh: $-t$ trên $(-\infty, 0]$ và t trên $[0, +\infty)$.
- (b) Hàm bản lề $h(t) = \max\{0, t\}$, ký hiệu $(t)_+$, có hai mảnh là 0 và t (Hình 1.4a). Trong mạng nơ-ron, hàm này được gọi là hàm kích hoạt ReLU.
- (c) Với $p \in \mathbb{R}^n \setminus \{0\}$ và $q \in \mathbb{R}$, hàm $x \mapsto \max\{0, p^\top x + q\}$ là hàm PWL trên $\mathbb{R}^n$ với hai mảnh, ngăn cách bởi siêu phẳng $p^\top x + q = 0$. Đồ thị của nó gồm hai nửa siêu phẳng nối với nhau dọc theo một “bản lề”; vì thế Breiman [9] gọi nó là *siêu phẳng bản lề* (hinging hyperplane).
- (d) Hàm hai biến

$$f(x) = 0,15 + 0,25x(1) + 0,2x(2) + 0,9(x(1) + x(2) - 0,9)_+ - 1,2(x(1) - 0,6)_+ + 0,8(0,45 - x(2))_+$$

trên hình vuông đơn vị có bảy mảnh (Hình 1.5). Ba đường thẳng mà tại đó các số hạng bản lề đổi trạng thái chia hình vuông thành bảy đa giác lồi $\Omega_1, \dots, \Omega_7$; trên mỗi đa giác, f là một hàm affine và đồ thị của f là một mảnh mặt phẳng.

(a) Đồ thị của f : các mảnh phẳng nối liền

(b) Phân hoạch đa diện (7 vùng)



Hình 1.5. Hàm PWL hai biến của Ví dụ 1.24(d). (a) Đồ thị gồm bảy mảnh mặt phẳng nối liền nhau; các nếp gấp nằm trên ba đường thẳng $x(1) + x(2) = 0,9$, $x(1) = 0,6$ và $x(2) = 0,45$. (b) Phân hoạch đa diện tương ứng của hình vuông đơn vị.

1.5.2. Các phép toán bảo toàn tính tuyến tính từng phần

Kiểm tra trực tiếp một hàm có phải là hàm PWL hay không theo Định nghĩa 1.22 thường khá phiền, vì phải chỉ ra được phân hoạch. Mệnh đề sau cho phép tạo ra các hàm PWL phức tạp từ những hàm đơn giản; nó sẽ được dùng nhiều lần ở Chương 2.

Mệnh đề 1.25. Giả sử $f, g : \mathbb{R}^n \rightarrow \mathbb{R}$ là các hàm PWL và $\alpha, \beta \in \mathbb{R}$. Khi đó $\alpha f + \beta g$, $\max\{f, g\}$ và $\min\{f, g\}$ đều là hàm PWL. Do đó, mọi hàm nhận được từ hữu hạn hàm affine bằng hữu hạn lần áp dụng các phép cộng, nhân với hằng số, lấy max, lấy min và lấy trị tuyệt đối đều là hàm PWL.

Chứng minh. Gọi $\{P_i\}_{i=1}^I$ và $\{Q_j\}_{j=1}^J$ là các phân hoạch đa diện của $\mathbb{R}^n$ ứng với f và g , với các mảnh tương ứng là ℓ_i và m_j . Mỗi tập $R_{ij} = P_i \cap Q_j$ là một đa diện, vì là giao của hữu hạn nửa không gian. Họ $\{R_{ij}\}$ phủ $\mathbb{R}^n$ và có phần trong đôi một rời nhau: nếu $(i, j) \neq (i', j')$ thì hoặc $\text{int } P_i \cap \text{int } P_{i'} = \emptyset$, hoặc $\text{int } Q_j \cap \text{int } Q_{j'} = \emptyset$. Trên R_{ij} ta có $\alpha f + \beta g = \alpha \ell_i + \beta m_j$ là hàm affine; hơn nữa $\alpha f + \beta g$ liên tục. Vậy $\alpha f + \beta g$ là hàm PWL.

Với $\max\{f, g\}$, ta chia tiếp mỗi R_{ij} thành hai đa diện

$$R_{ij}^+ = R_{ij} \cap \{x : \ell_i(x) \geq m_j(x)\}, \quad R_{ij}^- = R_{ij} \cap \{x : \ell_i(x) \leq m_j(x)\}$$

(nếu $\ell_i \equiv m_j$ thì giữ nguyên R_{ij}). Khi $\ell_i - m_j$ không đồng nhất bằng hằng số, hai nửa không gian đóng $\{\ell_i \geq m_j\}$ và $\{\ell_i \leq m_j\}$ có phần trong rời nhau; khi $\ell_i - m_j$ là hằng số khác 0, một trong hai tập là rỗng. Vì vậy họ các tập $R_{ij}^\pm$ vẫn là một phân hoạch đa diện của $\mathbb{R}^n$, và trên R_{ij}^+ (tương ứng R_{ij}^-) ta có $\max\{f, g\} = \ell_i$ (tương ứng m_j). Hàm $\max\{f, g\}$ liên tục vì là cực đại của hai hàm liên tục, nên nó là hàm PWL. Trường hợp $\min\{f, g\} = -\max\{-f, -g\}$ suy ra từ hai trường hợp trên.

Khẳng định cuối có được bằng quy nạp, vì mỗi hàm affine là hàm PWL với phân hoạch tầm thường $\{\mathbb{R}^n\}$ và $|f| = \max\{f, -f\}$. $\square$

Hệ quả 1.26. Các hàm có dạng $\max_{1 \leq j \leq J} \min_{i \in S_j} \ell_i(x)$, với ℓ_i affine và S_j là các tập chỉ số hữu hạn, cũng như các hàm có dạng tổng các bản lẻ

$$a^\top x + b + \sum_{m=1}^D c_m \max\{0, p_m^\top x + q_m\},$$

đều là hàm PWL trên $\mathbb{R}^n$.

1.5.3. Hàm tuyến tính từng phần một biến

Khi $n = 1$, cấu trúc của hàm PWL đặc biệt đơn giản: phân hoạch của $\mathbb{R}$ gồm các khoảng nối tiếp nhau, ngăn cách bởi các *điểm gãy*. Mệnh đề sau cho thấy mọi hàm như vậy là tổng của một hàm affine và các hàm bản lẻ đặt tại các điểm gãy.

Mệnh đề 1.27. Cho $f : \mathbb{R} \rightarrow \mathbb{R}$ là hàm PWL với các điểm gãy $t_1 < t_2 < \dots < t_K$, và gọi $s_0, s_1, \dots, s_K$ lần lượt là hệ số góc của f trên các khoảng $(-\infty, t_1]$,

$[t_1, t_2], \dots, [t_K, +\infty)$. Khi đó, với mọi $t \in \mathbb{R}$,

$$f(t) = f(t_1) + s_0(t - t_1) + \sum_{j=1}^K (s_j - s_{j-1})(t - t_j)_+. \quad (1.7)$$

Chứng minh. Ký hiệu $g(t)$ là vế phải của (1.7). Trên $(-\infty, t_1]$ mọi số hạng bản lề đều bằng 0, nên $g(t) = f(t_1) + s_0(t - t_1) = f(t)$, vì trên khoảng này f là hàm affine với hệ số góc s_0 . Giả sử $f = g$ trên $(-\infty, t_i]$ với một $i \in \{1, \dots, K\}$, và quy ước $t_{K+1} = +\infty$. Trên $[t_i, t_{i+1}]$, các số hạng bản lề với $j \leq i$ bằng $t - t_j$, còn các số hạng với $j > i$ bằng 0. Do đó g là hàm affine trên khoảng này với hệ số góc

$$s_0 + \sum_{j=1}^i (s_j - s_{j-1}) = s_i,$$

trùng với hệ số góc của f . Hai hàm affine có cùng hệ số góc và cùng giá trị tại t_i thì trùng nhau, nên $f = g$ trên $(-\infty, t_{i+1}]$. Theo quy nạp, $f = g$ trên toàn $\mathbb{R}$. $\square$

Nhận xét 1.28. Hệ số của hàm bản lề đặt tại t_j chính là độ thay đổi hệ số góc $s_j - s_{j-1}$, tức là “độ gãy” của đồ thị tại t_j (Hình 1.4b). Mệnh đề 1.27 có một hệ quả quan trọng cho học máy: nếu các điểm gãy được cố định trước, thì mọi hàm PWL một biến với các điểm gãy đó là tổ hợp tuyến tính của $K + 2$ hàm *cố định* $1, t, (t - t_1)_+, \dots, (t - t_K)_+$. Khi ấy, học một hàm PWL chỉ còn là tìm các hệ số của một tổ hợp tuyến tính, tức là một bài toán tuyến tính theo tham số. Đây chính là ý tưởng của ánh xạ đặc trưng cộng tính ở Mục 2.6.

1.5.4. Biểu diễn hàm tuyến tính từng phần nhiều biến

Khi $n \geq 2$, phân hoạch đa diện có thể rất phức tạp và các vùng không còn được sắp thứ tự tự nhiên như trên đường thẳng. Dù vậy, hai định lý dưới đây khẳng định rằng mọi hàm PWL vẫn viết được dưới những dạng tường minh và gọn. Chứng minh của chúng khá dài và nằm ngoài phạm vi đề án; ta chỉ phát biểu và phân tích ý nghĩa.

Định lý 1.29 (Biểu diễn max–min [46, 35]). Cho $f : \mathbb{R}^n \rightarrow \mathbb{R}$ là hàm PWL

với các mảnh $\ell_1, \dots, \ell_K$. Khi đó tồn tại các tập chỉ số $S_1, \dots, S_J \subseteq \{1, \dots, K\}$ sao cho

$$f(x) = \max_{1 \leq j \leq J} \min_{i \in S_j} \ell_i(x) \quad \text{với mọi } x \in \mathbb{R}^n. \quad (1.8)$$

Định lý 1.30 (Wang và Sun [52, Định lý 1]). Với mọi hàm PWL $f : \mathbb{R}^n \rightarrow \mathbb{R}$, tồn tại số nguyên dương D , các dấu $\sigma_1, \dots, \sigma_D \in \{-1, 1\}$ và các hàm affine $\ell_{m,i}$ ($m = 1, \dots, D; i = 0, \dots, n$) sao cho

$$f(x) = \sum_{m=1}^D \sigma_m \max\{\ell_{m,0}(x), \ell_{m,1}(x), \dots, \ell_{m,n}(x)\} \quad \text{với mọi } x \in \mathbb{R}^n. \quad (1.9)$$

Nhận xét 1.31. Có bốn điểm cần lưu ý về hai định lý trên.

- (i) Trong [52], mỗi số hạng là cực đại của *không quá* $n + 1$ hàm affine; lặp lại một hàm nếu cần, ta luôn có thể coi mỗi số hạng có đúng $n + 1$ hàm như trong (1.9). Mỗi số hạng là một dạng tổng quát của siêu phẳng bản lề, và Wang cùng Sun gọi mô hình (1.9) là *siêu phẳng bản lề tổng quát* (GHH).
- (ii) Khi $n = 1$, mỗi số hạng $\max\{\ell_0, \ell_1\} = \ell_0 + (\ell_1 - \ell_0)_+$ là một hàm affine cộng một hàm bản lề, và (1.9) trở về dạng của Mệnh đề 1.27. Khi $n \geq 2$, các số hạng hai mảnh $\max\{\ell_0, \ell_1\}$ của Breiman không còn đủ: tổng các siêu phẳng bản lề xấp xỉ được mọi hàm liên tục trên một tập compact [9] nhưng không biểu diễn đúng được mọi hàm PWL [52]. Định lý 1.30 cho biết $n + 1$ mảnh trong mỗi số hạng là đủ.
- (iii) Cả hai định lý chỉ khẳng định sự tồn tại; số số hạng J hay D có thể lớn hơn nhiều so với số mảnh K . Trong thực hành, điều này trở thành câu hỏi: cần bao nhiêu đặc trưng? Chương 3 sẽ trả lời câu hỏi này bằng thực nghiệm.
- (iv) Lớp hàm PWL cũng chính là lớp hàm mà mạng nơ-ron ReLU biểu diễn được: một hàm $\mathbb{R}^n \rightarrow \mathbb{R}$ biểu diễn được bởi một mạng ReLU (với số lớp đủ lớn) khi và chỉ khi nó là hàm PWL [3].

Tiểu kết Chương 1

Chương 1 đã chuẩn bị ba nhóm công cụ. Thứ nhất là hình học lồi: tập lồi, đa diện và định lý siêu phẳng phân tách, trong đó Hệ quả 1.10 cho điều kiện cần và đủ để hai tập điểm tách tuyến tính được. Thứ hai là tối ưu lồi và đối ngẫu: mọi cực tiểu địa phương của bài toán lồi là toàn cục, và khi các ràng buộc là affine, đối ngẫu mạnh cùng điều kiện KKT cho phép chuyển qua lại giữa bài toán gốc và bài toán đối ngẫu. Thứ ba là lớp hàm tuyến tính từng phần liên tục: lớp này đóng với các phép cộng, lấy cực đại và cực tiểu, và mọi hàm trong lớp đều viết được thành tổng các hàm bản lề tổng quát (Định lý 1.30). Chương 2 dùng hai nhóm công cụ đầu để xây dựng SVM, và nhóm thứ ba để xây dựng ánh xạ đặc trưng tuyến tính từng phần.

CHƯƠNG 2

SVM VÀ SVM VỚI ÁNH XẠ ĐẶC TRƯNG TUYẾN TÍNH TỪNG PHẦN

Đây là chương chính của đề án. Mục 2.1–2.3 trình bày SVM theo trình tự lễ cứng, lễ mềm, ánh xạ đặc trưng và LS-SVM, dựa trên các công cụ tối ưu của Chương 1. Mục 2.4–2.6 trình bày phương pháp của Huang, Mehrkanoon và Suykens [26]: từ khái niệm tập tuyến tính từng phần, qua ánh xạ đặc trưng tuyến tính từng phần và các mô hình PWL-SVM, đến các dạng ánh xạ cụ thể và cách chọn tham số. Mục 2.7 chỉ ra rằng một số bộ phân loại tuyến tính từng phần quen thuộc là trường hợp riêng của PWL-SVM.

Trong suốt chương, dữ liệu huấn luyện là $\{(x_k, y_k)\}_{k=1}^N$ với $x_k \in \mathbb{R}^n$ và nhãn $y_k \in \{-1, +1\}$; $x(i)$ là thành phần thứ i của vectơ x . Một bộ phân loại là một hàm $f : \mathbb{R}^n \rightarrow \mathbb{R}$ cùng quy tắc gán nhãn $\hat{y}(x) = \text{sign } f(x)$; tập $\{x : f(x) = 0\}$ là *biên quyết định*. Ta luôn giả thiết cả hai lớp đều có mặt trong dữ liệu.

2.1. Bài toán phân loại nhị phân và SVM lễ cứng

Bộ phân loại tuyến tính có dạng $f(x) = w^\top x + w_0$ với $w \in \mathbb{R}^n$ và hệ số chặn $w_0 \in \mathbb{R}$; biên quyết định của nó là siêu phẳng $H = \{x : w^\top x + w_0 = 0\}$. Giả sử trước hết dữ liệu tách tuyến tính được. Khi đó thường có vô số siêu phẳng phân loại đúng toàn bộ dữ liệu huấn luyện (Hình 2.1a), và câu hỏi đặt ra là nên chọn siêu phẳng nào. Ý tưởng của SVM [13, 50] là chọn siêu phẳng cách xa dữ liệu nhất: một biên nằm sát một điểm huấn luyện sẽ dễ phân loại sai những điểm mới ở gần điểm đó, còn một biên có khoảng trống rộng hai bên thì chịu được các nhiễu loạn nhỏ của dữ liệu.

Lễ và bài toán tối ưu. Theo Ví dụ 1.19, khoảng cách từ x_k đến H là $|w^\top x_k + w_0|/\|w\|$. Nếu H phân loại đúng x_k thì $y_k(w^\top x_k + w_0) > 0$, nên

khoảng cách này bằng $y_k(w^\top x_k + w_0)/\|w\|$. Lề của siêu phẳng là khoảng cách từ điểm gần nhất đến nó:

$$\rho(w, w_0) = \min_{1 \leq k \leq N} \frac{y_k(w^\top x_k + w_0)}{\|w\|}.$$

SVM tìm (w, w_0) cực đại hóa ρ . Hai cặp (w, w_0) và (cw, cw_0) với $c > 0$ xác định cùng một siêu phẳng và cùng một lề, nên ta được phép chuẩn hóa sao cho $\min_k y_k(w^\top x_k + w_0) = 1$; khi đó $\rho = 1/\|w\|$. Cực đại hóa $1/\|w\|$ tương đương với cực tiểu hóa $\|w\|$, và do đó tương đương với cực tiểu hóa $\frac{1}{2}\|w\|^2$, một hàm khả vi và lồi chặt theo w (hệ số $\frac{1}{2}$ chỉ để gradient gọn hơn). Cuối cùng, điều kiện chuẩn hóa có thể nói thành $y_k(w^\top x_k + w_0) \geq 1$ với mọi k : nếu ở một nghiệm của bài toán nói mà giá trị nhỏ nhất $\mu = \min_k y_k(w^\top x_k + w_0)$ lớn hơn 1 thì $(w, w_0)/\mu$ vẫn chấp nhận được và có chuẩn nhỏ hơn, vô lý. Ta được *bài toán SVM lề cứng*

$$\min_{w, w_0} \frac{1}{2}\|w\|^2 \quad \text{với điều kiện} \quad y_k(w^\top x_k + w_0) \geq 1, \quad k = 1, \dots, N. \quad (2.1)$$

Đây là một quy hoạch toàn phương với miền ràng buộc là một đa diện trong $\mathbb{R}^{n+1}$ (Mục 1.1).

Mệnh đề 2.1. *Bài toán (2.1) có điểm chấp nhận được khi và chỉ khi $\text{conv}\{x_k : y_k = 1\} \cap \text{conv}\{x_k : y_k = -1\} = \emptyset$. Khi đó bài toán có nghiệm duy nhất (w^*, w_0^*) , và tồn tại ít nhất một điểm mỗi lớp mà tại đó ràng buộc chặt.*

Chứng minh. Khẳng định đầu là Hệ quả 1.10. Giả sử bài toán chấp nhận được. Lấy k với $y_k = 1$ và l với $y_l = -1$; các ràng buộc cho $1 - w^\top x_k \leq w_0 \leq -1 - w^\top x_l$, nên với w bị chặn thì w_0 bị chặn. Do đó ta có thể hạn chế bài toán trên một tập con compact khác rỗng của miền ràng buộc, và nghiệm tồn tại. Nếu tại một nghiệm không có ràng buộc chặt nào thuộc lớp +1, thì giảm w_0 một lượng nhỏ làm mọi ràng buộc của lớp -1 trở thành không chặt; khi đó mọi ràng buộc đều không chặt, và ta có thể thu nhỏ (w, w_0) như trong lập luận chuẩn hóa ở trên, mâu thuẫn. Lập luận tương tự cho lớp -1. Nếu hai nghiệm có w khác nhau thì trung điểm của chúng chấp nhận được và, do $\frac{1}{2}\|w\|^2$ lồi

chặt, cho giá trị mục tiêu nhỏ hơn giá trị tối ưu, vô lý; vậy mọi nghiệm có cùng w^* . Nếu (w^*, w_0) và (w^*, w'_0) đều là nghiệm thì trung điểm $(w^*, \frac{w_0+w'_0}{2})$ cũng là nghiệm, nên có một điểm x_k thuộc lớp +1 với $w^{*\top}x_k + \frac{w_0+w'_0}{2} = 1$; vì $w^{*\top}x_k + w_0 \geq 1$ và $w^{*\top}x_k + w'_0 \geq 1$, cả hai đều phải bằng 1, tức $w_0 = w'_0$. $\square$

Bài toán đối ngẫu. Với nhân tử $\alpha_k \geq 0$ cho ràng buộc thứ k , hàm Lagrange của (2.1) là

$$L(w, w_0, \alpha) = \frac{1}{2}\|w\|^2 - \sum_{k=1}^N \alpha_k [y_k(w^\top x_k + w_0) - 1].$$

Hàm này lồi theo (w, w_0) ; cho các đạo hàm riêng bằng 0 ta được

$$w = \sum_{k=1}^N \alpha_k y_k x_k, \quad \sum_{k=1}^N \alpha_k y_k = 0. \quad (2.2)$$

Nếu $\sum_k \alpha_k y_k \neq 0$ thì L không bị chặn dưới theo w_0 , nên $g(\alpha) = -\infty$. Thế (2.2) vào L ta được bài toán đối ngẫu

$$\max_{\alpha} \sum_{k=1}^N \alpha_k - \frac{1}{2} \sum_{k=1}^N \sum_{l=1}^N \alpha_k \alpha_l y_k y_l x_k^\top x_l \quad (2.3)$$

$$\text{với điều kiện } \alpha_k \geq 0, \quad k = 1, \dots, N; \quad \sum_{k=1}^N \alpha_k y_k = 0.$$

Vì các ràng buộc của (2.1) là affine, theo Định lý 1.16 có đối ngẫu mạnh, và theo Định lý 1.18 nghiệm của hai bài toán liên hệ với nhau qua điều kiện KKT. Điều kiện bù

$$\alpha_k [y_k(w^{*\top}x_k + w_0^*) - 1] = 0, \quad k = 1, \dots, N,$$

cho thấy $\alpha_k > 0$ chỉ khi x_k nằm đúng trên một trong hai siêu phẳng $w^{*\top}x + w_0^* = \pm 1$. Những điểm này được gọi là các *vectơ hỗ trợ* (Hình 2.1b). Theo (2.2), w^* là tổ hợp tuyến tính của riêng các vectơ hỗ trợ: các điểm khác có thể bị xóa

khỏi dữ liệu mà nghiệm không thay đổi. Hệ số chặn được tính từ một vectơ hỗ trợ bất kỳ x_s bởi $w_0^* = y_s - w^{*\top} x_s$; trong tính toán số, người ta lấy trung bình theo mọi vectơ hỗ trợ để giảm sai số. Bộ phân loại thu được là

$$\hat{y}(x) = \text{sign}\left(\sum_{k=1}^N \alpha_k y_k x_k^\top x + w_0^*\right). \quad (2.4)$$

Cả (2.3) và (2.4) chỉ phụ thuộc vào dữ liệu qua các tích vô hướng $x_k^\top x_l$ và $x_k^\top x$; tính chất này là cơ sở của thủ thuật hạt nhân ở Mục 2.3.

Diễn giải hình học của bài toán đối ngẫu. Bài toán đối ngẫu có một ý nghĩa hình học rõ ràng, gắn với Định lý 1.8.


Mệnh đề 2.2 ([6]). *Giả sử dữ liệu tách tuyến tính được, và gọi $A = \{x_k : y_k = 1\}$, $B = \{x_k : y_k = -1\}$. Bài toán (2.3) tương đương với bài toán tìm hai điểm gần nhau nhất của hai bao lồi,*

$$\min \|u - v\| \quad \text{với} \quad u \in \text{conv } A, v \in \text{conv } B.$$

Nếu (u^, v^*) là nghiệm thì $w^* = 2(u^* - v^*)/\|u^* - v^*\|^2$, và lẻ cực đại bằng $\frac{1}{2}\|u^* - v^*\|$.*

Chứng minh. Với α chấp nhận được và khác 0, đặt $s = \sum_{y_k=1} \alpha_k$; ràng buộc $\sum_k \alpha_k y_k = 0$ cho $\sum_{y_k=-1} \alpha_k = s$, nên $\sum_k \alpha_k = 2s$. Các điểm $u = \sum_{y_k=1} (\alpha_k/s) x_k$ và $v = \sum_{y_k=-1} (\alpha_k/s) x_k$ là tổ hợp lồi, tức $u \in \text{conv } A$, $v \in \text{conv } B$, và $\sum_k \alpha_k y_k x_k = s(u - v)$. Ngược lại, mọi bộ (s, u, v) với $s > 0$, $u \in \text{conv } A$, $v \in \text{conv } B$ đều ứng với một α chấp nhận được. Hàm mục tiêu đối ngẫu trở thành $2s - \frac{1}{2}s^2\|u - v\|^2$; với u, v cố định (và $u \neq v$ vì hai bao lồi rời nhau theo Hệ quả 1.10), nó đạt cực đại tại $s = 2/\|u - v\|^2$ với giá trị $2/\|u - v\|^2$. Vì vậy cực đại hóa hàm mục tiêu đối ngẫu tương đương với cực tiểu hóa $\|u - v\|$. Tại nghiệm, $w^* = s(u^* - v^*) = 2(u^* - v^*)/\|u^* - v^*\|^2$, nên lẻ bằng $1/\|w^*\| = \frac{1}{2}\|u^* - v^*\|$. $\square$

Như vậy siêu phẳng tối ưu vuông góc với đoạn nối hai điểm gần nhau



Hình 2.1. SVM lề cứng. (a) Dữ liệu tách được thường có nhiều siêu phẳng phân loại đúng. (b) Siêu phẳng lề cực đại (nét liền), hai siêu phẳng $w^\top x + w_0 = \pm 1$ (nét đứt) và các vectơ hỗ trợ (khoanh tròn); khoảng cách giữa hai nét đứt là $2/\|w\|$. (c) Cách nhìn đối ngẫu: siêu phẳng tối ưu là trung trực của đoạn nối hai điểm gần nhau nhất của hai bao lồi.

nhất của hai bao lồi. Nó còn đi qua trung điểm của đoạn đó: tại nghiệm, u^* là tổ hợp lồi của các vectơ hỗ trợ lớp +1, là những điểm thỏa $w^{*\top} x + w_0^* = 1$, nên $w^{*\top} u^* + w_0^* = 1$; tương tự $w^{*\top} v^* + w_0^* = -1$. Đó chính là siêu phẳng dựng trong chứng minh Định lý 1.8 (Hình 2.1c).

2.2. SVM lề mềm và hàm mất mát bản lề

Khi hai bao lồi giao nhau, bài toán (2.1) vô nghiệm (Mệnh đề 2.1). Dữ liệu thực tế hầu như luôn ở trong trường hợp này, do nhiễu hoặc do bản chất chồng lấn của hai lớp. Cortes và Vapnik [13] nói các ràng buộc bằng các *biến bù* $e_k \geq 0$ và phạt tổng các biến bù trong hàm mục tiêu:

$$\min_{w, w_0, e} \quad \frac{1}{2} \|w\|^2 + \gamma \sum_{k=1}^N e_k \quad (2.5)$$

$$\text{với điều kiện} \quad y_k (w^\top x_k + w_0) \geq 1 - e_k, \quad e_k \geq 0, \quad k = 1, \dots, N,$$

trong đó $\gamma > 0$ là hằng số chính quy hóa, thường được gọi là C trong các thư viện phần mềm; mô hình này được gọi là C -SVM. Điểm x_k với $e_k = 0$ thỏa mãn ràng buộc lề như trước; điểm với $0 < e_k < 1$ nằm trong dải lề nhưng vẫn được phân loại đúng; điểm với $e_k > 1$ bị phân loại sai (Hình 2.2a).

Mệnh đề 2.3. Bài toán (2.5) tương đương với bài toán không ràng buộc

$$\min_{w, w_0} \frac{1}{2} \|w\|^2 + \gamma \sum_{k=1}^N \max\{0, 1 - y_k(w^\top x_k + w_0)\}. \quad (2.6)$$

Chứng minh. Với (w, w_0) cố định, giá trị nhỏ nhất của e_k thỏa hai ràng buộc $e_k \geq 1 - y_k(w^\top x_k + w_0)$ và $e_k \geq 0$ là $\max\{0, 1 - y_k(w^\top x_k + w_0)\}$; vì hàm mục tiêu tăng theo e_k , tại nghiệm e_k nhận đúng giá trị đó. $\square$

Hàm $\ell(t) = \max\{0, 1 - t\} = (1 - t)_+$ được gọi là *hàm mất mát bản lề*; nó chính là hàm bản lề của Mục 1.5, dịch và lật. Dạng (2.6) cho thấy C-SVM là một bài toán *cực tiểu hóa rủi ro thực nghiệm có chính quy hóa*: số hạng thứ hai đo sai số trên dữ liệu, số hạng thứ nhất khống chế độ phức tạp của mô hình qua độ rộng của lề. Vì $(1 - t)_+ \geq \mathbf{1}\{t \leq 0\}$, tổng các mất mát bản lề là một cận trên của số điểm huấn luyện bị phân loại sai; khác với mất mát 0–1, nó là hàm lồi, nên bài toán (2.6) là bài toán lồi (Mệnh đề 1.12). Hình 2.2b so sánh ba hàm mất mát thường gặp.

Bài toán đối ngẫu. Với các nhân tử $\alpha_k \geq 0$ và $\mu_k \geq 0$ cho hai nhóm ràng buộc, hàm Lagrange của (2.5) là

$$L = \frac{1}{2} \|w\|^2 + \gamma \sum_k e_k - \sum_k \alpha_k [y_k(w^\top x_k + w_0) - 1 + e_k] - \sum_k \mu_k e_k.$$

Điều kiện dừng theo w và w_0 vẫn là (2.2); điều kiện dừng theo e_k cho $\gamma - \alpha_k - \mu_k = 0$. Vì $\mu_k \geq 0$, ta có $\alpha_k \leq \gamma$, và các số hạng chứa e_k triệt tiêu. Bài toán đối ngẫu của C-SVM vì vậy có cùng hàm mục tiêu với (2.3), chỉ khác ở ràng buộc hộp:

$$\max_{\alpha} \sum_{k=1}^N \alpha_k - \frac{1}{2} \sum_{k=1}^N \sum_{l=1}^N \alpha_k \alpha_l y_k y_l x_k^\top x_l \quad (2.7)$$


với điều kiện $0 \leq \alpha_k \leq \gamma, \quad k = 1, \dots, N; \quad \sum_{k=1}^N \alpha_k y_k = 0.$

Bài toán gốc (2.5) luôn chấp nhận được (chọn $w = 0$, $w_0 = 0$, $e_k = 1$) và có ràng buộc affine, nên có đối ngẫu mạnh.

Ba loại điểm dữ liệu. Hai điều kiện bù $\alpha_k [y_k f(x_k) - 1 + e_k] = 0$ và $(\gamma - \alpha_k) e_k = 0$, với $f(x) = w^{*\top} x + w_0^*$, chia dữ liệu thành ba loại:

- (i) $\alpha_k = 0$: khi đó $\mu_k = \gamma > 0$ nên $e_k = 0$ và $y_k f(x_k) \geq 1$. Điểm được phân loại đúng và nằm ngoài (hoặc trên) dải lề; nó không ảnh hưởng đến nghiệm.
- (ii) $0 < \alpha_k < \gamma$: khi đó $e_k = 0$ và $y_k f(x_k) = 1$. Điểm nằm đúng trên lề; các điểm loại này được dùng để tính $w_0^* = y_k - w^{*\top} x_k$.
- (iii) $\alpha_k = \gamma$: khi đó $y_k f(x_k) = 1 - e_k \leq 1$. Điểm nằm trong dải lề hoặc bị phân loại sai.

Các điểm loại (ii) và (iii) là các vectơ hỗ trợ. Hằng số γ cân bằng giữa độ rộng của lề và số điểm vi phạm lề: γ lớn phạt nặng các vi phạm và cho lề hẹp; khi dữ liệu tách được và $\gamma \rightarrow \infty$, ta trở lại SVM lề cứng. γ nhỏ cho lề rộng và nhiều vectơ hỗ trợ hơn. Trong thực hành, γ được chọn bằng kiểm định chéo (Chương 3).



Hình 2.2. (a) SVM lề mềm trên dữ liệu chồng lấn: các điểm vi phạm lề được nối bằng nét chấm tới siêu phẳng lề của lớp mình, độ dài nét chấm bằng $e_k/\|w\|$; khoanh tròn là các vectơ hỗ trợ nằm đúng trên lề. (b) Mất mát 0-1, mất mát bản lề của C-SVM và mất mát bình phương của LS-SVM, theo $t = yf(x)$.


2.3. Ánh xạ đặc trưng, hạt nhân và LS-SVM

2.3.1. Ánh xạ đặc trưng và thủ thuật hạt nhân

Một bộ phân loại tuyến tính không thể tách hai vòng tròn đồng tâm (Hình 2.3a). Tuy nhiên, nếu thêm vào mỗi điểm tọa độ thứ ba $z = x(1)^2 + x(2)^2$, tức là dùng ánh xạ $\varphi(x) = (x(1), x(2), x(1)^2 + x(2)^2)$, thì trong $\mathbb{R}^3$ hai lớp được tách bởi một mặt phẳng $z = \text{hằng số}$ (Hình 2.3b). Tổng quát, cho một ánh xạ đặc trưng φ từ $\mathbb{R}^n$ vào một không gian đặc trưng $\mathcal{F}$ (hữu hạn hoặc vô hạn chiều, có tích vô hướng), ta áp dụng SVM tuyến tính cho dữ liệu $\{(\varphi(x_k), y_k)\}$. Bộ phân loại thu được, $\text{sign}(w^\top \varphi(x) + w_0)$, tuyến tính trong $\mathcal{F}$ nhưng phi tuyến trong $\mathbb{R}^n$.

Như đã nhận xét ở Mục 2.1, bài toán đối ngẫu (2.7) và bộ phân loại chỉ phụ thuộc vào dữ liệu qua các tích vô hướng. Vì vậy, sau khi thay x_k bởi $\varphi(x_k)$, ta chỉ cần biết hàm

$$\kappa(x, z) = \varphi(x)^\top \varphi(z), \quad (2.8)$$



Hình 2.3. (a) Hai vòng tròn đồng tâm không tách tuyến tính được trong $\mathbb{R}^2$. (b) Sau ánh xạ $\varphi(x) = (x(1), x(2), z)$ với $z = x(1)^2 + x(2)^2$, một mặt phẳng tách được hai lớp.

gọi là *hạt nhân*, mà không cần tính φ một cách tường minh. Bài toán đối ngẫu có dạng (2.7) với $x_k^\top x_l$ thay bởi $\kappa(x_k, x_l)$, và bộ phân loại là

$$\hat{y}(x) = \text{sign}\left(\sum_{k=1}^N \alpha_k y_k \kappa(x, x_k) + w_0\right). \quad (2.9)$$

Đây là *thủ thuật hạt nhân* [7, 39]. Một hàm đối xứng κ là hạt nhân, tức là viết được dưới dạng (2.8) với một ánh xạ φ nào đó, khi và chỉ khi với mọi tập hữu hạn điểm $x_1, \dots, x_N$, ma trận $[\kappa(x_k, x_l)]_{k,l}$ là nửa xác định dương (điều kiện Mercer, xem [39, Chương 2]). Ba hạt nhân thông dụng nhất là hạt nhân tuyến tính $\kappa(x, z) = x^\top z$, hạt nhân đa thức $\kappa(x, z) = (x^\top z + c)^d$ và hạt nhân Gauss (còn gọi là hạt nhân RBF)

$$\kappa(x, z) = \exp(-\|x - z\|^2 / \sigma^2), \quad \sigma > 0.$$

Với hạt nhân Gauss, không gian đặc trưng là vô hạn chiều, nên vectơ $w = \sum_k \alpha_k y_k \varphi(x_k)$ không thể được lưu một cách tường minh. Bộ phân loại (2.9) vì vậy phải lưu toàn bộ N_s vectơ hỗ trợ, và mỗi lần dự đoán cần tính N_s khoảng

cách và N_s hàm mũ. Với dữ liệu lớn, N_s thường tỉ lệ với N , nên chi phí dự đoán và bộ nhớ tăng theo kích thước dữ liệu huấn luyện. Ngược lại, khi φ tường minh và hữu hạn chiều, ta có thể tính w một lần sau khi huấn luyện và dự đoán bằng một tích vô hướng trong $\mathbb{R}^M$. Nhận xét này là điểm xuất phát của PWL-SVM (Mục 2.5).

2.3.2. SVM bình phương tối thiểu

Suykens và Vandewalle [42] đề xuất một biến thể của SVM trong đó ràng buộc bất đẳng thức được thay bằng đẳng thức và mất mát tuyến tính của biến bù được thay bằng mất mát bình phương:

$$\min_{w, w_0, e} \quad \frac{1}{2} \|w\|^2 + \frac{\gamma}{2} \sum_{k=1}^N e_k^2 \quad (2.10)$$

$$\text{với điều kiện} \quad y_k (w^\top \varphi(x_k) + w_0) = 1 - e_k, \quad k = 1, \dots, N.$$

Mô hình này được gọi là *LS-SVM*. Hàm Lagrange là

$$L(w, w_0, e, \alpha) = \frac{1}{2} \|w\|^2 + \frac{\gamma}{2} \sum_k e_k^2 - \sum_k \alpha_k [y_k (w^\top \varphi(x_k) + w_0) - 1 + e_k],$$

với các nhân tử $\alpha_k \in \mathbb{R}$ không bị ràng buộc dấu (vì các ràng buộc là đẳng thức). Bài toán lồi với ràng buộc affine nên điều kiện KKT là cần và đủ (Định lý 1.18):

$$\begin{aligned} w &= \sum_k \alpha_k y_k \varphi(x_k), & \sum_k \alpha_k y_k &= 0, \\ \alpha_k &= \gamma e_k, & y_k (w^\top \varphi(x_k) + w_0) &= 1 - e_k, & k &= 1, \dots, N. \end{aligned}$$

Thế đẳng thức thứ nhất và thứ ba vào đẳng thức cuối, ta được

$$\sum_{l=1}^N y_k y_l \kappa(x_k, x_l) \alpha_l + y_k w_0 + \frac{\alpha_k}{\gamma} = 1, \quad k = 1, \dots, N;$$

Bảng 2.1. So sánh C-SVM và LS-SVM với một hạt nhân tổng quát.

	C-SVM	LS-SVM
Ràng buộc	bất đẳng thức, $e_k \geq 0$	đẳng thức
Mất mát	bản lề $(1 - t)_+$	bình phương $(1 - t)^2$
Bài toán đối ngẫu	quy hoạch toàn phương với ràng buộc hộp	hệ tuyến tính $(N + 1)$ ẩn
Tính thừa của nghiệm	chỉ các vectơ hỗ trợ có $\alpha_k \neq 0$	nói chung mọi $\alpha_k \neq 0$
Công cụ giải điển hình	SMO [37], LIBSVM [11]	phân tích Cholesky, gradient liên hợp

cùng với đẳng thức thứ hai, đó là hệ tuyến tính $(N + 1)$ ẩn


$$\begin{bmatrix} 0 & y^\top \\ y & \Theta + \gamma^{-1}I \end{bmatrix} \begin{bmatrix} w_0 \\ \alpha \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{1} \end{bmatrix}, \quad \Theta_{kl} = y_k y_l \kappa(x_k, x_l), \quad (2.11)$$

với $y = (y_1, \dots, y_N)^\top$ và $\mathbf{1} \in \mathbb{R}^N$ là vectơ gồm toàn số 1. Ma trận Θ nửa xác định dương, nên $H = \Theta + \gamma^{-1}I$ xác định dương; phần bù Schur $-y^\top H^{-1}y$ của khối H âm, do đó ma trận của hệ (2.11) khả nghịch và hệ có nghiệm duy nhất. Bộ phân loại có dạng (2.9).

So với C-SVM, LS-SVM đổi một bài toán quy hoạch toàn phương lấy một hệ phương trình tuyến tính, dễ giải và dễ cài đặt hơn. Đổi lại, vì $\alpha_k = \gamma e_k$ và e_k nói chung khác 0, gần như mọi điểm huấn luyện đều có nhân tử khác 0: nghiệm không còn thừa, và với hạt nhân Gauss, bộ phân loại phải lưu toàn bộ N điểm huấn luyện. Bảng 2.1 tóm tắt sự khác biệt giữa hai mô hình.

2.4. Tập tuyến tính từng phần và phương trình tuyến tính từng phần

Trong bài toán phân loại hai lớp, miền dữ liệu được chia làm hai phần bởi một biên. Với bộ phân loại tuyến tính, biên là một siêu phẳng, tức là tập nghiệm của một phương trình tuyến tính $f(x) = 0$, và điểm x được xếp vào lớp $\text{sign } f(x)$. Theo Huang và cộng sự [26], ta gọi *khả năng phân loại* của một họ bộ phân loại là mức độ phong phú về kiểu dáng của các biên mà họ đó tạo ra được. Theo nghĩa này, khả năng phân loại của bộ phân loại tuyến tính là rất hạn chế. Mở rộng đơn giản nhất của một siêu phẳng là một *tập tuyến tính*



Hình 2.4. Một biên tuyến tính từng phần cho dữ liệu hai mặt trắng ($N = 600$). (a) Biên gồm ba đoạn thẳng, tách đúng 599/600 điểm. (b) Trên mỗi dải Ω_k , biên trùng với một đoạn của đường thẳng $c_k^T x + d_k = 0$ (các phần kéo dài được vẽ bằng nét chấm). Dữ liệu và biên được tính bằng mã của đề án; ý tưởng theo Hình 1 của [26].

từng phần: trên mỗi vùng của miền, tập đó trùng với một siêu phẳng.

Xét dữ liệu hai mặt trắng ở Hình 2.4a. Hai lớp đan vào nhau nên không một đường thẳng nào tách được chúng, nhưng một đường gấp khúc gồm ba đoạn thẳng thì tách gần như hoàn hảo. Ta có thể mô tả đường gấp khúc này như sau. Chia hình vuông đơn vị thành ba dải ngang

$$\Omega_k = \left\{ x \in [0, 1]^2 : \frac{k-1}{3} \leq x(2) \leq \frac{k}{3} \right\}, \quad k = 1, 2, 3;$$

trên mỗi dải, biên là một đoạn của đường thẳng $c_k^T x + d_k = 0$ (Hình 2.4b). Do đó

$$\mathcal{B} = \bigcup_{k=1}^3 \{x \in \Omega_k : c_k^T x + d_k = 0\}.$$

Cách tìm các hệ số c_k, d_k trong hình sẽ được trình bày ở Mục 2.6; ở đây ta chỉ quan tâm đến cấu trúc của biên.

Định nghĩa 2.4 (Tập tuyến tính từng phần [26]). Cho $\Omega \subseteq \mathbb{R}^n$. Tập $\mathcal{B} \subseteq \Omega$ được gọi là một *tập tuyến tính từng phần* (tập PWL) nếu

- (i) có một phân hoạch đa diện $\{\Omega_1, \dots, \Omega_K\}$ của Ω (Định nghĩa 1.21), và
- (ii) với mỗi k , tồn tại $c_k \in \mathbb{R}^n$ và $d_k \in \mathbb{R}$, không đồng thời bằng 0, sao cho

$$\mathcal{B} \cap \Omega_k = \{x \in \Omega_k : c_k^\top x + d_k = 0\}.$$

Nhận xét 2.5. Điều kiện “ $x \in \Omega_k$ ” trong (ii) là cần thiết: thiếu nó, vế phải là cả một siêu phẳng, thường không nằm trong Ω_k . Nếu $c_k = 0$ thì $d_k \neq 0$ và $\mathcal{B} \cap \Omega_k = \emptyset$, tức là biên không đi qua vùng Ω_k ; điều này cho phép các vùng “trống”. Điều kiện $(c_k, d_k) \neq (0, 0)$ loại trừ trường hợp $\mathcal{B}$ chứa trọn một vùng, vì khi đó $\mathcal{B}$ không còn là một biên theo nghĩa thông thường.

Định lý sau cho thấy mọi tập PWL đều là tập nghiệm của một phương trình tuyến tính từng phần, tương tự như siêu phẳng là tập nghiệm của một phương trình tuyến tính.

Định lý 2.6 ([26], Định lý 1). *Mọi tập tuyến tính từng phần $\mathcal{B}$ đều là tập nghiệm của một phương trình tuyến tính từng phần: tồn tại hàm PWL $f : \mathbb{R}^n \rightarrow \mathbb{R}$ sao cho $\mathcal{B} = \{x \in \mathbb{R}^n : f(x) = 0\}$.*

Chứng minh. Dùng các ký hiệu của Định nghĩa 2.4 và viết mỗi đa diện dưới dạng

$$\Omega_k = \{x : a_{ki}^\top x + b_{ki} \leq 0, i = 1, \dots, I_k\}, \quad k = 1, \dots, K.$$

Với mỗi k , đặt

$$g_k(x) = \max \left\{ |c_k^\top x + d_k|, \max_{1 \leq i \leq I_k} (a_{ki}^\top x + b_{ki}) \right\}, \quad f(x) = \min_{1 \leq k \leq K} g_k(x). \quad (2.12)$$

Theo Mệnh đề 1.25, các hàm g_k và f là hàm PWL trên $\mathbb{R}^n$. Ta chứng minh hai khẳng định.

(a) $g_k(x) \geq 0$ với mọi x , và $g_k(x) = 0$ khi và chỉ khi $x \in \mathcal{B} \cap \Omega_k$. Thật vậy, $g_k(x) \geq |c_k^\top x + d_k| \geq 0$. Hơn nữa, $g_k(x) = 0$ khi và chỉ khi $|c_k^\top x + d_k| \leq 0$ và $a_{ki}^\top x + b_{ki} \leq 0$ với mọi i , tức là khi và chỉ khi $c_k^\top x + d_k = 0$ và $x \in \Omega_k$. Theo Định nghĩa 2.4(ii), điều đó tương đương với $x \in \mathcal{B} \cap \Omega_k$.

(b) $\{f = 0\} = \mathcal{B}$. Vì mọi g_k đều không âm nên $f(x) = 0$ khi và chỉ khi $g_k(x) = 0$ với ít nhất một k . Kết hợp với (a) và việc $\mathcal{B} \subseteq \Omega = \bigcup_k \Omega_k$, ta được

$$\{x : f(x) = 0\} = \bigcup_{k=1}^K (\mathcal{B} \cap \Omega_k) = \mathcal{B} \cap \Omega = \mathcal{B}. \quad \square$$

Nhận xét 2.7. Chứng minh trong [26] xét riêng hai chiều bao hàm và dùng thêm lập luận về phần trong của các vùng Ω_k để chỉ ra $g_k(x_0) \geq 0$ khi $k \neq k_0$. Nhận xét đơn giản $g_k \geq |c_k^\top x + d_k| \geq 0$ làm lập luận đó trở nên không cần thiết. Cũng từ chứng minh trên ta thấy điều kiện phần trong rời nhau của phân hoạch không được dùng đến; chỉ cần các vùng phủ Ω .

Nhận xét 2.8. Hàm f trong (2.12) không âm trên toàn $\mathbb{R}^n$, nên nó mô tả biên $\mathcal{B}$ nhưng không phân biệt được hai phía của biên: $\text{sign } f$ không phải là một bộ phân loại. Để phân loại, ta cần một hàm đổi dấu khi đi qua $\mathcal{B}$. Nếu $\Omega \setminus \mathcal{B}$ gồm hai phần ứng với hai lớp và mỗi điểm của $\mathcal{B}$ đều là điểm biên chung của hai phần đó, thì đổi dấu f trên phần ứng với lớp -1 ta được một hàm PWL liên tục, dương ở lớp $+1$, âm ở lớp -1 và có cùng tập không điểm $\mathcal{B}$. Trong PWL-SVM, hàm đổi dấu này không được xây dựng tường minh mà được tìm trực tiếp bằng một bài toán tối ưu; các định lý biểu diễn chỉ bảo đảm rằng họ hàm được tìm kiếm là đủ giàu.

Vì $|t| = \max\{t, -t\}$ và $\max\{t_1, \max\{t_2, t_3\}\} = \max\{t_1, t_2, t_3\}$, hàm f trong (2.12) viết được dưới dạng min–max

$$f(x) = \min_{1 \leq k \leq K} \max\{c_k^\top x + d_k, -c_k^\top x - d_k, a_{k1}^\top x + b_{k1}, \dots, a_{kI_k}^\top x + b_{kI_k}\}. \quad (2.13)$$

Từ dạng min–max, người ta có thể xây dựng bộ phân loại PWL bằng cách coi các hệ số c_k, d_k, a_{ki}, b_{ki} là ẩn và cực tiểu hóa một hàm mất mát trên dữ liệu. Tuy nhiên, bài toán thu được là không lồi và không trơn; trong thực nghiệm của phương pháp tách max–min, số vùng chỉ được xét đến $K \leq 5$ [5]. Để xác định tham số một cách hiệu quả và có khả năng tổng quát hóa tốt, Huang và cộng sự chuyển sang một dạng biểu diễn khác, tuyến tính theo tham số, dựa

trên Định lý 1.30.

Định lý 2.9 ([26], Định lý 2). *Với mọi tập tuyến tính từng phần $\mathcal{B} \subseteq \mathbb{R}^n$, tồn tại số nguyên dương D , các hệ số $w_1, \dots, w_D \in \mathbb{R}$ và các tham số $p_{mi} \in \mathbb{R}^n$, $q_{mi} \in \mathbb{R}$ ($m = 1, \dots, D$; $i = 0, \dots, n$) sao cho*

$$\mathcal{B} = \left\{ x : \sum_{m=1}^D w_m g_m(x) = 0 \right\}, \quad g_m(x) = \max_{0 \leq i \leq n} \{ p_{mi}^\top x + q_{mi} \}. \quad (2.14)$$

Chứng minh. Theo Định lý 2.6, $\mathcal{B} = \{f = 0\}$ với một hàm PWL f . Theo Định lý 1.30, $f = \sum_{m=1}^D \sigma_m \max\{\ell_{m,0}, \dots, \ell_{m,n}\}$ với $\sigma_m \in \{-1, 1\}$. Đặt $w_m = \sigma_m$ và gọi p_{mi}, q_{mi} là các hệ số của $\ell_{m,i}$, ta được (2.14). $\square$

Trong [26], định lý được suy ra qua một bước trung gian: biến dạng min–max (2.13) thành dạng max–min nhờ đẳng thức $\min_k \max_i t_{ik} = -\max_k \min_i (-t_{ik})$, rồi áp dụng kết quả của Wang và Sun cho dạng max–min. Hai cách lập luận là tương đương, vì theo Định lý 1.29, mọi hàm PWL đều có dạng max–min.

2.5. Ánh xạ đặc trưng tuyến tính từng phần và PWL-SVM

2.5.1. Từ định lý biểu diễn đến ánh xạ đặc trưng

Định lý 2.9 biểu diễn biên PWL như tập không điểm của một *tổ hợp tuyến tính* các hàm cơ sở g_m . Đó chính là dạng mà SVM có thể xử lý: nếu coi các g_m là đặc trưng, thì việc tìm các hệ số w_m là một bài toán phân loại tuyến tính. Trước khi làm điều đó, ta tách phần affine ra khỏi mỗi hàm cơ sở. Với mọi số thực $a_0, \dots, a_n$ ta có $\max_i a_i = a_0 + \max\{0, a_1 - a_0, \dots, a_n - a_0\}$. Áp dụng cho g_m , với $\tilde{p}_{mi} = p_{mi} - p_{m0}$ và $\tilde{q}_{mi} = q_{mi} - q_{m0}$:

$$g_m(x) = (p_{m0}^\top x + q_{m0}) + \max\{0, \tilde{p}_{m1}^\top x + \tilde{q}_{m1}, \dots, \tilde{p}_{mn}^\top x + \tilde{q}_{mn}\}.$$

Lấy tổng theo m , phần affine gộp lại thành $(\sum_m w_m p_{m0})^\top x + \sum_m w_m q_{m0}$, tức là một tổ hợp tuyến tính của các tọa độ $x(1), \dots, x(n)$ cộng với một hằng số. Hằng số này sẽ được hấp thụ vào hệ số chặn của SVM. Vì vậy, thay vì giữ

nguyên các g_m , ta dùng ánh xạ đặc trưng $\varphi : \mathbb{R}^n \rightarrow \mathbb{R}^M$ với $M = n + D$ thành phần

$$\varphi_m(x) = \begin{cases} x(m), & m = 1, \dots, n, \\ \max\{0, p_{m1}^\top x + q_{m1}, \dots, p_{mn}^\top x + q_{mn}\}, & m = n + 1, \dots, M, \end{cases} \quad (2.15)$$

trong đó, để đơn giản ký hiệu, ta viết lại $\tilde{p}, \tilde{q}$ thành p, q . Đây là ánh xạ (4) của bài báo gốc. Từ Định lý 2.9 ta suy ra ngay:

Hệ quả 2.10. *Với mọi tập tuyến tính từng phần $\mathcal{B} \subseteq \mathbb{R}^n$, tồn tại số đặc trưng M , các tham số p_{mi}, q_{mi} của ánh xạ (2.15) và các hệ số $w \in \mathbb{R}^M, w_0 \in \mathbb{R}$ sao cho $\mathcal{B} = \{x : w^\top \varphi(x) + w_0 = 0\}$.*

Ý nghĩa của hệ quả nằm ở chỗ: khi các tham số phi tuyến p_{mi}, q_{mi} đã được cố định, hàm quyết định $w^\top \varphi(x) + w_0$ là tuyến tính theo các ẩn (w, w_0) . Toàn bộ tính phi tuyến nằm trong φ , còn việc học là tuyến tính. Vì vậy ta có thể dùng nguyên vẹn SVM tuyến tính trong không gian đặc trưng $\mathbb{R}^M$, với mọi ưu điểm của nó: bài toán lồi, nghiệm toàn cục, lý thuyết lồi và các bộ giải hiệu quả.

2.5.2. PWL-C-SVM

Thay x_k bởi $\varphi(x_k)$ trong bài toán SVM lồi mềm (Mục 2.2), ta được bài toán gốc của PWL-C-SVM:

$$\min_{w, w_0, e} \quad \frac{1}{2} \sum_{m=1}^M w_m^2 + \gamma \sum_{k=1}^N e_k$$

với điều kiện $y_k \left(w_0 + \sum_{m=1}^M w_m \varphi_m(x_k) \right) \geq 1 - e_k, \quad e_k \geq 0, \quad k = 1, \dots, N.$

(2.16)

Để tránh nhầm với các tham số của ánh xạ, hệ số chặn được ký hiệu là w_0 . Lặp lại đúng các bước dẫn bài toán đối ngẫu ở Mục 2.2, ta được

$$\begin{aligned} \max_{\alpha} \quad & \sum_{k=1}^N \alpha_k - \frac{1}{2} \sum_{k=1}^N \sum_{l=1}^N y_k y_l \kappa(x_k, x_l) \alpha_k \alpha_l \\ \text{với điều kiện} \quad & \sum_{k=1}^N \alpha_k y_k = 0, \quad 0 \leq \alpha_k \leq \gamma, \quad k = 1, \dots, N, \end{aligned} \quad (2.17)$$

với hạt nhân hữu hạn hạng

$$\kappa(x, z) = \varphi(x)^\top \varphi(z) = \sum_{m=1}^M \varphi_m(x) \varphi_m(z). \quad (2.18)$$

Từ nghiệm đối ngẫu, ta khôi phục $w = \sum_k \alpha_k y_k \varphi(x_k)$ và dùng bộ phân loại dạng gốc

$$\hat{y}(x) = \text{sign}(w^\top \varphi(x) + w_0). \quad (2.19)$$

Bài toán gốc (2.16) có $M + N + 1$ biến, bài toán đối ngẫu (2.17) có N biến; vì vậy Huang và cộng sự đề nghị giải bài toán đối ngẫu rồi khôi phục w . Điểm khác biệt căn bản so với SVM hạt nhân Gauss nằm ở khâu *dự đoán*: vì φ là tường minh và hữu hạn chiều, bộ phân loại (2.19) chỉ cần lưu w , w_0 và các tham số của ánh xạ, không cần lưu các vectơ hỗ trợ. Bảng 2.2 so sánh chi phí lưu trữ và chi phí tính toán khi dự đoán một điểm mới.

Với dữ liệu Magic ($n = 10$), bài báo gốc cho biết SVM hạt nhân Gauss cần 1013 vectơ hỗ trợ, tức khoảng 1013×11 số thực, trong khi PWL-C-SVM với ánh xạ cộng tính chỉ cần khoảng 100 số, với độ chính xác gần như nhau (0,839 so với 0,837) [26]. Chương 3 sẽ đo lại các con số này bằng thực nghiệm của đề án.

Bảng 2.2. Số thực cần lưu và số phép tính khi dự đoán một điểm, không kể $2n$ số của phép chuẩn hóa dữ liệu mà mọi mô hình đều cần; $D = M - n$ là số đặc trưng bản lề (với dạng cộng tính, D cũng là số nút), N_s là số vectơ hỗ trợ.

Mô hình	Số thực cần lưu	Phép tính khi dự đoán
SVM tuyến tính	$n + 1$	n phép nhân–cộng
PWL-SVM cộng tính	$M + D + 1$	D phép trừ và D phép max; M phép nhân–cộng
PWL-SVM HH	$D(n + 1) + M + 1$	Dn phép nhân–cộng và D phép max; M phép nhân–cộng
PWL-SVM GHH	$Dn(n + 1) + M + 1$	Dn^2 phép nhân–cộng và Dn phép max; M phép nhân–cộng
SVM hạt nhân Gauss	$N_s(n + 1) + 1$	N_s khoảng cách ($\approx 2N_sn$ phép tính) và N_s hàm mũ

2.5.3. PWL-LS-SVM

Áp dụng LS-SVM (Mục 2.3) cho ánh xạ (2.15), ta được PWL-LS-SVM:

$$\min_{w, w_0, e} \quad \frac{1}{2} \sum_{m=1}^M w_m^2 + \frac{\gamma}{2} \sum_{k=1}^N e_k^2$$

với điều kiện $y_k \left(w_0 + \sum_{m=1}^M w_m \varphi_m(x_k) \right) = 1 - e_k, \quad k = 1, \dots, N.$

(2.20)

Theo Mục 2.3, bài toán đối ngẫu của (2.20) là hệ tuyến tính $(N + 1)$ ẩn

$$\begin{bmatrix} 0 & y^\top \\ y & \Theta + \gamma^{-1} I \end{bmatrix} \begin{bmatrix} w_0 \\ \alpha \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{1} \end{bmatrix}, \quad \Theta_{kl} = y_k y_l \kappa(x_k, x_l), \quad (2.21)$$

với hạt nhân hữu hạn hạng (2.18). Sau khi khử e , bài toán gốc có $M + 1$ ẩn, còn bài toán đối ngẫu có $N + 1$ ẩn; vì vậy dạng gốc có lợi hơn khi $M \leq N$ [26]. Mệnh đề sau cho thấy dạng gốc thực chất là một bài toán quen thuộc.

Mệnh đề 2.11. Với $y_k \in \{-1, 1\}$, bài toán (2.20) tương đương với bài toán hồi quy ridge trên nhãn ± 1 với hệ số chặn không bị phạt:

$$\min_{w, w_0} \quad \frac{1}{2} \|w\|^2 + \frac{\gamma}{2} \sum_{k=1}^N (y_k - w^\top \varphi(x_k) - w_0)^2. \quad (2.22)$$

Bài toán này có nghiệm duy nhất

$$w = (\Phi_c^\top \Phi_c + \gamma^{-1} I)^{-1} \Phi_c^\top y_c, \quad w_0 = \bar{y} - \bar{\varphi}^\top w,$$

trong đó $\bar{\varphi} = \frac{1}{N} \sum_k \varphi(x_k)$, $\bar{y} = \frac{1}{N} \sum_k y_k$, Φ_c là ma trận cỡ $N \times M$ có hàng thứ k là $(\varphi(x_k) - \bar{\varphi})^\top$ và y_c là vectơ có thành phần thứ k là $y_k - \bar{y}$.

Chứng minh. Khử $e_k = 1 - y_k(w^\top \varphi(x_k) + w_0)$ từ ràng buộc. Vì $y_k^2 = 1$,


$$e_k^2 = y_k^2 e_k^2 = (y_k - y_k^2(w^\top \varphi(x_k) + w_0))^2 = (y_k - w^\top \varphi(x_k) - w_0)^2,$$

nên (2.20) trở thành (2.22). Gọi $J(w, w_0)$ là hàm mục tiêu của (2.22). Với mọi $(u, v) \neq (0, 0)$, dạng toàn phương của ma trận Hessian bằng $\|u\|^2 + \gamma \sum_k (u^\top \varphi(x_k) + v)^2 > 0$, nên J lồi chặt và có không quá một điểm cực tiểu. Cho đạo hàm theo w_0 bằng 0 ta được $w_0 = \bar{y} - \bar{\varphi}^\top w$; khi đó $y_k - w^\top \varphi(x_k) - w_0 = (y_k - \bar{y}) - w^\top (\varphi(x_k) - \bar{\varphi})$ và J trở thành $\frac{1}{2} \|w\|^2 + \frac{\gamma}{2} \|y_c - \Phi_c w\|^2$. Cho gradient theo w bằng 0 ta được $(\Phi_c^\top \Phi_c + \gamma^{-1} I)w = \Phi_c^\top y_c$; ma trận vế trái xác định dương nên khả nghịch. $\square$

Như vậy, khi $M \ll N$, PWL-LS-SVM chỉ cần lập ma trận $\Phi_c^\top \Phi_c$ cỡ $M \times M$ (chi phí $O(NM^2)$) và giải một hệ M ẩn (chi phí $O(M^3)$), rẻ hơn nhiều so với hệ đối ngẫu cỡ $(N+1) \times (N+1)$. Mục 3.1 kiểm tra bằng số rằng hai cách giải cho cùng một nghiệm.

2.5.4. Một cách nhìn khác: PWL-SVM như một mạng nơ-ron hai lớp

Khi mỗi đặc trưng trong (2.15) chỉ dùng một siêu phẳng, ta có $\varphi_m(x) = \max\{0, p_m^\top x + q_m\}$, tức là $\varphi_m(x) = \text{ReLU}(p_m^\top x + q_m)$: đó chính là đầu ra của một nơ-ron ReLU; với dạng tổng quát, φ_m là một nơ-ron maxout có một mảnh bằng 0 [21]. Do đó bộ phân loại (2.19) là một mạng nơ-ron hai lớp (Hình 2.5): lớp ẩn gồm D nơ-ron với trọng số *cố định*, cộng thêm các kết nối tắt từ đầu vào đến đầu ra; chỉ lớp ra được huấn luyện, và được huấn luyện bằng nguyên lý cực đại lẻ. Quan hệ giữa ánh xạ đặc trưng của SVM và lớp ẩn của mạng nơ-ron đã được Suykens và Vandewalle chỉ ra từ sớm [43]. Cách nhìn này đặt



Hình 2.5. PWL-SVM với ánh xạ siêu phẳng bản lề nhìn như một mạng nơ-ron hai lớp: lớp ẩn gồm các nơ-ron ReLU với tham số cố định; các tọa độ $x(1), \dots, x(n)$ đi thẳng đến đầu ra (nét đứt); chỉ các trọng số của lớp ra được học, bằng bài toán lồi (2.16) hoặc (2.20).

PWL-SVM vào cùng họ với các mô hình có lớp ẩn ngẫu nhiên như máy học cực trị [25] và đặc trưng ngẫu nhiên [38], và làm rõ sự đánh đổi so với mạng ReLU huấn luyện bằng lan truyền ngược: cố định lớp ẩn giúp bài toán trở nên lồi, nhưng mỗi nơ-ron đóng góp ít hơn vì không được điều chỉnh theo dữ liệu.

2.6. Các dạng ánh xạ đặc trưng và cách chọn tham số

Khả năng phân loại của PWL-SVM phụ thuộc vào dạng cụ thể của các đặc trưng φ_m và vào cách chọn tham số của chúng. Mục này trình bày ba dạng ánh xạ được đề xuất trong [26], từ đơn giản đến tổng quát, và các quy tắc sinh tham số.

2.6.1. Ba dạng ánh xạ

Dạng cộng tính. Đơn giản nhất là cho mỗi đặc trưng chỉ phụ thuộc vào một tọa độ:

$$\varphi_m(x) = \max\{0, x(i_m) - q_m\}, \quad i_m \in \{1, \dots, n\}, \quad q_m \in \mathbb{R}. \quad (2.23)$$

Gộp các số hạng theo từng tọa độ, hàm quyết định có dạng $w_0 + \sum_{i=1}^n h_i(x(i))$, trong đó theo Mệnh đề 1.27, mỗi h_i là một hàm PWL một biến với các điểm

gãy là những q_m ứng với $i_m = i$. Đây là một *mô hình cộng tính* theo nghĩa của thống kê học [23]: ảnh hưởng của từng biến có thể vẽ ra và đọc được, một ưu điểm lớn về khả năng diễn giải. Đối lại, biên các vùng tuyến tính là các siêu phẳng song song với trục tọa độ (Hình 2.6a), và mô hình không biểu diễn được tương tác giữa các biến; Chương 3 sẽ chỉ ra một hệ quả cụ thể của hạn chế này (Mệnh đề 3.1).

Dạng siêu phẳng bản lề (HH). Cho phép hướng tùy ý:

$$\varphi_m(x) = \max\{0, p_m^\top x + q_m\}, \quad p_m \in \mathbb{R}^n, q_m \in \mathbb{R}. \quad (2.24)$$

Mỗi đặc trưng đổi trạng thái trên cả một siêu phẳng $p_m^\top x + q_m = 0$ cắt ngang miền, nên D đặc trưng chia miền thành các ô của một *sắp xếp siêu phẳng* (Hình 2.6b). Trên mỗi ô, mọi hàm $w^\top \varphi(x) + w_0$ đều affine, nên số ô là một thước đo độ linh hoạt của biên. Trong mặt phẳng, D đường thẳng ở vị trí tổng quát tạo ra đúng $1 + D + \binom{D}{2}$ ô: đường thẳng thứ j cắt $j - 1$ đường trước tại $j - 1$ điểm phân biệt nên bị chia thành j đoạn, mỗi đoạn tách một ô cũ làm hai. Với $D = 6$ như trong hình, ta được 22 ô, nhiều hơn hẳn 16 ô của dạng cộng tính với cùng số đặc trưng.


Dạng siêu phẳng bản lề tổng quát (GHH). Dùng đúng dạng của (2.15):

$$\varphi_m(x) = \max\{0, p_{m1}^\top x + q_{m1}, \dots, p_{mn}^\top x + q_{mn}\}. \quad (2.25)$$

Mỗi đặc trưng có $n + 1$ mảnh, và vùng tuyến tính của nó là các tập mà trên đó một mảnh xác định đạt cực đại (Hình 2.6c). Theo Hệ quả 2.10, đây là dạng đủ để biểu diễn mọi biên PWL; cái giá là số tham số của mỗi đặc trưng tăng gấp n lần so với dạng HH (Bảng 2.2).

2.6.2. Chọn tham số

Giống như tham số độ rộng của hạt nhân Gauss, các tham số phi tuyến của ánh xạ ảnh hưởng lớn đến kết quả nhưng khó tối ưu trực tiếp. Theo [26], ta



Hình 2.6. Phân vùng tuyến tính của hình vuông đơn vị do ba dạng ánh xạ sinh ra: (a) cộng tính với lưới 4×4 (6 đặc trưng bản lề); (b) HH với 6 siêu phẳng ngẫu nhiên; (c) GHH với 3 đặc trưng, mỗi đặc trưng có 2 siêu phẳng. Trên mỗi vùng, mọi hàm quyết định $w^\top \varphi(x) + w_0$ đều là hàm affine.

chọn chúng dựa trên ý nghĩa hình học: các tham số của ánh xạ quyết định cấu trúc của các vùng, còn siêu phẳng trong từng vùng do SVM xác định. Trước hết, mỗi thành phần của dữ liệu được chuẩn hóa về đoạn $[0, 1]$.

Với dạng cộng tính, các nút q_m được đặt đều trên mỗi trục: chia $[0, 1]$ thành S đoạn bằng nhau, ta được $S - 1$ nút trên mỗi trục và $M = Sn$ đặc trưng (kể cả n tọa độ). Bài báo gốc đề nghị $S = 10$, tức $M = 10n$ [26].

Nhận xét 2.12. Lưới đều ngầm giả định rằng dữ liệu trải tương đối đều trên mỗi trục. Với những biến lệch mạnh, chẳng hạn các số tiền trong dữ liệu tín dụng ở Mục 3.5, phần lớn dữ liệu dồn vào một hai đoạn đầu và các nút còn lại gần như vô dụng. Một lựa chọn tự nhiên là đặt nút tại các phân vị mẫu mức s/S , $s = 1, \dots, S - 1$, của từng biến, bỏ đi các nút trùng nhau ở những biến chỉ nhận ít giá trị. Mọi kết quả ở các mục trước vẫn giữ nguyên, vì các nút vẫn được cố định trước khi giải SVM.

Với dạng HH và GHH, các siêu phẳng được sinh ngẫu nhiên sao cho chắc chắn cắt qua miền dữ liệu. Để sinh một siêu phẳng $p^\top x + q = 0$, ta lấy n điểm $u_1, \dots, u_n$ theo phân phối đều trên $[0, 1]^n$, chọn $p(1) \in \{-1, 1\}$ với xác suất

bằng nhau, rồi giải hệ n phương trình

$$\sum_{i=2}^n p(i) u_j(i) + q = -p(1) u_j(1), \quad j = 1, \dots, n, \quad (2.26)$$

với n ẩn $p(2), \dots, p(n), q$. Hàng thứ j của ma trận hệ số trong (2.26) là $(u_j(2), \dots, u_j(n), 1)$. Ma trận này khả nghịch khi và chỉ khi các điểm $\tilde{u}_j = (u_j(2), \dots, u_j(n))$, $j = 1, \dots, n$, độc lập affine trong $\mathbb{R}^{n-1}$, điều xảy ra với xác suất 1 vì các điểm được lấy theo một phân phối liên tục. Siêu phẳng thu được đi qua n điểm của miền nên luôn cắt miền — điều mà các siêu phẳng có hệ số lấy ngẫu nhiên tùy ý không bảo đảm. Dấu của $p(1)$ quyết định nửa không gian nào là nơi bản lề hoạt động. Với GHH, mỗi đặc trưng dùng n siêu phẳng sinh độc lập theo cách này.

Nhận xét 2.13. Việc cố định $|p(1)| = 1$ làm cho độ lớn $\|p\|$ rất khác nhau giữa các đặc trưng: một siêu phẳng gần song song với trục $x(1)$ có $|p(2)|, \dots, |p(n)|$ lớn, nên đặc trưng tương ứng có biên độ lớn. Do số hạng chính quy $\frac{1}{2}\|w\|^2$ phạt mọi trọng số như nhau, đặc trưng có biên độ lớn thực chất bị phạt nhẹ hơn. Một lựa chọn khác là chuẩn hóa $\|p\|_2 = 1$; ảnh hưởng của lựa chọn này sẽ được kiểm tra ở Chương 3.

2.6.3. Hai ví dụ


Trở lại dữ liệu hai mặt trăng. Biết trước rằng biên cần đổi hướng khi $x(2)$ đi qua $\frac{1}{3}$ và $\frac{2}{3}$, ta dùng ánh xạ cộng tính với các nút chỉ đặt trên trục thứ hai:

$$\varphi_1(x) = x(1), \quad \varphi_2(x) = x(2), \quad \varphi_3(x) = \left(x(2) - \frac{1}{3}\right)_+, \quad \varphi_4(x) = \left(x(2) - \frac{2}{3}\right)_+.$$

Giải PWL-C-SVM (2.16) với $\gamma = 100$ trên dữ liệu của Hình 2.4, ta được hàm quyết định

$$f(x) = 7,98 - 8,76x(1) - 16,33x(2) + 29,03\left(x(2) - \frac{1}{3}\right)_+ - 30,06\left(x(2) - \frac{2}{3}\right)_+.$$

Trên mỗi dải Ω_k , các số hạng bản lề hoặc bằng 0 hoặc là hàm affine, nên f là affine và biên $\{f = 0\} \cap \Omega_k$ là một đoạn thẳng. Chẳng hạn trên Ω_2 chỉ



Hình 2.7. Cùng ánh xạ (2.27), ba vectơ trọng số ở Bảng 2.3 cho ba biên (nét liền) có hình dạng rất khác nhau. Nét đứt là bốn đường $\varphi_m(x) = 0$, $m = 3, \dots, 6$; vùng tô cam là $\{f \leq 0\}$. Ví dụ được dựng lại theo ý tưởng của Hình 2 trong [26].

φ_3 hoạt động và $f(x) = -1,69 - 8,76x(1) + 12,70x(2)$; đó là đường thẳng $c_2^\top x + d_2 = 0$ ở Hình 2.4b. Bộ phân loại dùng 32 vectơ hỗ trợ và phân loại đúng 599/600 điểm huấn luyện. Ở ví dụ này, vị trí các nút được chọn nhờ biết trước hình dạng của dữ liệu; với dữ liệu “hộp đen”, ta dùng lưới đều hoặc siêu phẳng ngẫu nhiên như trên.

Một ánh xạ ngẫu nhiên, nhiều biên khác nhau. Để thấy một ánh xạ cố định có thể sinh ra những biên đa dạng thế nào, xét ánh xạ HH trong $\mathbb{R}^2$ gồm $\varphi_1 = x(1)$, $\varphi_2 = x(2)$ và bốn đặc trưng bản lề được sinh theo quy trình (2.26):

$$\begin{aligned}\varphi_3(x) &= (x(1) + 0,567x(2) - 0,919)_+, \\ \varphi_4(x) &= (-x(1) - 3,676x(2) + 1,604)_+, \\ \varphi_5(x) &= (x(1) - 3,171x(2) - 0,089)_+, \\ \varphi_6(x) &= (-x(1) + 0,654x(2) + 0,074)_+.\end{aligned}\tag{2.27}$$

Hình 2.7 vẽ biên $\{x : w_0 + \sum_{m=1}^6 w_m \varphi_m(x) = 0\}$ với ba vectơ trọng số ở Bảng 2.3. Cùng một ánh xạ, chỉ thay đổi trọng số, ta được một biên lồi, một biên không lồi và một biên không liên thông. Nhiệm vụ của SVM là chọn ra, trong họ các biên đó, biên có lề lớn nhất trên dữ liệu.

Nhận xét 2.14. Biên ở Hình 2.7a lồi không phải do tình cờ. Khi mọi hệ số

Bảng 2.3. Ba vectơ trọng số dùng ở Hình 2.7.

	w_0	w_1	w_2	w_3	w_4	w_5	w_6
(a) biên lỗi	0,4	-3,0	1,6	2,9	0,5	1,1	1,9
(b) biên không lỗi	0,3	-1,1	2,3	-1,4	-3,0	1,3	1,1
(c) biên không liên thông	1,7	-2,3	1,6	-2,9	-1,6	2,2	-0,9

của các đặc trưng bản lề đều không âm, f là tổng của một hàm affine và các hàm lỗi, nên f lỗi và tập $\{x : f(x) \leq 0\}$ là tập lỗi. Vì vậy, thêm ràng buộc $w_m \geq 0$ với $m > n$ vào (2.16) là một cách đưa tri thức tiên nghiệm “một lớp nằm trong một tập lỗi” vào mô hình mà vẫn giữ bài toán lỗi, như đã được gợi ý trong [26, Mục 5]. Cần lưu ý rằng với f lỗi, tập lỗi là tập mức dưới $\{f \leq 0\}$ chứ không phải $\{f \geq 0\}$ như được viết trong [26]; vì vậy lớp được biết là nằm trong một tập lỗi phải được gán nhãn -1 .

2.7. Quan hệ với các bộ phân loại tuyến tính từng phần khác

Nhiều bộ phân loại quen thuộc cho biên tuyến tính từng phần. Theo Mục 3 của [26], mục này chỉ ra rằng biên của ba bộ phân loại như vậy là biên của một PWL-SVM với tham số thích hợp. Các kết quả khẳng định *khả năng biểu diễn* của họ PWL-SVM; chúng không nói rằng PWL-SVM với tham số sinh theo Mục 2.6 sẽ tìm được đúng các biên đó.

2.7.1. SVM hạt nhân giao

Hạt nhân giao $\kappa_{\cap}(x, z) = \sum_{i=1}^n \min\{x(i), z(i)\}$, xác định cho các vectơ có thành phần không âm, được dùng rộng rãi trong phân loại ảnh dựa trên lược đồ tần suất [33]. Theo (2.9), hàm quyết định của SVM với hạt nhân này (Ik-SVM) là $f(x) = \sum_k \alpha_k y_k \kappa_{\cap}(x, x_k) + w_0$.

Mệnh đề 2.15. *Hàm quyết định của Ik-SVM là một hàm cộng tính tuyến tính từng phần:*

$$f(x) = w_0 - \sum_{i=1}^n \sum_{k=1}^N \alpha_k y_k (x(i) - x_k(i))_+. \quad (2.28)$$

Do đó mọi Ik-SVM là một PWL-SVM với ánh xạ cộng tính (2.23), trong đó

các nút trên trục thứ i là các giá trị $x_k(i)$ của dữ liệu huấn luyện.

Chứng minh. Với mọi $a, b \in \mathbb{R}$ ta có $\min\{a, b\} = a - (a - b)_+$. Do đó

$$\sum_k \alpha_k y_k \kappa_{\cap}(x, x_k) = \sum_{i=1}^n x(i) \sum_{k=1}^N \alpha_k y_k - \sum_{i=1}^n \sum_{k=1}^N \alpha_k y_k (x(i) - x_k(i))_+,$$

và số hạng thứ nhất bằng 0 vì $\sum_k \alpha_k y_k = 0$ là một ràng buộc của bài toán đối ngẫu (2.7). $\square$

Như vậy l_k -SVM thừa hưởng cả ưu điểm lẫn hạn chế của mô hình cộng tính: dễ diễn giải, nhưng không biểu diễn được tương tác giữa các biến. Hệ quả của hạn chế này sẽ được quan sát ở Mục 3.2.

2.7.2. AdaBoost với bộ phân loại yếu tuyến tính

AdaBoost [19] kết hợp các bộ phân loại yếu thành

$$F(x) = \sum_{m=1}^D \eta_m \text{sign}(a_m^\top x + b_m), \quad \eta_m > 0,$$

và phân loại theo $\text{sign } F(x)$. Khi các bộ phân loại yếu là tuyến tính, biên của AdaBoost là tuyến tính từng phần, nhưng F không liên tục, nên biên không phải là tập không điểm của một hàm PWL liên tục. Huang và cộng sự thay hàm dấu bằng hàm xấp xỉ

$$s_\delta(t) = -1 + \frac{1}{\delta}(t + \delta)_+ - \frac{1}{\delta}(t - \delta)_+, \quad \delta > 0,$$

trùng với $\text{sign}(t)$ khi $|t| \geq \delta$ và tuyến tính trên đoạn $[-\delta, \delta]$.

Mệnh đề 2.16. Hàm $F_\delta(x) = \sum_m \eta_m s_\delta(a_m^\top x + b_m)$ là tổ hợp tuyến tính của một hằng số và các đặc trưng dạng siêu phẳng bản lề $(a_m^\top x + b_m \pm \delta)_+$, và $F_\delta(x) = F(x)$ với mọi x nằm ngoài hợp các dải $S_m(\delta) = \{x : |a_m^\top x + b_m| < \delta\}$. Do đó $\text{sign } F_\delta$ và $\text{sign } F$ chỉ có thể khác nhau trên $\bigcup_m S_m(\delta)$, tập mà bề rộng của mỗi dải, $2\delta/\|a_m\|$, dần tới 0 khi $\delta \rightarrow 0$.

Chứng minh. Khẳng định thứ nhất suy từ định nghĩa của s_δ . Nếu $x \notin \bigcup_m S_m(\delta)$ thì $|a_m^\top x + b_m| \geq \delta$ với mọi m , nên $s_\delta(a_m^\top x + b_m) = \text{sign}(a_m^\top x + b_m)$ và $F_\delta(x) = F(x)$. $\square$

Vậy PWL-SVM với ánh xạ HH xấp xỉ được biên của AdaBoost tuyến tính với độ chính xác tùy ý, theo nghĩa của Mệnh đề 2.16.

2.7.3. Phương pháp láng giềng gần nhất

Với $k = 1$, phương pháp láng giềng gần nhất [14] gán cho x nhãn của điểm huấn luyện gần x nhất. Đặt $d_\pm(x) = \min_{k: y_k = \pm 1} \|x - x_k\|^2$; điểm x được xếp vào lớp $+1$ nếu $d_+(x) < d_-(x)$, và biên là tập $\{x : d_+(x) = d_-(x)\}$ (Hình 2.8a).


Mệnh đề 2.17. *Giả sử các điểm huấn luyện đôi một khác nhau. Khi đó $g = d_+ - d_-$ là hàm PWL liên tục trên $\mathbb{R}^n$. Do đó biên của phương pháp một láng giềng gần nhất là tập không điểm của một hàm PWL, và theo Hệ quả 2.10 nó biểu diễn được bởi một PWL-SVM với ánh xạ (2.15).*

Chứng minh. Với mỗi cặp (k, l) gồm một điểm lớp $+1$ và một điểm lớp -1 , gọi R_{kl} là tập các x mà x_k là điểm gần nhất trong lớp $+1$ và x_l là điểm gần nhất trong lớp -1 . Bất đẳng thức $\|x - x_k\|^2 \leq \|x - x_{k'}\|^2$ tương đương với $2(x_{k'} - x_k)^\top x \leq \|x_{k'}\|^2 - \|x_k\|^2$, tuyến tính theo x ; vì vậy R_{kl} là một đa diện. Các tập R_{kl} phủ $\mathbb{R}^n$, và phần trong của chúng rời nhau vì các điểm huấn luyện khác nhau. Trên R_{kl} ,

$$g(x) = \|x - x_k\|^2 - \|x - x_l\|^2 = 2(x_l - x_k)^\top x + \|x_k\|^2 - \|x_l\|^2$$

là một hàm affine: các số hạng bậc hai triệt tiêu. Cuối cùng g liên tục vì d_+ và d_- liên tục. $\square$

Điều thú vị là d_+ và d_- là các hàm bậc hai từng phần, nhưng hiệu của chúng là tuyến tính từng phần. Hình 2.8 so sánh biên của 1-NN và của 1k-SVM trên cùng một bộ dữ liệu nhỏ: cả hai đều là đường gấp khúc, nhưng biên của



Hình 2.8. Biên quyết định (nét liền) của (a) phương pháp một láng giềng gần nhất và (b) SVM hạt nhân giao trên cùng 26 điểm dữ liệu. Cả hai biên đều tuyến tính từng phần.

Ik-SVM chỉ đổi hướng tại các đường thẳng song song với trục tọa độ đi qua các điểm dữ liệu, đúng như Mệnh đề 2.15 dự báo.

2.7.4. Ý nghĩa và giới hạn

Ba kết quả trên cho thấy họ các biên mà PWL-SVM biểu diễn được chứa biên của Ik-SVM (với ánh xạ cộng tính), của AdaBoost tuyến tính (với ánh xạ HH, theo nghĩa xấp xỉ) và của 1-NN (với ánh xạ tổng quát). Huang và cộng sự rút ra rằng PWL-SVM “ít nhất có thể đạt được” hiệu năng của các bộ phân loại này [26]. Nhận định đó cần được hiểu thận trọng. Các kết quả trên là về khả năng biểu diễn, với những tham số phi tuyến được chọn riêng cho từng trường hợp, chẳng hạn các nút tại mọi điểm dữ liệu; còn trong thực hành, PWL-SVM dùng tham số sinh theo quy tắc cố định ở Mục 2.6. Khoảng cách giữa khả năng biểu diễn và độ chính xác thực tế sẽ được đo bằng thực nghiệm ở Chương 3.

Tiểu kết Chương 2

Chương 2 đã trình bày SVM từ lẽ cứng đến lẽ mềm, thủ thuật hạt nhân và LS-SVM, rồi xây dựng PWL-SVM theo một chuỗi lập luận chặt chẽ: mọi biên tuyến tính từng phần là tập không điểm của một hàm PWL liên tục (Định lý 2.6); hàm đó là tổ hợp tuyến tính của các hàm bản lề tổng quát (Định lý 2.9); tách phần affine ra, ta được ánh xạ đặc trưng (2.15), và việc học biên quy về

một SVM tuyến tính trên $\varphi(x)$ (Hệ quả 2.10). Mô hình thu được giữ tính lõi của SVM, có hai dạng PWL-C-SVM và PWL-LS-SVM, trong đó dạng gốc của PWL-LS-SVM chính là hồi quy ridge (Mệnh đề 2.11). Ưu điểm dự kiến nằm ở khâu dự đoán: mô hình chỉ cần lưu w và tham số của ánh xạ (Bảng 2.2). Ba dạng ánh xạ cộng tính, HH và GHH đánh đổi giữa khả năng diễn giải, chi phí và độ linh hoạt; dạng cộng tính không biểu diễn được tương tác giữa các biến. Những câu hỏi còn để ngỏ — chọn dạng ánh xạ nào, bao nhiêu đặc trưng, và độ chính xác, chi phí so với SVM hạt nhân Gauss ra sao — được trả lời bằng thực nghiệm ở Chương 3.

CHƯƠNG 3

CÀI ĐẶT, THỰC NGHIỆM VÀ ỨNG DỤNG

Chương này kiểm nghiệm các kết quả lý thuyết của Chương 2 bằng thực nghiệm và trả lời bốn câu hỏi nghiên cứu nêu ở Mở đầu. Mục 3.1 mô tả phần cài đặt và các phép kiểm chứng số. Mục 3.2 dùng dữ liệu hai chiều để quan sát trực tiếp biên quyết định. Mục 3.3 tái hiện một thí nghiệm của bài báo gốc, so sánh ba biến thể PWL-SVM với sáu phương pháp khác trên mười bộ dữ liệu chuẩn và khảo sát ảnh hưởng của số đặc trưng cùng quy tắc chọn tham số. Mục 3.4 đo chi phí huấn luyện, dự đoán và bộ nhớ. Mục 3.5 áp dụng PWL-SVM vào bài toán dự báo vỡ nợ thẻ tín dụng: so sánh với thể điểm truyền thống và các mô hình phi tuyến, phân tích khả năng diễn giải, và bổ sung ràng buộc đơn điệu. Mục 3.6 tổng hợp và thảo luận các kết quả.

3.1. Cài đặt

Toàn bộ thực nghiệm được cài đặt bằng Python 3 với các thư viện NumPy [22], SciPy [51] và scikit-learn [36]. Mã nguồn gồm một mô-đun chính, `pwlsvm.py`, với hai lớp tuân theo giao diện `fit/predict` của scikit-learn; nhờ vậy có thể dùng trực tiếp các công cụ kiểm định chéo và tìm kiếm tham số của thư viện này.

- Lớp `PWLFeatures` sinh tham số và tính ánh xạ đặc trưng (2.15) cho ba dạng cộng tính, HH và GHH, theo đúng quy trình ở Mục 2.6. Ngoài quy tắc của bài báo gốc, lớp này có hai tùy chọn: đặt nút của dạng cộng tính theo phân vị (Nhận xét 2.12) và chuẩn hóa các siêu phẳng ngẫu nhiên về $\|p\|_2 = 1$ (Nhận xét 2.13).
- Lớp `PWLSVM` ghép ba bước: chuẩn hóa từng thành phần về $[0, 1]$ (giá trị nhỏ nhất, lớn nhất được học trên tập huấn luyện), tính $\varphi(x)$, và giải bài toán tuyến tính trên $\varphi(x)$. Với PWL-C-SVM có hai bộ giải. LIBSVM [11] giải đúng bài toán đối ngẫu (2.17) với hệ số chặn không

Thuật toán 3.1 Huấn luyện và dự đoán với PWL-SVM

Đầu vào: dữ liệu $\{(x_k, y_k)\}_{k=1}^N$; dạng ánh xạ (cộng tính, HH hoặc GHH); số đặc trưng trên mỗi chiều M/n ; hằng số γ

Đầu ra: trọng số $w \in \mathbb{R}^M$, hệ số chặn w_0 , tham số của ánh xạ và của phép chuẩn hóa

- 1: Chuẩn hóa từng thành phần của x_k về $[0, 1]$; lưu giá trị nhỏ nhất và lớn nhất
 - 2: **nếu** dạng cộng tính **thì**
 - 3: đặt $S = M/n$ và các nút $q = s/S$ ($s = 1, \dots, S - 1$), hoặc các phân vị mức s/S , trên mỗi trục
 - 4: **ngược lại**
 - 5: **với** $m = n + 1, \dots, M$ **thực hiện**
 - 6: sinh 1 siêu phẳng (HH) hoặc n siêu phẳng (GHH) theo (2.26)
 - 7: Lập ma trận $\Phi \in \mathbb{R}^{N \times M}$ có hàng thứ k là $\varphi(x_k)^\top$, theo (2.15)
 - 8: Giải (2.17) rồi tính $w = \sum_k \alpha_k y_k \varphi(x_k)$ (PWL-C-SVM), hoặc giải (2.22) (PWL-LS-SVM)
 - 9: **Dự đoán** điểm mới x : chuẩn hóa x bằng các giá trị đã lưu, trả về $\text{sign}(w^\top \varphi(x) + w_0)$
-

bị phạt; nó được dùng cho các thí nghiệm nhỏ ở Mục 3.2 và Mục 3.3.1. LIBLINEAR [17] giải bài toán trên đặc trưng tường minh bằng phương pháp hạ theo tọa độ trên bài toán đối ngẫu, nhanh hơn nhiều khi N hoặc γ lớn; hệ số chặn được đưa vào như trọng số của một đặc trưng hằng bằng 10 nên bị chính quy hóa nhẹ, với phạt tương đương $w_0^2/200$. LIBLINEAR được dùng cho mọi thí nghiệm còn lại. Với PWL-LS-SVM, dạng gốc được giải trực tiếp theo Mệnh đề 2.11.

Mô-đun thứ hai, `pwlsvm_monotone.py`, bổ sung ràng buộc đơn điệu cho PWL-LS-SVM cộng tính (Mục 3.5.5). Các phương pháp đối chứng — SVM tuyến tính, SVM và LS-SVM hạt nhân Gauss, SVM hạt nhân giao, kNN, mạng nơ-ron một lớp ẩn ReLU, và trong phần ứng dụng thêm hồi quy logistic, thể điểm logistic trên biến rời rạc hóa và tổ hợp cây tăng cường — được đặt trong cùng một khung, để mọi phương pháp dùng chung cách chuẩn hóa, cách chia dữ liệu và cách chọn tham số. Quy trình huấn luyện và dự đoán của PWL-SVM được tóm tắt trong Thuật toán 3.1.

Kiểm chứng tính đúng đắn. Trước khi dùng mã cho thực nghiệm, đề án kiểm tra bằng số hai hệ thức của Chương 2, trên dữ liệu hai mặt trăng ($N = 400$, $M = 20$, $\gamma = 10$) với cả ba dạng ánh xạ.

- (i) Với PWL-LS-SVM, nghiệm của dạng gốc (hồi quy ridge, Mệnh đề 2.11) và nghiệm của hệ đối ngẫu (2.21) phải trùng nhau. Sai khác lớn nhất giữa hai bộ tham số (w, w_0) là $7 \cdot 10^{-12}$; trên 400 điểm kiểm tra, giá trị hàm quyết định của hai lời giải sai khác không quá $2 \cdot 10^{-12}$. Hai cách giải cho cùng một nghiệm, chỉ khác nhau ở sai số làm tròn.
- (ii) Với PWL-C-SVM, khôi phục $w = \sum_k \alpha_k y_k \varphi(x_k)$ từ nghiệm đối ngẫu với hạt nhân hữu hạn hạng (2.18) cho vectơ trọng số trùng với vectơ thu được khi giải trực tiếp trên $\varphi(x)$ (sai khác dưới $2 \cdot 10^{-12}$); hai bộ phân loại dự đoán giống hệt nhau trên toàn bộ tập kiểm tra.

Ngoài ra, ví dụ hai mặt trăng ở Mục 2.6 tái hiện đúng hiện tượng mà bài báo gốc mô tả: bốn đặc trưng cộng tính cho một biên ba đoạn với các điểm gãy nằm trên hai đường $x(2) = \frac{1}{3}$ và $x(2) = \frac{2}{3}$.

3.2. Thực nghiệm minh họa trên dữ liệu hai chiều

Với dữ liệu hai chiều, ta nhìn được trực tiếp biên quyết định, nên đây là nơi thích hợp để kiểm tra các nhận định định tính ở Chương 2. Đề án dùng bốn bộ dữ liệu tổng hợp có độ khó tăng dần (Hình 3.1): hai mặt trăng (nhiều Gauss với độ lệch chuẩn 0,15), hai vòng tròn đồng tâm (tỉ số bán kính 0,5, nhiều 0,08), bàn cờ 4×4 với các điểm phân bố đều, và hai xoắn ốc lồng nhau (1,6 vòng, nhiều 0,06). Mỗi bộ gồm 1000 điểm, chia đôi thành 500 điểm huấn luyện và 500 điểm kiểm tra như trong bài báo gốc.

Năm phương pháp được so sánh: SVM tuyến tính; PWL-C-SVM với ánh xạ cộng tính ($M/n = 10$), HH ($M/n = 50$, tức 98 siêu phẳng) và GHH ($M/n = 25$, tức 48 đặc trưng với tổng cộng 96 siêu phẳng); và SVM hạt nhân Gauss. Hai cấu hình HH và GHH được chọn để có số siêu phẳng xấp xỉ nhau. Hằng số γ được chọn trong tập $\{2^{-3}, 2^{-1}, \dots, 2^{11}\}$ bằng kiểm định chéo 5 phần trên tập huấn luyện; với SVM hạt nhân Gauss, tham số $1/\sigma^2$ được chọn

Bảng 3.1. Độ chính xác trên tập kiểm tra (% , trung bình $\pm$ độ lệch chuẩn qua 10 lần lặp) trên dữ liệu hai chiều; in đậm là giá trị trung bình cao nhất mỗi hàng.

Dữ liệu	SVM tuyến tính	PWL cộng tính	PWL-HH	PWL-GHH	SVM-RBF
Hai mặt trăng	$87,3 \pm 2,0$	$98,8 \pm 0,7$	$98,7 \pm 0,7$	$98,6 \pm 0,8$	$98,9 \pm 0,6$
Hai vòng tròn	$52,7 \pm 3,5$	$99,9 \pm 0,1$	$99,8 \pm 0,2$	$99,8 \pm 0,2$	$99,8 \pm 0,2$
Bàn cờ 4×4	$50,0 \pm 2,4$	$55,5 \pm 3,4$	$90,6 \pm 2,2$	$85,7 \pm 2,5$	$94,8 \pm 1,2$
Hai xoắn ốc	$64,8 \pm 2,7$	$89,2 \pm 1,5$	$98,2 \pm 0,6$	$96,7 \pm 1,4$	$99,2 \pm 0,4$

đồng thời trong $\{2^{-3}, 2^{-1}, \dots, 2^9\}$. Toàn bộ quy trình được lặp lại 10 lần với dữ liệu và tham số ngẫu nhiên khác nhau; Bảng 3.1 báo cáo trung bình và độ lệch chuẩn.


Kết quả ở Bảng 3.1 và Hình 3.1 phù hợp với phân tích ở Mục 2.6. SVM tuyến tính thất bại trên cả bốn bộ; trên hai vòng tròn và bàn cờ, độ chính xác của nó xấp xỉ 50%, tức không hơn đoán ngẫu nhiên. Cả ba dạng PWL-SVM đều cải thiện rõ rệt, và trên hai mặt trăng, hai vòng tròn, chúng đạt độ chính xác ngang SVM hạt nhân Gauss, với sai khác nhỏ hơn độ lệch chuẩn.

Ánh xạ cộng tính cho kết quả gần như tuyệt đối trên hai vòng tròn (99,9%) nhưng gần như thất bại trên bàn cờ (55,5%). Nguyên nhân không nằm ở số đặc trưng mà ở cấu trúc của mô hình. Biên của hai vòng tròn là đường $x(1)^2 + x(2)^2 = r^2$, với vế trái là tổng của hai hàm một biến, nên một mô hình cộng tính xấp xỉ được dễ dàng. Ngược lại, mệnh đề sau cho thấy không mô hình cộng tính nào xử lý được cấu trúc kiểu bàn cờ.

Mệnh đề 3.1. Cho $a \neq b$ và $c \neq d$. Giả sử hai điểm (a, c) và (b, d) thuộc lớp $+1$, còn hai điểm (a, d) và (b, c) thuộc lớp -1 . Khi đó không tồn tại hai hàm $g_1, g_2 : \mathbb{R} \rightarrow \mathbb{R}$ nào sao cho hàm cộng tính $f(x) = g_1(x(1)) + g_2(x(2))$ phân loại đúng cả bốn điểm.

Chứng minh. Nếu có, thì $f(a, c) + f(b, d) > 0$ và $f(a, d) + f(b, c) < 0$. Nhưng cả hai tổng đều bằng $g_1(a) + g_1(b) + g_2(c) + g_2(d)$, mâu thuẫn. $\square$

Bàn cờ 4×4 chứa rất nhiều bộ bốn điểm như vậy, nên mọi bộ phân loại cộng tính, dù dùng bao nhiêu đặc trưng, đều mắc nhiều lỗi. Kết luận này áp dụng cả cho SVM hạt nhân giao, vì theo Mục 2.7 nó cũng là một mô hình



Hình 3.1. Biên quyết định của năm phương pháp trên bốn bộ dữ liệu hai chiều (lần lặp đầu tiên). Chấm xanh và dấu nhân cam là các điểm kiểm tra của hai lớp; con số ở góc là độ chính xác trên 500 điểm kiểm tra. Biên của PWL-SVM là các đường gấp khúc, biên của SVM hạt nhân Gauss là đường tròn.

cộng tính; điều đó giải thích vì sao trong bài báo gốc, SVM hạt nhân giao chỉ đạt 48,8% trên dữ liệu bàn cờ [26, Bảng 1].

Hai dạng HH và GHH, vốn dùng các siêu phẳng có hướng tùy ý, xử lý được cả bàn cờ lẫn xoắn ốc. Trên hai bộ khó này, chúng vẫn kém SVM hạt nhân Gauss vài điểm phần trăm (90,6% và 85,7% so với 94,8% trên bàn cờ), và biên của chúng gấp khúc thay vì trơn. Với cùng số siêu phẳng, GHH kém HH một chút: mỗi đặc trưng GHH linh hoạt hơn, nhưng số trọng số được học chỉ bằng một nửa (50 so với 100), trong khi các siêu phẳng ngẫu nhiên không được điều chỉnh theo dữ liệu. Nói cách khác, khả năng biểu diễn tổng quát của GHH (Hệ quả 2.10) không tự động chuyển thành độ chính xác khi tham số được sinh ngẫu nhiên.


Một nhận xét về quy trình thực nghiệm: trên bàn cờ, hằng số γ được chọn thường nằm ở đầu trên của lưới (2^9 hoặc 2^{11}), và thời gian chọn tham số của PWL-HH và PWL-GHH (khoảng 9 và 18 giây mỗi lần lặp) lớn hơn nhiều so với SVM hạt nhân Gauss (dưới 0,4 giây), vì LIBSVM hội tụ chậm khi γ lớn. Đây là lý do các thí nghiệm trên dữ liệu chuẩn ở Mục 3.3 dùng bộ giải LIBLINEAR.

3.3. Thực nghiệm trên dữ liệu chuẩn

3.3.1. Tái hiện thí nghiệm trên dữ liệu Cosexp

Bộ dữ liệu Cosexp của hộp công cụ SVM-KM [10] được bài báo gốc dùng để minh họa ảnh hưởng của số đặc trưng M . Các điểm được lấy đều trên miền $[0, 5] \times [-1, 1]$ và được gán nhãn theo dấu của $\cos(0,5 e^{0,7x(1)}) - x(2)$; biên thật là đường cong $x(2) = \cos(0,5 e^{0,7x(1)})$, dao động ngày càng nhanh khi $x(1)$ tăng (nét đứt ở Hình 3.2a,b). Theo đúng thiết lập của [26], ta dùng 500 điểm huấn luyện, 500 điểm kiểm tra và PWL-C-SVM với ánh xạ cộng tính, cho M chạy từ 2 đến 40. Khác với bài báo, mỗi cấu hình được lặp lại trên 10 bộ dữ liệu sinh độc lập, và ánh xạ HH được chạy song song để so sánh.

Hình 3.2 tái hiện đúng xu hướng mà bài báo gốc báo cáo. Với $M = 2$, bộ phân loại chỉ là tuyến tính và đạt $72,7 \pm 2,0\%$ (bài báo: 76,83% với một lần



Hình 3.2. Tái hiện thí nghiệm Cosexp (Hình 3 của [26]), 10 lần lặp. (a), (b) Biên của PWL-C-SVM cộng tính với $M = 12$ và $M = 40$ (nét liền) so với biên thật (nét đứt). (c) Độ chính xác trên tập kiểm tra theo M : đường là trung bình, dải màu là $\pm$ một độ lệch chuẩn; đường chấm là SVM hạt nhân Gauss. (d) Thời gian huấn luyện (trung vị) với γ đã chọn.

chạy). Khi M tăng, biên uốn theo đường cong thật ngày càng sát (Hình 3.2a,b); độ chính xác đạt 90,0% tại $M = 20 = 10n$ và ổn định quanh 94% từ $M = 24$, ngang với SVM hạt nhân Gauss ($94,2 \pm 0,9\%$). Ở M nhỏ, đường cong không đơn điệu: mỗi giá trị của M ứng với một lưới nút hoàn toàn khác, và độ chính xác phụ thuộc vào việc các nút có rơi gần những chỗ biên đổi hướng hay không. Thời gian huấn luyện tăng theo M nhưng vẫn dưới 0,1 giây (Hình 3.2d).

Đáng chú ý, trên dữ liệu này ánh xạ HH kém hẳn ánh xạ cộng tính ($89,1 \pm 1,4\%$ tại $M = 40$), dù về lý thuyết nó linh hoạt hơn. Lý do là nhân của Cosexp được xác định bởi hàm $\cos(0,5 e^{0,7x(1)}) - x(2)$, một hàm cộng tính: ánh xạ cộng tính khớp đúng cấu trúc đó, còn các siêu phẳng ngẫu nhiên của

HH phân tán khả năng biểu diễn vào những hướng không cần thiết. Kết hợp với Mục 3.2, ta rút ra một quy tắc thực hành: nên thử ánh xạ cộng tính trước, vì nó rẻ, dễ diễn giải và đủ tốt khi tương tác giữa các biến yếu; chỉ chuyển sang HH khi có dấu hiệu tương tác mạnh, như trên bàn cờ. Đây cũng là thứ tự mà bài báo gốc khuyến nghị [26, Mục 4].

3.3.2. Mười bộ dữ liệu chuẩn

Dữ liệu và giao thức. Đề án dùng mười bộ dữ liệu phân loại nhị phân (Bảng 3.2). Bảy bộ trong số đó có mặt trong Bảng 1 của bài báo gốc (Haberman, Transfusion, Pima, Breast, Magic, Parkinsons, Ionosphere); ba bộ còn lại (Banknote, Spambase, Sonar) được thêm vào để bao quát thêm các kích thước dữ liệu và số chiều khác nhau. Mỗi bộ được chia ngẫu nhiên có phân tầng thành hai nửa huấn luyện và kiểm tra, lặp lại 10 lần; với Magic, tập huấn luyện gồm 2.000 điểm như trong bài báo gốc, phần còn lại dùng để kiểm tra; với Spambase, do chi phí tính chỉnh các mô hình hạt nhân lớn, chỉ lặp lại 5 lần. Trên mỗi tập huấn luyện, tham số được chọn bằng kiểm định chéo 10 phần: $\gamma \in \{2^{-5}, 2^{-3}, \dots, 2^{11}\}$ cho mọi mô hình SVM, tham số $1/\sigma^2$ của hạt nhân Gauss trên lưới $\{2^{-15}, 2^{-13}, \dots, 2^3\}$ theo khuyến nghị của [24], và hệ số phạt L_2 của mạng nơ-ron trong $\{10^{-4}, 10^{-3}, \dots, 1\}$. Chín phương pháp được so sánh: SVM tuyến tính; SVM và LS-SVM hạt nhân Gauss; kNN với $k = 1$ như trong bài báo; l_k-SVM; mạng nơ-ron một lớp ẩn gồm $D = 9n$ nơ-ron ReLU, bằng đúng số đặc trưng bản lề của PWL-SVM dạng HH, được huấn luyện bằng L-BFGS [31]; và ba biến thể PWL-SVM với $M/n = 10$ theo đúng quy tắc của bài báo: PWL-C-SVM và PWL-LS-SVM với ánh xạ cộng tính lưới đều, và PWL-C-SVM với ánh xạ HH chuẩn hóa $|p(1)| = 1$.

Kết quả tổng quát. Bảng 3.3 cho độ chính xác trung bình và Hình 3.3 biểu diễn chênh lệch so với SVM hạt nhân Gauss; độ lệch chuẩn và kích thước mô hình được cho ở Phụ lục B. Ba phương pháp dẫn đầu về độ chính xác là LS-SVM hạt nhân Gauss, mạng nơ-ron và SVM hạt nhân Gauss, với hạng trung bình lần lượt 2,35, 3,00 và 3,15. PWL-C-SVM cộng tính đứng giữa bảng (hạng 5,35), trên SVM tuyến tính (6,55) và kNN (7,40).

Bảng 3.2. Mười bộ dữ liệu chuẩn, sắp theo số chiều n (sau khi bỏ các cột hằng). N là số mẫu, cột cuối là số mẫu huấn luyện/kiểm tra trong mỗi lần chia.

Tên	Nội dung	N	n	% lớp	Huấn luyện/ kiểm tra
				+1	
Haberman	sống sót sau phẫu thuật ung thư vú	306	3	26,5	153/153
Transfusion	hiển máu tình nguyện	748	4	23,8	374/374
Banknote	xác thực tiền giấy	1.372	4	44,5	686/686
Pima	bệnh tiểu đường	768	8	34,9	384/384
Breast	ung thư vú Wisconsin (bản gốc)	699	9	34,5	349/350
Magic	kính thiên văn tia gamma	19.020	10	35,2	2.000/17.020
Parkinsons	bệnh Parkinson (giọng nói)	195	22	75,4	97/98
Ionosphere	tín hiệu radar tầng điện li	351	33	64,1	175/176
Spambase	thư rác	4.601	57	39,4	2.300/2.301
Sonar	tín hiệu sonar (đá hay mìn)	208	60	53,4	104/104

Bức tranh rõ hơn khi tách các bộ dữ liệu thành hai nhóm. Ở nhóm thứ nhất gồm Haberman, Transfusion, Banknote, Pima và Breast, mọi phương pháp dựa trên SVM, kể cả SVM tuyến tính, chênh nhau không quá khoảng 1,5 điểm phần trăm: một biên tuyến tính đã gần như đủ tốt, và tính phi tuyến không đem lại lợi ích đáng kể. Ở nhóm thứ hai gồm Magic, Parkinsons, Ionosphere, Sonar, nơi SVM tuyến tính kém SVM hạt nhân Gauss từ 4 đến 9 điểm, PWL-C-SVM cộng tính thu hẹp đáng kể khoảng cách trên ba trong bốn bộ: nó cải thiện so với SVM tuyến tính 5,8 điểm trên Magic, 3,5 điểm trên Ionosphere và 5,0 điểm trên Sonar, nhưng vẫn kém SVM hạt nhân Gauss từ 0,7 đến 4,1 điểm. Magic là trường hợp đáng chú ý nhất: PWL-C-SVM đạt 84,8% so với 85,5% của SVM hạt nhân Gauss, trong khi mô hình chỉ gồm 211 số thực so với 7.694 số, nhỏ hơn khoảng 36 lần.


Kiểm định thống kê. Bảng 3.4 so sánh PWL-C-SVM cộng tính với từng phương pháp bằng kiểm định dấu hạng Wilcoxon trên mười cặp giá trị trung bình, theo khuyến nghị của Demšar [15]. Ở mức ý nghĩa 5%, PWL-C-SVM cộng tính kém SVM hạt nhân Gauss và LS-SVM hạt nhân Gauss một cách có ý nghĩa ($p = 0,014$ và $p = 0,008$). Nó cao hơn SVM tuyến tính trên bảy trong mười bộ, với chênh lệch trung bình 1,7 điểm, và khác biệt này có ý nghĩa

Bảng 3.3. Độ chính xác trung bình trên tập kiểm tra (%) qua 10 lần chia ngẫu nhiên (5 lần với Spambase). In đậm: giá trị cao nhất mỗi hàng. Dòng cuối là hạng trung bình trên mười bộ dữ liệu (1 là tốt nhất). Độ lệch chuẩn được cho ở Bảng PL.1 (Phụ lục B).

Dữ liệu	SVM tuyến tính	SVM- RBF	LS-SVM- RBF	kNN ($k = 1$)	lk- SVM	MLP- ReLU	PWL-C cộng tính	PWL-LS cộng tính	PWL-C HH
Haberman	72,5	73,3	73,4	65,7	72,0	72,4	73,2	72,6	73,5
Transfusion	76,5	77,6	77,7	68,4	76,7	78,6	76,3	77,4	76,3
Banknote	98,6	100,0	100,0	99,8	99,9	99,9	99,9	99,5	99,9
Pima	76,7	76,1	76,6	70,8	76,0	76,7	76,3	76,5	76,2
Breast	96,6	96,5	96,4	95,3	96,4	96,8	96,3	96,0	95,6
Magic	79,0	85,5	85,6	78,3	85,0	85,7	84,8	84,4	84,3
Parkinsons	85,4	89,9	91,4	93,7	89,4	90,6	86,2	89,3	85,5
Ionosphere	86,2	93,4	93,8	86,4	91,1	88,0	89,7	87,7	87,0
Spambase	93,0	93,6	93,4	88,8	94,6	93,9	93,4	92,6	82,1
Sonar	75,2	84,3	84,5	81,2	82,0	81,9	80,2	79,8	76,2
Hạng trung bình	6,55	3,15	2,35	7,40	4,60	3,00	5,35	6,00	6,60

thống kê ($p = 0,037$); khác biệt so với mạng nơ-ron và lk-SVM không có ý nghĩa thống kê. Với chỉ mười bộ dữ liệu, các kiểm định này có lực thấp, nên “không bác bỏ” không có nghĩa là “tương đương”.

Ánh xạ HH và quy tắc chọn tham số. PWL-C-SVM với ánh xạ HH có hạng trung bình thấp (6,60), và trên Spambase kết quả của nó rất bất ổn: ở lần chia đầu tiên, mô hình thất bại hoàn toàn (40,0%, thấp hơn cả tỉ lệ 60,6% của lớp đa số), trong khi ở bốn lần chia còn lại nó đạt từ 91,0% đến 93,7%. Nguyên nhân nằm ở quy tắc sinh tham số chứ không ở mô hình. Dữ liệu Spambase rất thưa: sau khi chuẩn hóa, gần 78% các giá trị bằng 0, và phần lớn dữ liệu nằm sát một đỉnh của hình hộp $[0, 1]$ ⁵⁷. Các siêu phẳng đi qua những điểm lấy đều trong hình hộp vì vậy thường không cắt qua vùng dữ liệu: ở mỗi lần chia, từ 18% đến 22% số đặc trưng bản lẻ bằng 0 trên mọi điểm huấn luyện, và từ 17% đến 22% luôn hoạt động, tức là chỉ tuyến tính trên dữ liệu. Nghiêm trọng hơn, việc cố định $|p(1)| = 1$ (Nhận xét 2.13) làm độ lớn của các đặc trưng phụ thuộc mạnh vào lần sinh ngẫu nhiên: giá trị lớn nhất của các đặc trưng trên tập huấn luyện dao động từ 423 đến $3,3 \cdot 10^5$ giữa các lần chia. Ở lần chia đầu tiên, một siêu phẳng gần song song với trục $x(1)$ có hệ số lên tới $5,3 \cdot 10^4$,



Hình 3.3. Chênh lệch độ chính xác trung bình so với SVM hạt nhân Gauss (điểm phần trăm; giá trị âm nghĩa là kém hơn) của bốn phương pháp trên mười bộ dữ liệu.

khuyến bài toán tối ưu bị điều kiện hóa rất kém và bộ giải LIBLINEAR không hội tụ tới một nghiệm có ý nghĩa. Chỉ cần chuẩn hóa $\|p\|_2 = 1$, các đặc trưng trên dữ liệu huấn luyện không vượt quá 2,0 ở mọi lần chia, và với cùng giao thức, PWL-C-SVM HH đạt $93,4 \pm 0,2\%$ trên Spambase. Nhìn chung, mạng nơ-ron với cùng số nơ-ron ẩn tốt hơn PWL-C-SVM HH trên tám trong mười bộ: học lớp ẩn từ dữ liệu có lợi hơn nhiều so với sinh nó ngẫu nhiên, và đó là cái giá của tính lười đã được nêu ở Mục 2.5.

So với bài báo gốc. Kết quả trên không xác nhận nhận định của bài báo gốc rằng PWL-SVM có độ chính xác tương đương SVM hạt nhân Gauss [26]. Nguyên nhân chính là bài báo chỉ dùng một lần chia dữ liệu: trên các bộ nhỏ như Parkinsons, với 98 điểm kiểm tra, độ lệch chuẩn giữa các lần chia lên tới 2–4 điểm phần trăm, nên một lần chia có thể cho kết quả rất lạc quan; bài báo báo cáo độ chính xác 100% cho PWL-C-SVM trên bộ này, trong khi trung bình qua mười lần chia là 86,2%. Mặt khác, lợi thế về kích thước mô hình

Bảng 3.4. So sánh theo cặp giữa PWL-C-SVM cộng tính và từng phương pháp khác trên mười bộ dữ liệu: số bộ mà PWL-C-SVM cao hơn / bằng / thấp hơn (theo độ chính xác trung bình làm tròn đến 0,1 điểm phần trăm), chênh lệch trung bình, và giá trị p của kiểm định dấu hạng Wilcoxon hai phía.


Phương pháp so sánh	Cao hơn / bằng / thấp hơn	Chênh lệch TB	p
SVM tuyến tính	7 / 0 / 3	+1,66	0,037
SVM-RBF	1 / 0 / 9	-1,39	0,014
LS-SVM-RBF	0 / 1 / 9	-1,65	0,008
kNN ($k = 1$)	8 / 0 / 2	+2,79	0,105
lk-SVM	2 / 1 / 7	-0,68	0,110
MLP-ReLU	2 / 1 / 7	-0,82	0,154
PWL-LS-SVM cộng tính	7 / 0 / 3	+0,05	0,432
PWL-C-SVM HH	7 / 2 / 1	+1,97	0,025

được xác nhận rõ ràng: với ánh xạ cộng tính, PWL-C-SVM cần từ 64 đến 1.261 số thực, nhỏ hơn SVM hạt nhân Gauss từ 2,5 đến 36 lần trên cả mười bộ dữ liệu (Phụ lục B).

3.3.3. Ảnh hưởng của số đặc trưng và của quy tắc chọn tham số

Để trả lời câu hỏi CH3 một cách có kiểm soát, ta cố định mô hình là PWL-LS-SVM, giải chính xác bằng hồi quy ridge (Mệnh đề 2.11) để loại trừ ảnh hưởng của bộ giải, và thay đổi hai yếu tố: số đặc trưng trên mỗi chiều $M/n \in \{1, 2, 3, 5, 10, 20\}$ và quy tắc chọn tham số. Bốn quy tắc được so sánh: ánh xạ cộng tính với lưới đều (quy tắc của bài báo gốc) và với lưới phân vị (Nhận xét 2.12); ánh xạ HH với $|p(1)| = 1$ (quy tắc của bài báo gốc) và với $\|p\|_2 = 1$ (Nhận xét 2.13). Thí nghiệm được thực hiện trên ba bộ dữ liệu có đặc điểm khác nhau — Ionosphere ($n = 33$), Magic ($n = 10$, nhiều dữ liệu) và Spambase ($n = 57$, rất thưa) — với 5 lần chia như ở Mục 3.3.2 và γ chọn bằng kiểm định chéo 5 phần. Kết quả được vẽ ở Hình 3.4.

Có bốn nhận xét. Thứ nhất, độ chính xác tăng nhanh khi M/n tăng từ 1 (bộ phân loại tuyến tính) và bão hòa quanh $M/n = 5-10$, phù hợp với quy tắc $M = 10n$ của bài báo gốc; tăng tiếp lên $M/n = 20$ hầu như không có lợi. Thứ hai, đặt nút theo phân vị cho kết quả tốt hơn hoặc ngang lưới đều trên cả ba bộ dữ liệu, và khác biệt rõ nhất trên những dữ liệu có phân bố lệch: trên Magic,



Hình 3.4. Độ chính xác trung bình (qua 5 lần chia) của PWL-LS-SVM theo số đặc trưng trên mỗi chiều M/n , với bốn quy tắc chọn tham số. $M/n = 1$ ứng với bộ phân loại tuyến tính.

lưới phân vị đạt 84,2% ngay với $M/n = 2$, trong khi lưới đều cần $M/n = 10$ để đạt 84,3%; trên Spambase, lưới phân vị đạt 93,9% so với 92,6% của lưới đều ở $M/n = 10$, đồng thời chỉ dùng 156 đặc trưng thay vì 570, vì các nút trùng nhau của những biến gần như luôn bằng 0 bị loại bỏ. Thứ ba, ánh xạ HH cần nhiều đặc trưng hơn hẳn mới đạt tới độ chính xác của ánh xạ cộng tính: trên Magic, nó chỉ đuổi kịp lưới phân vị khi $M/n \geq 10$ (và nhỉnh hơn 0,4 điểm ở $M/n = 20$), còn trên Spambase nó kém ở mọi giá trị của M/n ; chỉ trên Ionosphere, nơi tương tác giữa các biến có vai trò, HH với $\|p\|_2 = 1$ đạt kết quả tốt nhất (90,0% ở $M/n = 10$). Thứ tư, chuẩn hóa $\|p\|_2 = 1$ không bao giờ làm kết quả xấu đi đáng kể và cải thiện rõ trên Ionosphere (90,0% so với 86,9% ở $M/n = 10$); kết hợp với sự cố của LIBLINEAR trên Spambase, đây là một lý do mạnh để thay quy tắc $|p(1)| = 1$ bằng $\|p\|_2 = 1$.

Từ đó rút ra một quy trình thực hành cho dữ liệu dạng bảng: bắt đầu với ánh xạ cộng tính, nút theo phân vị và M/n khoảng 5 đến 10; chỉ dùng ánh xạ HH, với các siêu phẳng được chuẩn hóa, khi có dấu hiệu tương tác mạnh giữa các biến. Quy trình này được áp dụng cho bài toán tín dụng ở Mục 3.5.

3.4. Chi phí tính toán và bộ nhớ

Mục 2.5 dự báo rằng lợi thế của PWL-SVM nằm ở khâu dự đoán: mô hình chỉ gồm w , w_0 và tham số của ánh xạ, và việc dự đoán chỉ gồm các phép so sánh, nhân, cộng và lấy cực đại (Bảng 2.2). Mục này kiểm tra dự báo đó trên hai bộ dữ liệu lớn hơn: Magic với 9.510 mẫu huấn luyện (chia đôi toàn bộ dữ liệu) và dữ liệu tín dụng sẽ được mô tả ở Mục 3.5, với 21.000 mẫu huấn luyện. Để phép đo công bằng, mọi mô hình chạy trên một luồng xử lý của cùng một máy tính, khi không có tiến trình nặng nào khác; tham số được chọn trước bằng kiểm định chéo trên một mẫu con 4.000 điểm, và chỉ thời gian của một lần huấn luyện với tham số đã chọn được đo. Thời gian dự đoán là trung vị của bảy lần dự đoán toàn bộ tập kiểm tra, chia cho số mẫu. PWL-SVM dùng ánh xạ cộng tính với nút phân vị và $M/n = 10$, theo quy trình rút ra ở Mục 3.3.3; thể điểm là hồi quy logistic trên các biến rời rạc hóa, như ở Mục 3.5.


Dự đoán và bộ nhớ. Kết quả ở Bảng 3.5 và Hình 3.5 xác nhận dự báo lý thuyết. PWL-LS-SVM cộng tính dự đoán mỗi mẫu trong $0,33 \mu s$ trên Magic và $0,56 \mu s$ trên dữ liệu tín dụng, nhanh hơn SVM hạt nhân Gauss khoảng 200 và 430 lần. Chênh lệch đến từ cấu trúc của mô hình: trên dữ liệu tín dụng, SVM hạt nhân Gauss lưu 239.111 số thực, ứng với khoảng 8.854 vectơ hỗ trợ, và mỗi lần dự đoán phải tính chừng ấy khoảng cách cùng hàm mũ; còn PWL-SVM cộng tính chỉ lưu 349 số và thực hiện vài trăm phép so sánh, nhân và cộng, đúng như các công thức ở Bảng 2.2. Trên dữ liệu tín dụng, mạng nơ-ron dự đoán nhanh ngang PWL-SVM cộng tính, còn tổ hợp cây tăng cường chậm hơn khoảng 2,5 lần; cả hai mô hình cũng lớn hơn nhiều, với 6.605 và khoảng 4.514 số thực. Thể điểm có kích thước tương đương PWL-SVM cộng tính (379 so với 349 số thực), và trong cài đặt dựa trên scikit-learn, nó dự đoán chậm hơn PWL-SVM khoảng 2,6 lần. Chỉ các mô hình tuyến tính trên biến gốc là nhỏ và nhanh hơn PWL-SVM, với cái giá là độ chính xác thấp hơn rõ rệt: trên Magic, hồi quy logistic đạt 78,7% so với 84,8% của PWL-LS-SVM cộng tính.

Bảng 3.5. Chi phí trên Magic (9.510 mẫu huấn luyện) và dữ liệu tín dụng (21.000 mẫu huấn luyện), đo trên một luồng xử lý: thời gian huấn luyện một mô hình với tham số đã chọn, thời gian dự đoán mỗi mẫu, số thực cần lưu, và độ chính xác (Magic) hoặc AUC (tín dụng) trên tập kiểm tra. Đây là một lần chia riêng, với tham số chọn trên mẫu con (và với Magic, tập huấn luyện lớn hơn nhiều), nên độ chính xác khác với ở Bảng 3.3 và 3.7.

Mô hình	Magic				Tín dụng			
	Huấn luyện (s)	Dự đoán (μ s/mẫu)	Số thực	ĐCX (%)	Huấn luyện (s)	Dự đoán (μ s/mẫu)	Số thực	AUC
SVM tuyến tính	5,2	0,02	31	78,7	9,3	0,06	79	0,694
Hồi quy logistic	0,00	0,02	31	78,7	0,02	0,05	79	0,716
Thẻ điểm	0,02	0,69	191	84,6	0,07	1,4	379	0,768
PWL-C-SVM, cộng tính	4,7	0,33	211	85,7	52	0,58	349	0,685
PWL-LS-SVM, cộng tính	0,01	0,33	211	84,8	0,04	0,56	349	0,768
PWL-LS-SVM, HH	0,01	0,40	1.111	85,1	0,07	1,3	6.631	0,740
SVM-RBF	0,76	64,7	34.462	87,1	4,6	241	239.111	0,711
MLP-ReLU	2,9	0,18	1.101	86,5	21	0,57	6.605	0,761
Tổ hợp cây tăng cường	0,11	3,8	12.200	88,1	0,15	1,4	4.514	0,774

Huấn luyện. PWL-LS-SVM là mô hình phi tuyến huấn luyện nhanh nhất: 0,01 giây trên Magic và 0,04 giây trên dữ liệu tín dụng, vì chỉ cần lập và giải một hệ tuyến tính cỡ $M \times M$ (Mệnh đề 2.11). PWL-C-SVM chậm hơn (4,7 và 52 giây) vì bộ giải lập của LIBLINEAR cần nhiều vòng để hội tụ. SVM hạt nhân Gauss cần 0,76 và 4,6 giây, và chi phí này tăng nhanh hơn tuyến tính theo số mẫu [11]; mạng nơ-ron cần 2,9 và 21 giây. Trong một quy trình thực tế, nơi mô hình phải được huấn luyện lại nhiều lần để chọn tham số, khác biệt này còn được nhân lên theo kích thước lưới tham số.

Cần lưu ý rằng số đo tuyệt đối phụ thuộc vào cài đặt: PWL-SVM được cài bằng NumPy, còn LIBSVM là thư viện C đã được tối ưu nhiều năm. Trên một thiết bị nhúng, số phép tính và số thực cần lưu ở Bảng 2.2 mới là thước đo phù hợp, và ở cả hai thước đo đó, PWL-SVM cộng tính có lợi thế lớn so với SVM hạt nhân Gauss.



Hình 3.5. Độ chính xác (Magic) hoặc AUC (dữ liệu tín dụng) theo thời gian dự đoán mỗi mẫu, trên thang logarit. Ô vuông là các biến thể PWL-SVM; điểm tròn là các phương pháp khác.

3.5. Ứng dụng: dự báo vỡ nợ thẻ tín dụng

3.5.1. Bài toán và dữ liệu

Ngân hàng phát hành thẻ tín dụng cần ước lượng khả năng một khách hàng không thanh toán được dư nợ trong kỳ tới, để điều chỉnh hạn mức, ưu tiên nhắc nợ hoặc trích lập dự phòng rủi ro. Đây là một bài toán phân loại nhị phân điển hình của chấm điểm tín dụng [48], và cả ba yêu cầu nêu ở Mở đầu đều có mặt: độ chính xác quyết định trực tiếp chi phí rủi ro; số hồ sơ lớn và việc chấm điểm được lặp lại định kỳ, nên chi phí dự đoán đáng kể; và tổ chức tín dụng cần giải thích được quyết định của mình với khách hàng cũng như với cơ quan quản lý.


Đề án dùng dữ liệu của Yeh và Lien [54] về 30.000 chủ thẻ tín dụng của một ngân hàng ở Đài Loan, trong giai đoạn từ tháng 4 đến tháng 9 năm 2005. Nhận cho biết khách hàng có vỡ nợ trong tháng tiếp theo hay không; có 6.636 khách hàng vỡ nợ, tức 22,1%. Hai mươi ba biến giải thích thuộc bốn nhóm: hạn mức tín dụng, thông tin nhân khẩu học, lịch sử trả nợ sáu tháng gần nhất

Bảng 3.6. Các biến của dữ liệu vỡ nợ thẻ tín dụng [54] và cách xử lý trong đề án. Số tiền tính bằng Đài tệ.

Biến	Ý nghĩa	Xử lý
LIMIT_BAL	hạn mức tín dụng của khách hàng và gia đình	giữ nguyên
SEX	giới tính (1 nam, 2 nữ)	một biến chỉ báo “nữ”
EDUCATION	học vấn (1 sau đại học, 2 đại học, 3 trung học, 4 khác)	ba biến chỉ báo; các mã 0, 5, 6 không được mô tả, gộp vào “khác”
MARRIAGE	hôn nhân (1 đã kết hôn, 2 độc thân, 3 khác)	hai biến chỉ báo; mã 0 gộp vào “khác”
AGE	tuổi	giữ nguyên
PAY_0, PAY_2, ..., PAY_6	trạng thái trả nợ các tháng 9, 8, ..., 4: -1 trả đúng hạn, $k \geq 1$ chậm k tháng; các mã -2 và 0 cũng xuất hiện	giữ nguyên như biến thứ bậc
BILL_AMT1, ..., BILL_AMT6	dư nợ sao kê các tháng 9, ..., 4	giữ nguyên
PAY_AMT1, ..., PAY_AMT6	số tiền đã thanh toán các tháng 9, ..., 4	giữ nguyên

và các số tiền sao kê, thanh toán tương ứng (Bảng 3.6).

Sau khi mã hóa các biến định danh, mỗi khách hàng được mô tả bởi $n = 26$ đặc trưng số. Hai đặc điểm của dữ liệu quyết định thiết kế mô hình (Hình 3.6). Thứ nhất, quan hệ giữa lịch sử trả nợ và rủi ro là phi tuyến rõ rệt: tỉ lệ vỡ nợ gần như không đổi, khoảng 13–17%, với các trạng thái -2, -1 và 0, rồi tăng vọt lên 34% khi chậm một tháng và gần 70% khi chậm hai tháng. Một mô hình tuyến tính theo PAY_0 không thể mô tả bước nhảy này, trong khi một hàm tuyến tính từng phần với vài điểm gãy thì có thể. Thứ hai, các biến tiền tệ lệch rất mạnh: hạn mức trả từ 10 nghìn đến 1 triệu Đài tệ, nhưng một nửa số khách hàng có hạn mức không vượt quá 140 nghìn. Lưới nút đều của bài báo gốc vì vậy đặt phần lớn các nút ở vùng gần như không có dữ liệu, còn lưới theo phân vị (Nhận xét 2.12) đặt nút theo mật độ dữ liệu.



Hình 3.6. (a) Tỷ lệ vỡ nợ theo trạng thái trả nợ tháng 9 (PAY_0); cột nhạt ứng với các nhóm có ít hơn 100 khách hàng. (b) Phân bố hạn mức tín dụng cùng vị trí 9 nút của lưới đều (nét đứt) và của lưới theo phân vị (nét liền).

3.5.2. Thiết kế thực nghiệm

Dữ liệu được chia ngẫu nhiên có phân tầng theo tỷ lệ 70/30, thành 21.000 khách hàng huấn luyện và 9.000 khách hàng kiểm tra, lặp lại 5 lần. Độ đo chính là diện tích dưới đường cong ROC (AUC) [18]: xác suất để một khách hàng vỡ nợ chọn ngẫu nhiên được mô hình chấm điểm rủi ro cao hơn một khách hàng không vỡ nợ chọn ngẫu nhiên. AUC không phụ thuộc vào ngưỡng quyết định và là độ đo chuẩn trong chấm điểm tín dụng [29]. Để đánh giá thêm chất lượng phân loại, đề án chọn một ngưỡng trên tập huấn luyện sao cho tỷ lệ khách hàng bị dự báo vỡ nợ bằng tỷ lệ vỡ nợ quan sát được, rồi tính độ chính xác cân bằng (trung bình của độ nhạy và độ đặc hiệu) và độ đo F1 của lớp vỡ nợ trên tập kiểm tra. Quy tắc chọn ngưỡng này tương ứng với chính sách “đưa vào diện theo dõi một tỷ lệ khách hàng cố định”.

Mười mô hình được so sánh. Ba mô hình tuyến tính đóng vai trò chuẩn so sánh của ngành: hồi quy logistic trên các biến gốc, SVM tuyến tính, và *thẻ điểm* — hồi quy logistic trên các biến đã được rời rạc hóa, theo cách xây dựng thẻ điểm truyền thống [48], trong đó mỗi biến liên tục được chia thành mười khoảng theo thập phân vị và mỗi giá trị của các biến PAY là một hạng

mục riêng. Bốn biến thể PWL-SVM được thử: PWL-LS-SVM cộng tính với lưới đều (quy tắc của bài báo gốc) và với lưới phân vị, PWL-C-SVM cộng tính với lưới phân vị, và PWL-LS-SVM với ánh xạ HH; mọi biến thể dùng $M/n = 10$. Ba mô hình phi tuyến làm đối chứng: SVM hạt nhân Gauss, mạng nơ-ron một lớp ẩn với $9n = 234$ nơ-ron ReLU, huấn luyện bằng L-BFGS [31], và tổ hợp cây tăng cường [20] với thiết lập mặc định của scikit-learn, là một đại diện cho nhóm mô hình thường chính xác nhất trên dữ liệu dạng bảng [29]. Tham số của mỗi mô hình được chọn bằng kiểm định chéo 5 phần trên tập huấn luyện với tiêu chí AUC; riêng SVM hạt nhân Gauss và mạng nơ-ron được tinh chỉnh trên một mẫu con phân tầng gồm 5.000 và 7.000 khách hàng với kiểm định chéo 3 phần, rồi huấn luyện lại trên toàn bộ tập huấn luyện, vì chi phí huấn luyện của chúng lớn hơn nhiều. Các lưới tham số là: $\gamma \in \{2^{-9}, 2^{-7}, \dots, 2^7\}$ cho SVM tuyến tính và mọi biến thể PWL-SVM; $\gamma \in \{2^{-2}, 2^0, 2^2, 2^4\}$ và $1/\sigma^2 \in \{2^{-7}, 2^{-5}, 2^{-3}, 2^{-1}\}$ cho SVM hạt nhân Gauss; hệ số phạt L_2 trong $\{10^{-2}, 10^{-1}, 1, 10\}$ cho mạng nơ-ron; nghịch đảo của hệ số phạt trong $\{10^{-3}, 10^{-2}, \dots, 10\}$ cho hồi quy logistic và thể điểm. Tổ hợp cây tăng cường dùng thiết lập mặc định, có cơ chế dừng sớm trên một phần dữ liệu kiểm định nội bộ.

3.5.3. Kết quả


Bảng 3.7 và Hình 3.7 cho thấy các mô hình chia thành hai nhóm rõ rệt. Nhóm dẫn đầu gồm tổ hợp cây tăng cường (AUC trung bình 0,779), PWL-LS-SVM cộng tính với nút phân vị (0,776), thể điểm logistic trên các biến đã rời rạc hóa (0,773) và PWL-LS-SVM cộng tính với lưới đều (0,772). Nhóm còn lại gồm hồi quy logistic trên các biến gốc (0,724), SVM tuyến tính (0,706) và SVM hạt nhân Gauss (0,716); mạng nơ-ron (0,768) đứng giữa hai nhóm. Như vậy, AUC của PWL-LS-SVM cộng tính với nút phân vị chỉ kém tổ hợp cây tăng cường một chút. Độ chính xác cân bằng và độ đo F1 ở ngưỡng đã chọn dẫn tới cùng kết luận: bốn mô hình của nhóm dẫn đầu gần như ngang nhau và cao hơn rõ rệt hồi quy logistic, SVM tuyến tính và SVM hạt nhân Gauss. Kết quả rất ổn định giữa các lần chia: độ lệch chuẩn của AUC chỉ khoảng 0,006.

Bảng 3.7. Kết quả trên dữ liệu vỡ nợ thẻ tín dụng (trung bình $\pm$ độ lệch chuẩn qua 5 lần chia 70/30). AUC: diện tích dưới đường ROC; ĐCX-CB: độ chính xác cân bằng; F1 tính cho lớp vỡ nợ; ngưỡng được chọn trên tập huấn luyện sao cho tỉ lệ dự báo vỡ nợ bằng tỉ lệ vỡ nợ quan sát. Cột cuối: số thực cần lưu (trung vị); thời gian dự đoán được đo riêng ở Mục 3.4.

Mô hình	AUC	ĐCX-CB (%)	F1 (%)	Số thực
Hồi quy logistic	0,724 $\pm$ 0,009	68,7 $\pm$ 0,6	51,2 $\pm$ 0,9	79
Thẻ điểm (logistic, biến rời rạc hóa)	0,773 $\pm$ 0,006	70,3 $\pm$ 0,6	53,7 $\pm$ 1,0	381
SVM tuyến tính	0,706 $\pm$ 0,008	68,5 $\pm$ 0,8	50,9 $\pm$ 1,4	79
PWL-LS-SVM, cộng tính, lưới đều	0,772 $\pm$ 0,006	70,3 $\pm$ 0,5	53,6 $\pm$ 0,9	547
PWL-LS-SVM, cộng tính, phân vị	0,776 $\pm$ 0,006	70,4 $\pm$ 0,7	53,8 $\pm$ 1,1	349
và ràng buộc đơn điệu (Mục 3.5.5)	0,775 $\pm$ 0,006	70,3 $\pm$ 0,8	53,7 $\pm$ 1,2	349
PWL-C-SVM, cộng tính, phân vị	0,744 $\pm$ 0,007	67,8 $\pm$ 0,8	49,9 $\pm$ 1,4	349
PWL-LS-SVM, HH	0,743 $\pm$ 0,007	69,5 $\pm$ 0,6	52,4 $\pm$ 1,0	6.631
SVM-RBF	0,716 $\pm$ 0,010	69,2 $\pm$ 0,6	52,0 $\pm$ 1,0	243.134
MLP-ReLU	0,768 $\pm$ 0,005	70,0 $\pm$ 0,4	53,3 $\pm$ 0,7	6.605
Tổ hợp cây tăng cường	0,779 $\pm$ 0,006	70,3 $\pm$ 0,7	53,7 $\pm$ 1,1	4.636

Khoảng cách 0,052 đơn vị AUC giữa PWL-LS-SVM và hồi quy logistic trên các biến gốc cần được hiểu đúng. Phần lớn khoảng cách đó đến từ quan hệ phi tuyến giữa các trạng thái trả nợ và rủi ro (Hình 3.6a), mà một mô hình tuyến tính theo PAY_0 không mô tả được. Trong thực tế, các thẻ điểm không dùng trực tiếp biến gốc mà rời rạc hóa từng biến thành các khoảng rồi mới hồi quy logistic [48], và thẻ điểm xây dựng theo cách đó ở Bảng 3.7 đã thu hẹp phần lớn khoảng cách. Thẻ điểm cũng là đối chứng công bằng nhất cho PWL-SVM cộng tính: cả hai đều là mô hình cộng tính, đều dựa trên các khoảng của từng biến, chỉ khác ở chỗ đóng góp của mỗi biến là hàm bậc thang trong thẻ điểm và là đường gấp khúc liên tục trong PWL-SVM. So với thẻ điểm, PWL-LS-SVM cao hơn ở bốn trong năm lần chia, với chênh lệch trung bình 0,002 đơn vị AUC, trong khi hai mô hình có kích thước tương đương (349 và 381 số thực). Chênh lệch này nhỏ, nhưng trong chấm điểm tín dụng, ngay cả những cải thiện nhỏ về khả năng phân biệt cũng có thể mang lại lợi ích kinh tế đáng kể khi áp dụng cho một danh mục lớn [29].

Ba quan sát khác đáng chú ý. Thứ nhất, lưới phân vị tốt hơn lưới đều (0,776 so với 0,772) với mô hình nhỏ hơn (349 so với 547 số thực), đúng như phân tích ở Hình 3.6b. Thứ hai, với cùng ánh xạ, PWL-C-SVM cho AUC thấp



Hình 3.7. Đường cong ROC trên tập kiểm tra của lần chia đầu tiên cho bốn mô hình; con số trong ngoặc là AUC trung bình qua năm lần chia.

hơn hẳn PWL-LS-SVM (0,744). Điều này có thể giải thích bằng hàm mất mát: mất mát bản lề chỉ quan tâm đến các điểm nằm gần hoặc vi phạm lề, nên giá trị hàm quyết định ở xa biên không mang nhiều thông tin về mức độ rủi ro; còn mất mát bình phương của LS-SVM, tương đương hồi quy trên nhãn ± 1 (Mệnh đề 2.11), buộc điểm số của mọi khách hàng phải phản ánh nhãn của họ, và vì thế cho một thứ hạng tốt hơn. SVM hạt nhân Gauss, cũng dùng mất mát bản lề, gặp cùng hạn chế. Thứ ba, ánh xạ HH (0,743) kém ánh xạ cộng tính: trên dữ liệu này, ảnh hưởng của từng biến quan trọng hơn tương tác giữa các biến, và các siêu phẳng ngẫu nhiên lãng phí khả năng biểu diễn, phù hợp với kết luận của Mục 3.3.3.

3.5.4. Diễn giải mô hình


Vì ánh xạ là cộng tính, hàm quyết định của PWL-LS-SVM tách thành tổng các đóng góp của từng biến,

$$f(x) = w_0 + \sum_{i=1}^n h_i(x(i)), \quad (3.1)$$

trong đó mỗi h_i là một hàm tuyến tính từng phần một biến, có không quá chín điểm gãy đặt tại các phân vị của biến đó (Mệnh đề 1.27). Mỗi h_i có thể được vẽ ra và đọc trực tiếp, giống như một thẻ điểm trong đó số điểm cộng thêm cho mỗi khách hàng là một đường gấp khúc theo giá trị của biến. Hình 3.8 vẽ sáu hàm h_i có ảnh hưởng lớn nhất của mô hình huấn luyện trên lần chia đầu tiên, sau khi trừ đi giá trị trung bình trên tập huấn luyện; giá trị dương nghĩa là rủi ro cao hơn một khách hàng trung bình.

Hàm đóng góp của PAY_0 thể hiện rõ cấu trúc mà hồi quy logistic trên biến gốc bỏ lỡ (so sánh với Hình 3.6a). Ba mã không chậm trả (-2 , -1 và 0) có đóng góp thấp và gần nhau; mã -1 cao hơn hai mã còn lại một chút, đúng như tỉ lệ vỡ nợ quan sát được (16,8% so với 13,2% và 12,8%). Đóng góp tăng mạnh khi khách hàng chậm trả một tháng (tỉ lệ vỡ nợ 33,9%) và đạt cực đại khi chậm hai tháng (69,1%); chênh lệch giữa mã 0 và mã 2 là 0,86 đơn vị điểm, lớn hơn toàn bộ biên độ của bất kỳ biến nào khác. Đóng góp của hạn mức tín dụng giảm dần theo hạn mức — điều hợp lý, vì hạn mức do chính ngân hàng xác định dựa trên đánh giá tín nhiệm — và khoảng 60% mức giảm diễn ra ở vùng hạn mức dưới 100 nghìn Đài tệ. Trạng thái trả nợ của các tháng trước (PAY_2, PAY_3, PAY_4) có hình dạng tương tự PAY_0 nhưng biên độ nhỏ hơn nhiều: thông tin gần nhất là quan trọng nhất.


Hai đặc điểm khác của các hàm đóng góp cần được đọc thận trọng. Thứ nhất, sau mức chậm hai tháng, đóng góp của PAY_0 và nhất là của PAY_4 lại giảm, trái với trực giác. Đây không phải là quy luật của dữ liệu mà là hệ quả của việc có quá ít dữ liệu: chỉ 1,5% khách hàng có PAY_0 từ 3 trở lên, tỉ lệ vỡ nợ của nhóm này (71,9%) không thấp hơn của nhóm chậm hai tháng,



Hình 3.8. Sáu hàm đóng góp h_i có ảnh hưởng lớn nhất của PWL-LS-SVM cộng tính (nút phân vị) trên dữ liệu tín dụng, đã trừ giá trị trung bình. Nét đậm: mô hình của lần chia đầu tiên, nét chấm dọc là vị trí các nút của nó; nét mảnh: mô hình của bốn lần chia còn lại. Giá trị dương ứng với rủi ro vỡ nợ cao hơn.

và những khách hàng này thường chậm trả nhiều tháng liền, nên mô hình có thể phân bổ rủi ro giữa các biến PAY theo nhiều cách gần tương đương. Hệ số góc của đoạn cuối, được ước lượng từ rất ít điểm, vì vậy không đáng tin cậy; Mục 3.5.5 sẽ khắc phục hiện tượng này. Thứ hai, các biến dư nợ sao kê BILL_AMT1–6 tương quan rất mạnh với nhau (hệ số tương quan giữa hai tháng liền kề từ 0,92 đến 0,95), nên mô hình có thể chuyển ảnh hưởng qua lại giữa chúng: chẳng hạn, đóng góp của BILL_AMT3 tăng theo dư nợ, còn đóng góp của BILL_AMT4 lại giảm. Với những nhóm biến như vậy, chỉ tổng đóng góp của cả nhóm mới nên được diễn giải. Đây là hạn chế chung của mọi mô hình cộng tính khi các biến tương quan mạnh, không riêng gì PWL-SVM.

Các nét mảnh ở Hình 3.8 cho thấy các hàm đóng góp thay đổi thế nào khi dữ liệu huấn luyện thay đổi. Ở vùng có nhiều dữ liệu, hình dạng gần như không đổi giữa các lần chia: giữa phân vị 5% và 95% của hạn mức tín dụng,



Hình 3.9. (a) Mức độ ảnh hưởng của mười biến quan trọng nhất, đo bằng độ lệch chuẩn của đóng góp h_i trên tập huấn luyện; với các biến định danh, đó là độ lệch chuẩn của tổng đóng góp của các biến chỉ báo tương ứng. (b) Tám đóng góp lớn nhất, so với khách hàng trung bình, của hồ sơ có điểm rủi ro cao nhất trong số các khách hàng vỡ nợ ở tập kiểm tra.

đóng góp của LIMIT_BAL ở bốn lần chia còn lại lệch khỏi lần chia đầu tiên không quá 15% biên độ của nó, và ở các trạng thái từ -2 đến 2 , đóng góp của PAY_0 lệch không quá 10% biên độ. Thứ hạng của các biến cũng ổn định: ở cả năm lần chia, PAY_0 là biến có ảnh hưởng lớn nhất và LIMIT_BAL đứng thứ hai; thứ tự của các biến tiếp theo, vốn có mức ảnh hưởng gần nhau, thì thay đổi giữa các lần chia. Ngược lại, ở các trạng thái chậm trả từ ba tháng trở lên, các lần chia cho những đường rất khác nhau: độ lệch chuẩn giữa các lần chia của đóng góp, tính trung bình trên sáu biến PAY, ở những trạng thái này lớn gấp khoảng 8 lần so với ở các trạng thái từ -2 đến 2 — thêm một bằng chứng rằng các đoạn đó không đáng tin cậy.

Hình 3.9a xếp hạng các biến theo mức độ ảnh hưởng. PAY_0 vượt xa mọi biến khác; tiếp theo, với mức ảnh hưởng nhỏ hơn nhiều, là hạn mức tín dụng, các trạng thái trả nợ của những tháng trước và các số tiền sao kê; các biến nhân khẩu học (học vấn, hôn nhân, giới tính, tuổi) có ảnh hưởng không đáng kể. Vì hàm quyết định (3.1) là một tổng, mỗi quyết định của mô hình được giải thích

một cách chính xác chứ không phải xấp xỉ: điểm của một khách hàng bằng điểm trung bình trên tập huấn luyện cộng với tổng các đóng góp của từng biến so với khách hàng trung bình. Hình 3.9b minh họa điều đó với khách hàng có điểm rủi ro cao nhất trong số những người vỡ nợ ở tập kiểm tra. Điểm của khách hàng này là 0,96, trong khi điểm trung bình là $-0,56$ và ngưỡng phân loại là $-0,44$. Trong phần chênh lệch 1,51 so với điểm trung bình, riêng việc chậm trả hai tháng ở tháng 9 đóng góp 0,71, lịch sử chậm trả ở năm tháng trước đó đóng góp thêm 0,63, và hạn mức thấp (20.000 Đài tệ) đóng góp 0,13. Một lời giải thích như vậy có thể được trình bày trực tiếp cho cán bộ tín dụng hay cho khách hàng. Với SVM hạt nhân Gauss hay tổ hợp cây, việc giải thích một quyết định đòi hỏi những kỹ thuật bổ sung, chẳng hạn giá trị SHAP [32], được tính sau khi huấn luyện và phức tạp hơn nhiều so với việc đọc trực tiếp các hàm h_i .


3.5.5. Ràng buộc đơn điệu

Người làm tín dụng kỳ vọng rằng rủi ro không giảm khi số tháng chậm trả tăng, và không tăng khi hạn mức tín dụng tăng. Mô hình không ràng buộc chỉ thỏa mãn một phần kỳ vọng này: ở cả năm lần chia, ít nhất một trong sáu hàm h_i của các biến PAY có một đoạn với hệ số góc âm ở vùng từ trạng thái 0 trở đi, và hàm của LIMIT_BAL có đoạn đi lên ở cả năm lần chia. Như đã phân tích ở trên, đó là những đoạn được ước lượng từ rất ít dữ liệu, không phải là quy luật thật. Một mô hình trái với tri thức nghiệp vụ khó được chấp nhận khi thẩm định, dù độ chính xác của nó cao; vì vậy ta đưa kỳ vọng đơn điệu vào chính bài toán huấn luyện.

Với PWL-SVM cộng tính, điều này có thể làm mà vẫn giữ tính lồi. Gọi $t_{i1} < \dots < t_{iK}$ là các nút của biến thứ i và $s_{i0}, \dots, s_{iK}$ là hệ số góc của h_i trên $K + 1$ đoạn mà các nút chia ra. Khi đó

$$h_i(t) = \sum_{j=0}^K s_{ij} G_{ij}(t), \quad G_{ij}(t) = \min\{(t - t_{ij})_+, t_{i,j+1} - t_{ij}\}, \quad (3.2)$$

với quy ước $t_{i0} = -\infty$, $t_{i,K+1} = +\infty$ (tức $G_{i0}(t) = \min\{t, t_{i1}\}$ và $G_{iK}(t) =$



Hình 3.10. Hàm đóng góp của PAY_0 , PAY_4 và $LIMIT_BAL$ trong mô hình không ràng buộc (nét liền) và mô hình có ràng buộc đơn điệu (nét đứt), lần chia đầu tiên. Vùng tô xám: các trạng thái chậm trễ từ ba tháng trở lên, chỉ chiếm chưa tới 2% số khách hàng.

$(t - t_{iK})_+$: $G_{ij}(t)$ là độ dài phần đoạn thứ j nằm bên trái t . Theo Mệnh đề 1.27, hệ số của $x(i)$ trong ánh xạ (2.15) bằng s_{i0} và hệ số của $(x(i) - t_{ij})_+$ bằng $s_{ij} - s_{i,j-1}$. Vì vậy (3.2) chỉ là một cách tham số hóa khác của cùng một mô hình, và bài toán (2.22) trở thành

$$\min_{s, w_0} \frac{1}{2} \sum_{i=1}^n \left[s_{i0}^2 + \sum_{j=1}^K (s_{ij} - s_{i,j-1})^2 \right] + \frac{\gamma}{2} \sum_{k=1}^N \left(y_k - w_0 - \sum_{i=1}^n h_i(x_k(i)) \right)^2.$$

Hàm h_i không giảm khi và chỉ khi $s_{ij} \geq 0$ với mọi j , và không tăng khi và chỉ khi $s_{ij} \leq 0$ với mọi j ; muốn h_i đơn điệu chỉ trên một phần của trục, chẳng hạn trên nửa đường thẳng $t \geq t_{ij_0}$, ta chỉ cần áp các bất đẳng thức đó cho những đoạn nằm trong phần ấy. Thêm các ràng buộc này, ta được một bài toán bình phương tối thiểu với ràng buộc cận trên các biến — một bài toán lồi, giải được chính xác bằng thuật toán BVLS [41] có sẵn trong SciPy [51]. Cũng như ở Nhận xét 2.14, tri thức tiên nghiệm được đưa vào mô hình mà không phải từ bỏ tính lồi. Khi không có ràng buộc nào, lời giải trùng với lời giải của Mệnh đề 2.11 (sai khác dưới 10^{-9}), điều được dùng để kiểm tra cài đặt.

Ta ràng buộc sáu hàm của các biến PAY không giảm từ trạng thái 0 trở đi

— ba mã -2 , -1 và 0 chỉ những tình trạng không chậm trễ khác nhau, không có thứ tự tự nhiên, nên được để tự do — và hàm của `LIMIT_BAL` không tăng trên toàn miền; các biến khác, các nút và hằng số γ đã chọn cho mô hình không ràng buộc được giữ nguyên. Hình 3.10 cho thấy tác động của ràng buộc: sau mức chậm hai tháng, đóng góp của `PAY_0` và `PAY_4` giữ nguyên thay vì giảm, và đường của `LIMIT_BAL` trở thành đơn điệu giảm, trong khi hình dạng ở vùng có nhiều dữ liệu hầu như không đổi. Độ chính xác hầu như không thay đổi: AUC trung bình là $0,775$, so với $0,776$ của mô hình không ràng buộc, và mô hình có ràng buộc vẫn cao hơn thể điểm ($0,773$) (Bảng 3.7). Như vậy, với ràng buộc đơn điệu, `PWL-LS-SVM` cộng tính cho một mô hình vừa chính xác vừa nhất quán với tri thức nghiệp vụ.

3.5.6. Khả năng triển khai

Mô hình `PWL-LS-SVM` cộng tính trên dữ liệu tín dụng gồm 349 số thực: các nút và hệ số của 20 đường gấp khúc cho các biến số, hệ số của 6 biến chỉ báo, hệ số chặn và hai vectơ chuẩn hóa. Để chấm điểm một hồ sơ, với mỗi biến ta chỉ cần xác định giá trị rơi vào đoạn nào giữa các nút rồi tính một hàm bậc nhất, tổng cộng vài trăm phép so sánh, nhân và cộng. Một mô hình như vậy có thể được cài đặt bằng vài dòng lệnh SQL trong kho dữ liệu của ngân hàng, bằng một bảng tính, hoặc trên thiết bị có tài nguyên rất hạn chế, mà không cần thư viện học máy nào; ràng buộc đơn điệu không làm thay đổi cấu trúc này. Việc huấn luyện lại khi có dữ liệu mới chỉ mất chưa tới một giây (Bảng 3.5). Để so sánh, SVM hạt nhân Gauss cần lưu khoảng 243.134 số thực, và tổ hợp cây tăng cường gồm từ 34 đến 47 cây quyết định với khoảng 4.636 tham số; cả hai đều khó kiểm tra và giải thích hơn nhiều.

3.6. Thảo luận

Trả lời các câu hỏi nghiên cứu. Các thực nghiệm của chương cho phép trả lời bốn câu hỏi nêu ở Mở đầu.

(CH1) *Độ chính xác.* Trên dữ liệu hai chiều, `PWL-SVM` dạng HH đạt độ chính xác gần SVM hạt nhân Gauss, trừ trên bàn cờ (Bảng 3.1). Trên mười bộ

dữ liệu chuẩn, PWL-C-SVM cộng tính đứng giữa SVM tuyến tính và SVM hạt nhân Gauss: nó kém SVM hạt nhân Gauss trung bình 1,4 điểm phần trăm, một khác biệt có ý nghĩa thống kê, và hơn SVM tuyến tính trung bình 1,7 điểm, với phần cải thiện tập trung ở những bộ dữ liệu phi tuyến rõ rệt (Bảng 3.3 và 3.4). Nhận định của bài báo gốc rằng PWL-SVM chính xác tương đương SVM hạt nhân Gauss vì vậy không được xác nhận khi thực nghiệm được lặp lại. Trên dữ liệu tín dụng, ngược lại, PWL-LS-SVM cộng tính thuộc nhóm mô hình tốt nhất, cùng với tổ hợp cây tăng cường và thẻ điểm logistic (Bảng 3.7).

(CH2) *Chi phí*. Lợi thế về chi phí được xác nhận rõ ràng. Với ánh xạ cộng tính, mô hình nhỏ hơn SVM hạt nhân Gauss từ 2,5 đến 36 lần trên mười bộ dữ liệu chuẩn và khoảng 690 lần trên dữ liệu tín dụng; thời gian dự đoán nhanh hơn khoảng 200 lần trên Magic và 430 lần trên dữ liệu tín dụng (Bảng 3.5). PWL-LS-SVM còn là mô hình phi tuyến huấn luyện nhanh nhất.

(CH3) *Cấu hình*. Ánh xạ cộng tính là lựa chọn mặc định tốt cho dữ liệu dạng bảng: rẻ, dễ diễn giải và thường chính xác nhất trong các dạng ánh xạ. Ánh xạ HH chỉ có lợi khi tương tác giữa các biến đáng kể (bàn cờ, xoắn ốc, Ionosphere); kích thước của nó tăng gần như bậc hai theo số chiều, và quy tắc sinh tham số của bài báo gốc có thể thất bại trên dữ liệu thưa. Độ chính xác bão hòa quanh $M/n = 5-10$. Hai điều chỉnh nhỏ của đề án — nút theo phân vị và chuẩn hóa $\|p\|_2 = 1$ — cải thiện kết quả và độ ổn định số mà không thay đổi bản chất của phương pháp.

(CH4) *Ứng dụng*. Trên bài toán võ nợ thẻ tín dụng, PWL-LS-SVM cộng tính với nút phân vị đạt AUC 0,776, chỉ kém một chút so với tổ hợp cây tăng cường (0,779) và cao hơn thẻ điểm logistic truyền thống (0,773) ở bốn trong năm lần chia, trong khi mô hình chỉ gồm 349 số thực, dự đoán mỗi hồ sơ trong khoảng 0,56 micro giây và đọc được như một thẻ điểm tuyến tính từng phần (Hình 3.8). Khi thêm ràng buộc đơn điệu để mô hình nhất quán với tri thức nghiệp vụ, AUC hầu như không đổi (0,775 so với 0,776) (Mục 3.5.5).

Khi nào nên dùng PWL-SVM. Từ các kết quả trên, PWL-SVM cộng tính phù hợp với dữ liệu dạng bảng có số chiều vừa phải, khi mô hình cần nhỏ,

dự đoán nhanh hoặc phải giải thích được: chấm điểm tín dụng, các hệ thống nhúng, hay bất cứ bối cảnh nào mà hồi quy logistic đang được dùng vì tính minh bạch. Khi độ chính xác là tiêu chí duy nhất và tài nguyên không bị hạn chế, SVM hạt nhân Gauss, mạng nơ-ron hay tổ hợp cây thường là lựa chọn tốt hơn. Với dữ liệu nhiều chiều, thưa hoặc có tương tác phức tạp, PWL-SVM với các siêu phẳng sinh ngẫu nhiên không phải là công cụ thích hợp; khi đó nên học cả các siêu phẳng, tức là chuyển sang mạng nơ-ron ReLU.

Giới hạn của thực nghiệm. Kết luận của chương dựa trên mười bộ dữ liệu chuẩn và một bài toán ứng dụng, nên lực của các kiểm định thống kê còn hạn chế. Các lưới tham số được chọn theo khuyến nghị thông dụng và có thể chưa tối ưu cho mọi mô hình; SVM hạt nhân Gauss và mạng nơ-ron trên dữ liệu tín dụng được tinh chỉnh trên mẫu con; thể điểm đối chứng dùng một cách rời rạc hóa đơn giản (mười khoảng theo thập phân vị), trong khi các thể điểm thực tế thường được xây dựng với các khoảng chọn cẩn thận hơn. Bộ giải LIBLINEAR chính quy hóa nhẹ hệ số chặn, khác với bài toán (2.16). Dữ liệu tín dụng được thu thập ở Đài Loan năm 2005, nên các hàm đóng góp tìm được minh họa phương pháp chứ không nhất thiết phản ánh hành vi của khách hàng Việt Nam hiện nay. Cuối cùng, thời gian đo được phụ thuộc vào phần cứng và cách cài đặt.

Tiểu kết Chương 3

Chương 3 đã cài đặt PWL-SVM, kiểm chứng tính đúng đắn của cài đặt bằng các phép thử số, và đánh giá phương pháp qua ba lớp thực nghiệm: dữ liệu hai chiều, mười bộ dữ liệu chuẩn và một bài toán ứng dụng. Kết quả cho một bức tranh nhất quán: PWL-SVM không chính xác hơn các mô hình phi tuyến mạnh như SVM hạt nhân Gauss, nhưng nó cho những mô hình nhỏ hơn từ vài lần đến hàng trăm lần, dự đoán nhanh hơn nhiều, huấn luyện bằng một bài toán lồi và, với ánh xạ cộng tính, có thể đọc được từng thành phần. Trên bài toán dự báo vỡ nợ thể tín dụng, nơi các tính chất đó được coi trọng, PWL-LS-SVM cộng tính với nút phân vị đạt độ chính xác ngang những mô

hình tốt nhất, và với ràng buộc đơn điệu, cho một mô hình nhất quán với tri thức nghiệp vụ mà không mất độ chính xác.

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Kết quả đạt được

Đề án đã nghiên cứu một cách có hệ thống phương pháp SVM với ánh xạ đặc trưng tuyến tính từng phần của Huang, Mehrkanoon và Suykens [26], cài đặt lại phương pháp, đánh giá nó bằng thực nghiệm lặp lại và áp dụng vào bài toán dự báo vỡ nợ thẻ tín dụng. Các kết quả chính như sau.

Về lý thuyết. Đề án đã trình bày đầy đủ chuỗi lập luận từ tập lỗi, định lý siêu phẳng phân tách và đối ngẫu Lagrange đến SVM lồi cứng, lồi mềm và LS-SVM, rồi từ các định lý biểu diễn hàm tuyến tính từng phần đến ánh xạ đặc trưng tuyến tính từng phần. Bên cạnh việc viết lại các chứng minh, đề án đã đưa ra một chứng minh ngắn hơn cho định lý biểu diễn tập tuyến tính từng phần, chỉ ra rằng hàm xây dựng trong chứng minh luôn không âm nên chỉ mô tả biên chứ không phải một bộ phân loại, chứng minh rằng phần tuyến tính của SVM hạt nhân giao triệt tiêu nhờ ràng buộc của bài toán đối ngẫu, chứng minh rằng hiệu hai hàm khoảng cách của phương pháp láng giềng gần nhất là hàm tuyến tính từng phần, chỉ ra dạng gốc của PWL-LS-SVM chính là hồi quy ridge, nêu một giới hạn cơ bản của mô hình cộng tính đối với cấu trúc kiểu XOR, và chỉ ra rằng tham số hóa theo hệ số góc cho phép đưa ràng buộc đơn điệu vào PWL-SVM cộng tính mà bài toán vẫn là lồi.

Về cài đặt. Đề án cung cấp một cài đặt bằng Python, tương thích với scikit-learn, cho ba dạng ánh xạ và hai mô hình PWL-C-SVM và PWL-LS-SVM, cùng hai tùy chọn mới là đặt nút theo phân vị và chuẩn hóa siêu phẳng, và một biến thể PWL-LS-SVM cộng tính có ràng buộc đơn điệu. Tính đúng đắn của cài đặt được kiểm chứng bằng số: nghiệm gốc và nghiệm đối ngẫu trùng nhau đến sai số làm tròn.

Về thực nghiệm. Trên mười bộ dữ liệu chuẩn, PWL-SVM cộng tính chính xác hơn SVM tuyến tính nhưng kém SVM hạt nhân Gauss trung bình 1,4 điểm phần trăm; nhận định về độ chính xác của bài báo gốc, vốn dựa trên một lần

chia dữ liệu, chỉ được xác nhận một phần. Ngược lại, lợi thế về kích thước mô hình và tốc độ dự đoán được xác nhận rõ ràng: mô hình nhỏ hơn SVM hạt nhân Gauss từ 2,5 đến 36 lần trên các bộ dữ liệu chuẩn, và dự đoán nhanh hơn khoảng 200 lần trên Magic. Các thực nghiệm cũng cho thấy ánh xạ cộng tính là lựa chọn mặc định hợp lý, số đặc trưng $M = 5n$ đến $10n$ là đủ, còn quy tắc sinh siêu phẳng của bài báo gốc có thể gây sự cố số trên dữ liệu thưa và nên được thay bằng quy tắc chuẩn hóa $\|p\|_2 = 1$.

Về ứng dụng. Trên dữ liệu vỡ nợ của 30.000 chủ thẻ tín dụng, PWL-LS-SVM cộng tính với nút phân vị đạt AUC 0,776, chỉ kém một chút so với tổ hợp cây tăng cường (0,779), cao hơn thẻ điểm logistic trên các biến rời rạc hóa (0,773) và cao hơn rõ rệt hồi quy logistic trên biến gốc (0,724) cũng như SVM hạt nhân Gauss (0,716). Mô hình chỉ gồm 349 số thực, dự đoán mỗi hồ sơ trong khoảng 0,56 micro giây, và mỗi biến có một hàm đóng góp tuyến tính từng phần đọc được, phù hợp với yêu cầu minh bạch của chấm điểm tín dụng. Khi thêm ràng buộc đơn điệu cho các biến trạng thái trả nợ và hạn mức, mô hình trở nên nhất quán với tri thức nghiệp vụ, trong khi AUC hầu như không đổi (0,775 so với 0,776).

Hạn chế

Các tham số phi tuyến của ánh xạ được chọn theo quy tắc cố định hoặc ngẫu nhiên chứ không được học từ dữ liệu, nên PWL-SVM dạng HH kém hiệu quả trên dữ liệu nhiều chiều. Các định lý biểu diễn chỉ khẳng định sự tồn tại và không cho biết cần bao nhiêu đặc trưng. Thực nghiệm dựa trên mười bộ dữ liệu chuẩn và một bài toán ứng dụng, với các lưới tham số và một thẻ điểm đối chứng được xây dựng theo cách đơn giản; dữ liệu tín dụng được thu thập ở Đài Loan năm 2005 và có thể không đại diện cho khách hàng Việt Nam hiện nay. Đề án chỉ xét bài toán phân loại nhị phân, và dạng siêu phẳng bản lề tổng quát chỉ được thử trên dữ liệu hai chiều.

Hướng phát triển

Từ các kết quả và hạn chế trên, có bốn hướng phát triển tự nhiên. Thứ nhất, dùng chính quy hóa ℓ_1 như trong Mục 5 của [26] để tự động loại bớt các đặc trưng thừa và thu được những biên gồm ít mảnh hơn. Thứ hai, mở rộng cách tiếp cận ở Mục 3.5.5 cho những dạng tri thức nghiệp vụ khác, chẳng hạn ràng buộc lỗi (Nhận xét 2.14) hay ràng buộc về độ trơn của các hàm đóng góp, và chọn hằng số γ đồng thời với các ràng buộc. Thứ ba, học cả tham số của các siêu phẳng bản lề, chẳng hạn bằng cách xen kẽ giữa tối ưu các siêu phẳng và giải SVM, tiến tới các mạng nơ-ron tuyến tính từng phần [45]. Thứ tư, mở rộng phương pháp cho bài toán nhiều lớp và hồi quy, và kiểm nghiệm trên dữ liệu tín dụng của Việt Nam khi có điều kiện tiếp cận.

TÀI LIỆU THAM KHẢO

Tiếng Việt

- [1] Đỗ Văn Lưu, Phan Huy Khải (2000), *Giải tích lồi*, Nhà xuất bản Khoa học và Kỹ thuật, Hà Nội.
- [2] Vũ Hữu Tiệp (2018), *Machine Learning cơ bản*, Nhà xuất bản Khoa học và Kỹ thuật, Hà Nội.

Tiếng Anh

- [3] Arora R., Basu A., Mianjy P., Mukherjee A. (2018), “Understanding deep neural networks with rectified linear units”, in: *International Conference on Learning Representations (ICLR 2018)*.
- [4] Baesens B., Van Gestel T., Viaene S., Stepanova M., Suykens J.A.K., Vanthienen J. (2003), “Benchmarking state-of-the-art classification algorithms for credit scoring”, *Journal of the Operational Research Society*, 54(6), pp. 627–635.
- [5] Bagirov A.M. (2005), “Max–min separability”, *Optimization Methods and Software*, 20(2–3), pp. 277–296.
- [6] Bennett K.P., Bredensteiner E.J. (2000), “Duality and geometry in SVM classifiers”, in: *Proceedings of the 17th International Conference on Machine Learning (ICML)*, pp. 57–64.
- [7] Boser B.E., Guyon I.M., Vapnik V.N. (1992), “A training algorithm for optimal margin classifiers”, in: *Proceedings of the 5th Annual Workshop on Computational Learning Theory (COLT)*, ACM, pp. 144–152.
- [8] Boyd S., Vandenberghe L. (2004), *Convex Optimization*, Cambridge University Press, Cambridge.
- [9] Breiman L. (1993), “Hinging hyperplanes for regression, classification, and function approximation”, *IEEE Transactions on Information Theory*, 39(3), pp. 999–1013.
- [10] Canu S., Grandvalet Y., Guigue V., Rakotomamonjy A. (2005), *SVM and Kernel Methods Matlab Toolbox*, Perception Systèmes et Information, INSA de Rouen, Rouen.
- [11] Chang C.-C., Lin C.-J. (2011), “LIBSVM: a library for support vector machines”, *ACM Transactions on Intelligent Systems and Technology*, 2(3), Article 27.
- [12] Chua L.O., Kang S.M. (1977), “Section-wise piecewise-linear functions: canonical representation, properties, and applications”, *Proceedings of the IEEE*, 65(6), pp. 915–929.

- [13] Cortes C., Vapnik V. (1995), “Support-vector networks”, *Machine Learning*, 20(3), pp. 273–297.
- [14] Cover T., Hart P. (1967), “Nearest neighbor pattern classification”, *IEEE Transactions on Information Theory*, 13(1), pp. 21–27.
- [15] Demšar J. (2006), “Statistical comparisons of classifiers over multiple data sets”, *Journal of Machine Learning Research*, 7, pp. 1–30.
- [16] Do T.-N., Poulet F. (2017), “Parallel learning of local SVM algorithms for classifying large datasets”, in: *Transactions on Large-Scale Data- and Knowledge-Centered Systems XXXI*, Lecture Notes in Computer Science 10140, Springer, Berlin, Heidelberg.
- [17] Fan R.-E., Chang K.-W., Hsieh C.-J., Wang X.-R., Lin C.-J. (2008), “LIBLINEAR: a library for large linear classification”, *Journal of Machine Learning Research*, 9, pp. 1871–1874.
- [18] Fawcett T. (2006), “An introduction to ROC analysis”, *Pattern Recognition Letters*, 27(8), pp. 861–874.
- [19] Freund Y., Schapire R.E. (1995), “A decision-theoretic generalization of on-line learning and an application to boosting”, in: *Computational Learning Theory (EuroCOLT 1995)*, Lecture Notes in Computer Science 904, Springer, pp. 23–37.
- [20] Friedman J.H. (2001), “Greedy function approximation: a gradient boosting machine”, *The Annals of Statistics*, 29(5), pp. 1189–1232.
- [21] Goodfellow I., Warde-Farley D., Mirza M., Courville A., Bengio Y. (2013), “Maxout networks”, in: *Proceedings of the 30th International Conference on Machine Learning (ICML)*, pp. 1319–1327.
- [22] Harris C.R. và cộng sự (2020), “Array programming with NumPy”, *Nature*, 585(7825), pp. 357–362.
- [23] Hastie T., Tibshirani R. (1990), *Generalized Additive Models*, Chapman & Hall, London.
- [24] Hsu C.-W., Chang C.-C., Lin C.-J. (2003), *A Practical Guide to Support Vector Classification*, Technical report, Department of Computer Science, National Taiwan University.
- [25] Huang G.-B., Zhu Q.-Y., Siew C.-K. (2006), “Extreme learning machine: theory and applications”, *Neurocomputing*, 70(1–3), pp. 489–501.
- [26] Huang X., Mehrkanon S., Suykens J.A.K. (2013), “Support vector machines with piecewise linear feature mapping”, *Neurocomputing*, 117, pp. 118–127.
- [27] Kelly M., Longjohn R., Nottingham K., *The UCI Machine Learning Repository*, <https://archive.ics.uci.edu> (truy cập tháng 9/2026).
- [28] Kostin A. (2006), “A simple and fast multi-class piecewise linear pattern classifier”, *Pattern Recognition*, 39(11), pp. 1949–1962.

- [29] Lessmann S., Baesens B., Seow H.-V., Thomas L.C. (2015), “Benchmarking state-of-the-art classification algorithms for credit scoring: an update of research”, *European Journal of Operational Research*, 247(1), pp. 124–136.
- [30] Li Y., Liu B., Yang X., Fu Y., Li H. (2011), “Multiconlitron: a general piecewise linear classifier”, *IEEE Transactions on Neural Networks*, 22(2), pp. 276–289.
- [31] Liu D.C., Nocedal J. (1989), “On the limited memory BFGS method for large scale optimization”, *Mathematical Programming*, 45(1–3), pp. 503–528.
- [32] Lundberg S.M., Lee S.-I. (2017), “A unified approach to interpreting model predictions”, in: *Advances in Neural Information Processing Systems 30*, pp. 4765–4774.
- [33] Maji S., Berg A.C., Malik J. (2008), “Classification using intersection kernel support vector machines is efficient”, in: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1–8.
- [34] Mangasarian O.L. (1968), “Multisurface method of pattern separation”, *IEEE Transactions on Information Theory*, 14(6), pp. 801–807.
- [35] Ovchinnikov S. (2002), “Max-min representation of piecewise linear functions”, *Beiträge zur Algebra und Geometrie*, 43(1), pp. 297–302.
- [36] Pedregosa F. và cộng sự (2011), “Scikit-learn: machine learning in Python”, *Journal of Machine Learning Research*, 12, pp. 2825–2830.
- [37] Platt J.C. (1999), “Fast training of support vector machines using sequential minimal optimization”, in: *Advances in Kernel Methods: Support Vector Learning*, MIT Press, Cambridge, MA, pp. 185–208.
- [38] Rahimi A., Recht B. (2007), “Random features for large-scale kernel machines”, in: *Advances in Neural Information Processing Systems 20*, pp. 1177–1184.
- [39] Schölkopf B., Smola A.J. (2002), *Learning with Kernels*, MIT Press, Cambridge, MA.
- [40] Sklansky J., Michelotti L. (1980), “Locally trained piecewise linear classifiers”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2(2), pp. 101–111.
- [41] Stark P.B., Parker R.L. (1995), “Bounded-variable least-squares: an algorithm and applications”, *Computational Statistics*, 10(2), pp. 129–141.
- [42] Suykens J.A.K., Vandewalle J. (1999), “Least squares support vector machine classifiers”, *Neural Processing Letters*, 9(3), pp. 293–300.
- [43] Suykens J.A.K., Vandewalle J. (1999), “Training multilayer perceptron classifiers based on a modified support vector method”, *IEEE Transactions on Neural Networks*, 10(4), pp. 907–911.
- [44] Suykens J.A.K., Van Gestel T., De Brabanter J., De Moor B., Vandewalle J. (2002), *Least Squares Support Vector Machines*, World Scientific, Singapore.

- [45] Tao Q., Li L., Huang X., Xi X., Wang S., Suykens J.A.K. (2022), “Piecewise linear neural networks and deep learning”, *Nature Reviews Methods Primers*, 2, Article 42.
- [46] Tarela J.M., Martínez M.V. (1999), “Region configurations for realizability of lattice piecewise-linear models”, *Mathematical and Computer Modelling*, 30(11–12), pp. 17–27.
- [47] Tenmoto H., Kudo M., Shimbo M. (1998), “Piecewise linear classifiers with an appropriate number of hyperplanes”, *Pattern Recognition*, 31(11), pp. 1627–1634.
- [48] Thomas L.C., Edelman D.B., Crook J.N. (2002), *Credit Scoring and Its Applications*, SIAM, Philadelphia.
- [49] Vanschoren J., van Rijn J.N., Bischl B., Torgo L. (2013), “OpenML: networked science in machine learning”, *SIGKDD Explorations*, 15(2), pp. 49–60.
- [50] Vapnik V.N. (1998), *Statistical Learning Theory*, Wiley, New York.
- [51] Virtanen P. và cộng sự (2020), “SciPy 1.0: fundamental algorithms for scientific computing in Python”, *Nature Methods*, 17(3), pp. 261–272.
- [52] Wang S., Sun X. (2005), “Generalization of hinging hyperplanes”, *IEEE Transactions on Information Theory*, 51(12), pp. 4425–4431.
- [53] Webb D. (2010), *Efficient Piecewise Linear Classifiers and Applications*, PhD thesis, University of Ballarat, Australia.
- [54] Yeh I.-C., Lien C.-H. (2009), “The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients”, *Expert Systems with Applications*, 36(2), pp. 2473–2480.

PHỤ LỤC

A. Mã nguồn chính

Toàn bộ mã nguồn của đề án gồm mô-đun `pwlsvm.py` (ánh xạ đặc trưng và mô hình), mô-đun `baselines.py` (LS-SVM hạt nhân Gauss, SVM hạt nhân giao), các tệp nạp dữ liệu và các tệp thực nghiệm; mỗi hình và bảng của Chương 3 được sinh bởi một tệp riêng, với hạt giống ngẫu nhiên cố định. Dưới đây là phần cốt lõi của `pwlsvm.py`, đã lược bớt phần kiểm tra đầu vào và chú thích.

```
import numpy as np
from sklearn.preprocessing import MinMaxScaler
from sklearn.svm import SVC, LinearSVC

def random_hyperplane(rng, lo, hi):
    """ $p^T x + q = 0$  through  $n$  uniform points of  $[lo, hi]$ ,
    with  $p(1) = +1$  or  $-1$ ."""
    n = lo.size
    while True:
        U = rng.uniform(lo, hi, size=(n, n)) # rows  $u_j$ 
        s = rng.choice([-1.0, 1.0]) #  $p(1)$ 
        A = np.hstack([U[:, 1:], np.ones((n, 1))])
        if abs(np.linalg.det(A)) > 1e-12:
            sol = np.linalg.solve(A, -s * U[:, 0])
            return np.r_[s, sol[:-1]], sol[-1]

class PWLFeatures:
    """ $\phi(x) = [x(1..n), \text{hinge features}]$ ."""
    def __init__(self, kind, m_per_dim, knots="uniform",
                 normalize=False, random_state=None): ...

    def fit(self, X):
        n = X.shape[1]; lo, hi = X.min(0), X.max(0)
        if self.kind == "additive": # additive map
            S = int(self.m_per_dim); f = np.arange(1, S) / S
            axes, knots = [], []
            for i in range(n):
                if self.knots == "uniform":
                    q = lo[i] + (hi[i] - lo[i]) * f
                else: # quantile knots
                    q = np.unique(np.quantile(X[:, i], f))
                    q = q[(q > lo[i]) & (q < hi[i])]
                axes.append(np.full(q.size, i)); knots.append(q)
            self.axis_ = np.concatenate(axes)
            self.knot_ = np.concatenate(knots)
        else: # HH or GHH map
```

```

        rng = np.random.default_rng(self.random_state)
        D = int(round((self.m_per_dim - 1) * n))
        k = 1 if self.kind == "hh" else n
        P, q = np.empty((D, k, n)), np.empty((D, k))
        for m in range(D):
            for j in range(k):
                P[m, j], q[m, j] = random_hyperplane(rng, lo, hi)
        if self.normalize:  # ||p||_2 = 1
            s = np.linalg.norm(P, axis=2)
            P, q = P / s[...], q / s
        self.P_, self.q_ = P, q
    return self

def transform(self, X):
    if self.kind == "additive":
        H = np.maximum(0.0, X[:, self.axis_] - self.knot_)
    else:
        D, k, n = self.P_.shape
        Z = X @ self.P_.reshape(D * k, n).T + self.q_.ravel()
        H = np.maximum(0.0, Z.reshape(len(X), D, k).max(2))
    return np.hstack([X, H])

class PWLSVM:
    """PWL-C-SVM (loss="hinge") or PWL-LS-SVM ("squared")."""
    def fit(self, X, y):
        self.scaler_ = MinMaxScaler().fit(X)
        Xs = self.scaler_.transform(X)
        self.features_ = PWLFeatures(self.kind, self.m_per_dim,
                                     self.knots, self.random_state).fit(Xs)
        Phi = self.features_.transform(Xs)
        if self.loss == "squared":  # ridge primal
            t = np.where(y == y.max(), 1.0, -1.0)
            mu, tb = Phi.mean(0), t.mean()
            Pc = Phi - mu
            A = Pc.T @ Pc + np.eye(Phi.shape[1]) / self.C
            self.coef_ = np.linalg.solve(A, Pc.T @ (t - tb))
            self.intercept_ = tb - mu @ self.coef_
        elif self.solver == "libsvm":  # exact dual
            m = SVC(kernel="linear", C=self.C).fit(Phi, y)
            self.coef_, self.intercept_ = m.coef_[0], m.intercept_[0]
        else:  # LIBLINEAR
            m = LinearSVC(loss="hinge", C=self.C, dual=True,
                          intercept_scaling=10.0).fit(Phi, y)
            self.coef_, self.intercept_ = m.coef_[0], m.intercept_[0]
        return self

    def decision_function(self, X):
        Phi = self.features_.transform(self.scaler_.transform(X))
        return Phi @ self.coef_ + self.intercept_

```

Ví dụ sử dụng, với cú pháp quen thuộc của scikit-learn:

```

model = PWLSVM(kind="additive", m_per_dim=10, loss="squared",
               knots="quantile", C=2.0).fit(X_train, y_train)
scores = model.decision_function(X_test)

```

Phần cốt lõi của `pwlsvm_monotone.py` (Mục 3.5.5): mỗi biến được tham số hóa bởi các hệ số góc s_{ij} theo (3.2), và ràng buộc đơn điệu trở thành ràng buộc cận trên các s_{ij} .

```
from scipy.linalg import block_diag
from scipy.optimize import lsq_linear

def fit_monotone(Xs, t, knots, C, sign):
    """Xs: inputs in [0, 1]; t: labels +-1; knots[i]: sorted
    knots of input i; sign[i]: +1, -1 or 0 for each segment."""
    G, D, lb, ub = [], [], [], []
    for i, tk in enumerate(knots):
        x, K = Xs[:, i], len(tk)
        g = np.empty((len(x), K + 1)) # the G_ij
        g[:, 0] = np.minimum(x, tk[0]) if K else x
        for j in range(1, K):
            g[:, j] = np.clip(x - tk[j-1], 0, tk[j] - tk[j-1])
        if K:
            g[:, K] = np.maximum(0, x - tk[K-1])
        G.append(g)
        D.append(np.eye(K + 1) - np.eye(K + 1, k=-1)) # s -> (a, c)
        lb.append(np.where(sign[i] > 0, 0.0, -np.inf))
        ub.append(np.where(sign[i] < 0, 0.0, np.inf))
    G, D = np.hstack(G), block_diag(*D)
    gbar, tbar = G.mean(0), t.mean() # unpenalized bias
    A = np.vstack([np.sqrt(C) * (G - gbar), D])
    b = np.r_[np.sqrt(C) * (t - tbar), np.zeros(len(D))]
    s = lsq_linear(A, b, bounds=(np.concatenate(lb),
        np.concatenate(ub)), method="bvls").x
    return s, tbar - gbar @ s # slopes, bias
```

B. Kết quả đầy đủ trên mười bộ dữ liệu chuẩn

Bảng PL.1 bổ sung cho Bảng 3.3 độ lệch chuẩn của độ chính xác qua mười lần chia (năm lần với Spambase) và kích thước của từng mô hình. Kích thước được tính là số thực cần lưu để dự đoán, gồm cả hai vectơ giá trị nhỏ nhất và lớn nhất dùng để chuẩn hóa: với SVM hạt nhân và kNN là các điểm được lưu cùng hệ số của chúng; với MLP là mọi trọng số và độ lệch; với PWL-SVM là các nút hoặc tham số của siêu phẳng cùng vectơ w và w_0 .

Bảng PL.1. Độ chính xác trên tập kiểm tra (% , trung bình $\pm$ độ lệch chuẩn qua 10 lần chia, 5 lần với Spambase) và kích thước mô hình (số thực cần lưu, trung vị).

Dữ liệu	SVM tuyến tính	SVM- RBF	LS-SVM- RBF	kNN ($k = 1$)	Ik- SVM
Haberman	$72,5 \pm 1,1$	$73,3 \pm 1,9$	$73,4 \pm 1,8$	$65,7 \pm 1,5$	$72,0 \pm 1,4$
Transfusion	$76,5 \pm 0,4$	$77,6 \pm 1,4$	$77,7 \pm 1,5$	$68,4 \pm 2,0$	$76,7 \pm 0,9$
Banknote	$98,6 \pm 0,4$	$100,0 \pm 0,0$	$100,0 \pm 0,1$	$99,8 \pm 0,1$	$99,9 \pm 0,2$
Pima	$76,7 \pm 1,6$	$76,1 \pm 2,3$	$76,6 \pm 2,0$	$70,8 \pm 2,1$	$76,0 \pm 1,7$
Breast	$96,6 \pm 0,5$	$96,5 \pm 0,9$	$96,4 \pm 0,9$	$95,3 \pm 1,0$	$96,4 \pm 0,7$
Magic	$79,0 \pm 0,2$	$85,5 \pm 0,4$	$85,6 \pm 0,4$	$78,3 \pm 0,5$	$85,0 \pm 0,4$
Parkinsons	$85,4 \pm 2,3$	$89,9 \pm 3,5$	$91,4 \pm 3,8$	$93,7 \pm 2,3$	$89,4 \pm 3,1$
Ionosphere	$86,2 \pm 1,5$	$93,4 \pm 1,6$	$93,8 \pm 1,8$	$86,4 \pm 3,3$	$91,1 \pm 1,8$
Spambase	$93,0 \pm 0,6$	$93,6 \pm 0,4$	$93,4 \pm 0,5$	$88,8 \pm 0,8$	$94,6 \pm 0,3$
Sonar	$75,2 \pm 4,6$	$84,3 \pm 2,9$	$84,5 \pm 4,3$	$81,2 \pm 2,9$	$82,0 \pm 4,7$
số thực, Haberman	10	325	619	618	367
số thực, Transfusion	13	959	1.879	1.878	984
số thực, Banknote	13	282	3.439	3.438	329
số thực, Pima	25	2.042	3.473	3.472	2.200
số thực, Breast	28	469	3.509	3.508	464
số thực, Magic	31	7.694	22.021	22.020	9.008
số thực, Parkinsons	67	1.276	2.276	2.275	1.057
số thực, Ionosphere	100	2.855	6.017	6.016	2.668
số thực, Spambase	172	29.753	133.515	133.514	29.869
số thực, Sonar	181	5.458	6.465	6.464	4.696

Dữ liệu	MLP- ReLU	PWL-C cộng tính	PWL-LS cộng tính	PWL-C HH
Haberman	$72,4 \pm 1,6$	$73,2 \pm 1,9$	$72,6 \pm 2,1$	$73,5 \pm 1,5$
Transfusion	$78,6 \pm 1,5$	$76,3 \pm 0,5$	$77,4 \pm 0,8$	$76,3 \pm 2,7$
Banknote	$99,9 \pm 0,1$	$99,9 \pm 0,1$	$99,5 \pm 0,3$	$99,9 \pm 0,1$
Pima	$76,7 \pm 1,7$	$76,3 \pm 1,2$	$76,5 \pm 1,5$	$76,2 \pm 1,7$
Breast	$96,8 \pm 0,8$	$96,3 \pm 0,9$	$96,0 \pm 0,7$	$95,6 \pm 1,3$
Magic	$85,7 \pm 0,2$	$84,8 \pm 0,3$	$84,4 \pm 0,3$	$84,3 \pm 1,4$
Parkinsons	$90,6 \pm 3,7$	$86,2 \pm 2,3$	$89,3 \pm 3,0$	$85,5 \pm 2,7$
Ionosphere	$88,0 \pm 2,7$	$89,7 \pm 2,0$	$87,7 \pm 3,7$	$87,0 \pm 3,3$
Spambase	$93,9 \pm 0,2$	$93,4 \pm 0,4$	$92,6 \pm 0,4$	$82,1 \pm 23,5$
Sonar	$81,9 \pm 4,4$	$80,2 \pm 4,1$	$79,8 \pm 4,3$	$76,2 \pm 2,4$
số thực, Haberman	142	64	64	145
số thực, Transfusion	225	85	85	229
số thực, Banknote	225	85	85	229
số thực, Pima	737	169	169	745
số thực, Breast	910	190	190	919
số thực, Magic	1.101	211	211	1.111
số thực, Parkinsons	4.797	463	463	4.819
số thực, Ionosphere	10.462	694	694	10.495
số thực, Spambase	30.382	1.198	1.198	30.439
số thực, Sonar	33.601	1.261	1.261	33.661

C. Nguồn dữ liệu

Mọi bộ dữ liệu đều là bản sao trên kho OpenML [49] của các bộ dữ liệu trong kho UCI [27], được tải bằng hàm `fetch_openml` của `scikit-learn` theo mã số ở Bảng PL.2. Với Breast, 16 giá trị thiếu của biến *Bare Nuclei* được thay bằng trung vị; với Ionosphere, cột thứ hai (hàng số) được loại bỏ.

Bảng PL.2. Mã số OpenML và nhãn được coi là lớp +1.

Dữ liệu	Mã số	Lớp +1	Dữ liệu	Mã số	Lớp +1
Haberman	43	2	Magic	1120	h
Transfusion	1464	2	Parkinsons	1488	2
Banknote	1462	2	Ionosphere	59	g
Pima	37	tested_positive	Spambase	44	1
Breast	15	malignant	Sonar	40	Mine
Tín dụng	42477	1 (vỡ nợ)			