

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC QUY NHƠN

HUỲNH TRỌNG PHÚC

THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC
TRUNG TUYẾN TÍNH TỪNG PHẦN VÀ ỨNG
DỤNG

ĐỀ ÁN THẠC SĨ
KHOA HỌC DỮ LIỆU

Bình Định - Năm 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC QUY NHƠN

HUỲNH TRỌNG PHÚC

THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC
TRUNG TUYẾN TÍNH TỪNG PHẦN VÀ ỨNG
DỤNG

Ngành: Khoa học dữ liệu

Mã số: 8460108

Người hướng dẫn: TS. Lê Quang Thuận

Lời cam đoan

Tôi xin cam đoan nội dung trong luận văn "**Thuật toán SVM với ánh xạ đặc trưng tuyến tính từng phần và ứng dụng**" là do bản thân thực hiện theo logic riêng dưới sự hướng dẫn của TS. Lê Quang Thuận. Các nội dung và kết quả sử dụng trong luận văn đều có trích dẫn và chú thích nguồn gốc rõ ràng.

Tác giả đề án

Huỳnh Trọng Phúc

Lời cảm ơn

Lời đầu tiên tôi xin gửi đến TS. Lê Quang Thuận lời cảm ơn sâu sắc về sự tận tình giúp đỡ của thầy đối với tôi trong suốt khóa học, đặc biệt trong quá trình làm luận văn.

Tôi xin được bày tỏ lòng biết ơn đến tất cả các thầy cô Trường Đại Học Quy Nhơn, các giảng viên Trường ĐHKHTN-ĐHQG TP.HCM đã nhiệt tình giảng dạy chúng tôi trong suốt khóa học.

Xin được cảm ơn các vị lãnh đạo và chuyên viên Phòng Đào tạo sau đại học Trường Đại Học Quy Nhơn đã tạo điều kiện thuận lợi cho tôi trong suốt quá trình học.

Tôi cũng xin được cảm ơn gia đình tôi, các đồng nghiệp và các bạn học viên Cao học khóa 25B đã hỗ trợ, động viên tôi trong suốt thời gian học.

Cuối cùng, với kiến thức còn hạn chế nên dù rất cố gắng nhưng chắc chắn luận văn còn nhiều sót. Kính mong các thầy cô và các bạn đồng nghiệp đóng góp ý kiến để luận văn còn hoàn chỉnh hơn.

Trân trọng cảm ơn!

MỤC LỤC

Lời cam đoan	
Lời cảm ơn	
Mục lục	
Danh mục các bảng	1
Danh mục các hình	2
MỞ ĐẦU	3
Tính cấp thiết của đề tài	3
Mục đích và nhiệm vụ nghiên cứu	4
Mục đích nghiên cứu	4
Nhiệm vụ nghiên cứu	5
Đối tượng và phạm vi nghiên cứu	5
Cơ sở lí luận và phương pháp nghiên cứu	6
Kết cấu của đề án	8
NỘI DUNG	9
1 KIẾN THỨC CHUẨN BỊ	9
1.1 Tập affine và tập lồi	9
1.1.1 Đường thẳng và đoạn thẳng	9
1.1.2 Tập affine	9
1.1.3 Tập lồi	11
1.1.4 Một số ví dụ về tập lồi	12
1.1.5 Các phép toán bảo toàn tính lồi	13
1.2 Siêu phẳng phân chia và siêu phẳng hỗ trợ	14
1.2.1 Định lí siêu phẳng phân chia	14

2	THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC TRƯNG TUYẾN TÍNH TỪNG PHẦN	15
2.1	Thuật toán SVM (Support Vector Machine)	15
2.1.1	Xây dựng bài toán tối ưu cho SVM	16
2.1.2	Lề cứng (Hard margin) và lề mềm - (Soft margin) . .	18
2.2	SVM với ánh xạ đặc trưng tuyến tính từng phần	18
2.2.1	Biên tuyến tính từng phần	18
2.2.2	Phương trình tuyến tính từng phần	22
2.2.3	SVM với ánh xạ đặc trưng tuyến tính từng phần . . .	24
2.2.4	Khả năng phân loại của ánh xạ đặc trưng tuyến tính từng phần	28
2.2.5	Tham số trong ánh xạ đặc trưng tuyến tính từng phần	29

Danh mục các bảng

Danh mục các hình

1	Minh họa siêu phẳng phân tách	15
2	Ý tưởng của SVM	16
3	Tập dữ liệu hình mặt trăng	19
4	Biên phân loại	20
5	Ranh giới của các vùng con	30

MỞ ĐẦU

Tính cấp thiết của đề tài

Ngày nay, nhiệm vụ phân loại trong học máy (machine learning) đóng một vai trò quan trọng trong nhiều ứng dụng thực tế, giúp giải quyết các vấn đề thực tiễn và cải thiện hiệu quả của nhiều quy trình. Ví dụ:

- **Ứng dụng trong y tế:** Trong y học, phân loại giúp xác định các bệnh, chẳng hạn như phân loại hình ảnh chẩn đoán (MRI, X-quang) để phát hiện các bệnh ung thư, bệnh tim mạch, hoặc các vấn đề sức khỏe khác. Sự chính xác trong phân loại có thể cứu sống bệnh nhân.
- **An ninh và bảo mật:** Trong nhận dạng khuôn mặt, nhận dạng vân tay, hay các hệ thống xác thực sinh trắc học, phân loại giúp xác định người dùng một cách nhanh chóng và chính xác. Điều này rất quan trọng trong bảo mật thông tin cá nhân và giao dịch.
- **Phân loại thư rác (Spam):** Trong các ứng dụng email, phân loại thư điện tử thành thư rác và thư hợp lệ là một trong những nhiệm vụ phân loại quan trọng, giúp người dùng tránh bị quấy rầy bởi các thông tin không mong muốn.
- **Xử lý ngôn ngữ tự nhiên (NLP):** Các nhiệm vụ phân loại trong NLP như phân loại cảm xúc trong văn bản, phân loại chủ đề hay phân loại văn bản theo các chủ đề cụ thể là rất quan trọng trong các ứng dụng như phân tích cảm xúc, chatbot, và các hệ thống tìm kiếm.
- **Tiếp thị và phân tích khách hàng:** Phân loại khách hàng theo các nhóm dựa trên hành vi mua sắm, sở thích hoặc mức độ gắn kết giúp các

doanh nghiệp tối ưu hóa các chiến lược marketing và gia tăng hiệu quả tiếp cận khách hàng.

- **Tự động hóa và phân tích dữ liệu lớn:** Phân loại dữ liệu là một trong những nhiệm vụ cơ bản trong phân tích dữ liệu lớn, giúp nhận diện các mẫu dữ liệu quan trọng và phân loại chúng thành các nhóm có ý nghĩa, từ đó hỗ trợ ra quyết định.
- **Quản lý rủi ro trong tài chính:** Phân loại các khoản vay là rủi ro thấp hay cao giúp các tổ chức tài chính đưa ra các quyết định cho vay, giảm thiểu rủi ro tài chính.

Các bộ phân loại tuyến tính từng phần là một mở rộng đơn giản của các bộ phân loại tuyến tính, đồng thời có khả năng xấp xỉ các ranh giới phi tuyến tính. Điều này làm cho chúng trở nên phù hợp cho các ứng dụng đòi hỏi tốc độ xử lý nhanh và ít tổn bộ nhớ, chẳng hạn như robot trinh sát nhỏ, camera thông minh, và các hệ thống nhúng.

Mục đích và nhiệm vụ nghiên cứu

Mục đích nghiên cứu

Mục đích của đề tài là nghiên cứu và phát triển một phương pháp cải tiến cho thuật toán máy vector hỗ trợ (Support Vector Machines - SVM) thông qua kỹ thuật ánh xạ đặc trưng tuyến tính từng phần (Piecewise Linear Feature Mapping - PLFM), nhằm nâng cao khả năng phân loại của mô hình trong các bài toán có đặc trưng phi tuyến. Đồng thời, đề tài hướng đến việc ứng dụng mô hình này vào các bài toán thực tế như nhận dạng hình ảnh, phân loại văn bản hoặc dữ liệu y sinh.

Nhiệm vụ nghiên cứu

Nhiệm vụ nghiên cứu của đề án bao gồm:

1. Tổng quan lý thuyết

- Tìm hiểu cơ sở lý thuyết của thuật toán SVM truyền thống
- Khảo sát các phương pháp ánh xạ đặc trưng trong học máy

2. Phân tích và xây dựng mô hình

- Trình bày nguyên lý của ánh xạ đặc trưng tuyến tính từng phần
- Tích hợp PLFM vào khung SVM để xây dựng mô hình phân loại mới

3. Thực nghiệm và đánh giá

- Triển khai mô hình trên các tập dữ liệu chuẩn
- So sánh hiệu năng với các phương pháp SVM truyền thống và các biến thể khác

4. Ứng dụng thực tế

- Đề xuất các bài toán ứng dụng phù hợp với mô hình
- Phân tích tiềm năng triển khai trong các hệ thống thực tế

Đối tượng và phạm vi nghiên cứu

Đối tượng nghiên cứu của đề tài là thuật toán máy vector hỗ trợ (SVM) được cải tiến bằng kỹ thuật ánh xạ đặc trưng tuyến tính từng phần (Piecewise Linear Feature Mapping - PLFM). Cụ thể, đề tài tập trung vào:

- Cấu trúc và nguyên lý hoạt động của SVM truyền thống
- Cách thức ánh xạ đặc trưng tuyến tính từng phần được tích hợp vào mô hình SVM
- Hiệu năng của mô hình cải tiến trong các bài toán phân loại

Phạm vi nghiên cứu của đề tài được giới hạn như sau:

- Về mặt lý thuyết: tập trung vào SVM và kỹ thuật ánh xạ đặc trưng tuyến tính từng phần, không đi sâu vào các biến thể khác như SVM kernel phi tuyến, SVM đa lớp, hay các mô hình deep learning.
- Về mặt thực nghiệm: áp dụng mô hình vào các bài toán phân loại nhị phân; sử dụng các tập dữ liệu chuẩn như UCI, MNIST hoặc các tập dữ liệu có tính phân biệt rõ ràng; so sánh hiệu năng với SVM truyền thống và một số biến thể đơn giản khác
- Về mặt ứng dụng: đề xuất ứng dụng mô hình trong các lĩnh vực như nhận dạng hình ảnh, phân loại văn bản, hoặc dữ liệu y sinh, nhưng chưa triển khai thực tế trong hệ thống sản phẩm.

Cơ sở lý luận và phương pháp nghiên cứu

Cơ sở lý luận

Đề tài được xây dựng trên nền tảng lý thuyết của các lĩnh vực sau:

- **Học máy (Machine Learning):** Là lĩnh vực nghiên cứu các thuật toán cho phép máy tính học từ dữ liệu để đưa ra dự đoán hoặc quyết định mà không cần được lập trình rõ ràng.

- **Support Vector Machines:** Là một trong những thuật toán phân loại mạnh mẽ, có khả năng tìm ra siêu phẳng tối ưu để phân tách các lớp dữ liệu.
- **Ánh xạ đặc trưng:** Là kỹ thuật chuyển dữ liệu từ không gian đầu vào sang không gian đặc trưng để làm rõ cấu trúc phân loại. Trong đó, ánh xạ tuyến tính từng phần (Piecewise Linear Feature Mapping – PLFM) là một phương pháp ánh xạ có khả năng biểu diễn các đặc trưng phi tuyến một cách hiệu quả.
- **Tối ưu hóa lồi:** Là nền tảng toán học giúp giải bài toán tối ưu trong SVM, đảm bảo tìm được nghiệm toàn cục.

Các tài liệu tham khảo bao gồm các công trình nghiên cứu về SVM, ánh xạ đặc trưng, và các ứng dụng thực tế trong phân loại dữ liệu. Đặc biệt, bài báo “Support Vector Machines with Piecewise Linear Feature Mapping” là tài liệu nền tảng cho đề tài này.

Phương pháp nghiên cứu được áp dụng bao gồm:

1. Phân tích - Tổng hợp tài liệu

- Khảo sát các tài liệu khoa học liên quan đến SVM và PLFM
- Tổng hợp các hướng tiếp cận và đánh giá ưu nhược điểm

2. Mô hình hóa toán học

- Biểu diễn thuật toán SVM với ánh xạ đặc trưng tuyến tính từng phần dưới dạng bài toán tối ưu
- Phân tích tính chất toán học của mô hình

3. Thực nghiệm mô phỏng

- Triển khai mô hình bằng ngôn ngữ lập trình Python
- Sử dụng các tập dữ liệu chuẩn để huấn luyện và kiểm thử mô hình

4. So sánh và đánh giá

- So sánh hiệu năng của mô hình với SVM truyền thống và các biến thể khác
- Đánh giá độ chính xác, độ ổn định và khả năng tổng quát hóa

5. Phân tích ứng dụng

- Đề xuất các bài toán thực tế có thể áp dụng mô hình
- Phân tích tiềm năng triển khai trong các hệ thống thông minh

Kết cấu của đề án

Ngoài phần mở đầu, kết luận, tài liệu tham khảo, phụ lục đề án có 3 chương.

- Chương 1: KIẾN THỨC CHUẨN BỊ
- Chương 2: THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC TRƯNG TUYẾN TÍNH TỪNG PHẦN
- Chương 3: ỨNG DỤNG CỦA THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC TRƯNG TUYẾN TÍNH TỪNG PHẦN

NỘI DUNG

CHƯƠNG 1: KIẾN THỨC CHUẨN BỊ

1.1. Tập affine và tập lồi

1.1.1. Đường thẳng và đoạn thẳng

Giả sử $x_1 \neq x_2$ là hai điểm trong $\mathbb{R}^n$. Các điểm có dạng $y = \theta x_1 + (1 - \theta)x_2$, trong đó $\theta \in \mathbb{R}$, tạo thành đường thẳng đi qua x_1 và x_2 . Giá trị tham số $\theta = 0$ tương ứng với $y = x_2$, và giá trị tham số $\theta = 1$ tương ứng với $y = x_1$. Các giá trị của tham số θ nằm giữa 0 và 1 tương ứng với đoạn thẳng (đóng) giữa x_1 và x_2 .

Biểu diễn y dưới dạng

$$y = x_2 + \theta(x_1 - x_2) \quad (1.1.1)$$

cho ta một cách hiểu khác: y là tổng của điểm cơ sở x_2 (tương ứng với $\theta = 0$) và vector chỉ phương $x_1 - x_2$ (chỉ từ x_2 đến x_1) được nhân với tham số θ . Do đó, θ cho biết tỉ lệ khoảng cách từ x_2 đến x_1 mà điểm y nằm trên đó. Khi θ tăng từ 0 đến 1, điểm y di chuyển từ x_2 đến x_1 ; với $\theta > 1$, điểm y nằm trên đường thẳng vượt qua x_1 .

1.1.2. Tập affine

Định nghĩa 1.1.1. (Tập affine) Một tập $C \subseteq \mathbb{R}^n$ được gọi là tập affine nếu đường thẳng đi qua bất kỳ hai điểm phân biệt nào trong C đều nằm trong C , nghĩa là với mọi $x_1, x_2 \in C$ và $\theta \in \mathbb{R}$, ta có $\theta x_1 + (1 - \theta)x_2 \in C$. Nói cách khác, C chứa tổ hợp tuyến tính của bất kỳ hai điểm nào trong C , miễn là các hệ số trong tổ hợp tuyến tính có tổng bằng một.

Ý tưởng này có thể được tổng quát hóa cho nhiều hơn hai điểm. Ta gọi

một điểm có dạng $\theta_1 x_1 + \dots + \theta_k x_k$, trong đó $\theta_1 + \dots + \theta_k = 1$, là tổ hợp affine của các điểm $x_1, \dots, x_k$. Sử dụng quy nạp từ định nghĩa của tập affine (tức là tập chứa mọi tổ hợp affine của hai điểm bất kỳ trong nó), có thể chứng minh rằng tập affine chứa mọi tổ hợp affine của các điểm trong nó: nếu $\mathcal{C}$ là tập affine, $x_1, \dots, x_k \in \mathcal{C}$, và $\theta_1 + \dots + \theta_k = 1$, thì điểm $\theta_1 x_1 + \dots + \theta_k x_k$ cũng thuộc $\mathcal{C}$.

Nếu $\mathcal{C}$ là tập affine và $x_0 \in \mathcal{C}$, thì tập

$$\mathcal{V} = \mathcal{C} - x_0 = \{x - x_0 \mid x \in \mathcal{C}\} \quad (1.1.2)$$

là một không gian con, tức là đóng với phép cộng và phép nhân với số vô hướng. Để thấy điều này, giả sử $v_1, v_2 \in \mathcal{V}$ và $\alpha, \beta \in \mathbb{R}$. Khi đó ta có $v_1 + x_0 \in \mathcal{C}$ và $v_2 + x_0 \in \mathcal{C}$, và do đó

$$\alpha v_1 + \beta v_2 + x_0 = \alpha(v_1 + x_0) + \beta(v_2 + x_0) + (1 - \alpha - \beta)x_0 \in \mathcal{C}, \quad (1.1.3)$$

vì $\mathcal{C}$ là tập affine và $\alpha + \beta + (1 - \alpha - \beta) = 1$. Ta kết luận rằng $\alpha v_1 + \beta v_2 \in \mathcal{V}$ vì $\alpha v_1 + \beta v_2 + x_0 \in \mathcal{C}$.

Do đó, tập affine $\mathcal{C}$ có thể được biểu diễn dưới dạng

$$\mathcal{C} = \mathcal{V} + x_0 = \{v + x_0 \mid v \in \mathcal{V}\}, \quad (1.1.4)$$

tức là một không gian con cộng với một điểm dịch chuyển. Không gian con $\mathcal{V}$ gắn với tập affine $\mathcal{C}$ không phụ thuộc vào việc chọn x_0 , vì vậy x_0 có thể được chọn là bất kỳ điểm nào trong $\mathcal{C}$. Ta định nghĩa chiều của tập affine $\mathcal{C}$ là chiều của không gian con $\mathcal{V} = \mathcal{C} - x_0$, trong đó x_0 là một phần tử bất kỳ của $\mathcal{C}$.

Tập hợp tất cả các tổ hợp affine của các điểm trong một tập $C \subseteq \mathbb{R}^n$ được gọi là *bao affine* (affine hull) của C , và còn được ký hiệu là $\mathbf{aff} C$:

$$\mathbf{aff} C = \{\theta_1 x_1 + \cdots + \theta_k x_k \mid x_1, \dots, x_k \in C, \theta_1 + \cdots + \theta_k = 1\}.$$

Bao affine là tập affine nhỏ nhất chứa C , theo nghĩa sau: nếu S là bất kỳ tập affine nào thỏa $C \subseteq S$, thì $\mathbf{aff} C \subseteq S$.

1.1.3. Tập lồi

Định nghĩa 1.1.2. (*Tập lồi*) Một tập C được gọi là *tập lồi* nếu đoạn thẳng nối giữa hai điểm bất kỳ trong C đều nằm trong C ; tức là, với mọi $x_1, x_2 \in C$ và mọi θ thỏa $0 \leq \theta \leq 1$, ta có: $\theta x_1 + (1 - \theta)x_2 \in C$.

Mọi *tập affine* cũng là tập lồi, bởi vì nó chứa toàn bộ đường thẳng đi qua hai điểm phân biệt bất kỳ trong nó, và do đó cũng chứa đoạn thẳng nối hai điểm đó.

Định nghĩa 1.1.3. (*Tổ hợp lồi*) Một điểm được gọi là *tổ hợp lồi* (convex combination) của các điểm $x_1, x_2, \dots, x_k$ nếu nó có thể được viết dưới dạng $x = \theta_1 x_1 + \theta_2 x_2 + \cdots + \theta_k x_k$, với các hệ số $\theta_1, \theta_2, \dots, \theta_k$ thỏa mãn

$$\theta_1 + \theta_2 + \cdots + \theta_k = 1, \quad \text{và} \quad \theta_i \geq 0, \quad \forall i = 1, 2, \dots, k.$$

Tương tự như trong trường hợp các tập affine, có thể chứng minh rằng một tập là lồi khi và chỉ khi nó chứa mọi tổ hợp lồi của các điểm của chính nó. Một tổ hợp lồi có thể được hiểu như một hỗn hợp hay trung bình có trọng số của các điểm, trong đó θ_i là tỷ lệ (hay phần đóng góp) của x_i trong hỗn hợp.

Định nghĩa 1.1.4. (*Bao lồi - Convex hull*) Bao lồi của một tập $\mathcal{C}$, ký hiệu là $\mathbf{conv} \mathcal{C}$, được định nghĩa là tập hợp tất cả các tổ hợp lồi của các điểm trong $\mathcal{C}$:

$$\mathbf{conv} \mathcal{C} = \{ \theta_1 x_1 + \cdots + \theta_k x_k \mid x_i \in \mathcal{C}, \theta_i \geq 0, \\ i = 1, \dots, k, \theta_1 + \cdots + \theta_k = 1 \}.$$

Như tên gọi, $\mathbf{conv} \mathcal{C}$ luôn là một tập lồi. Đây cũng là tập lồi nhỏ nhất chứa $\mathcal{C}$, tức là, nếu $\mathcal{B}$ là một tập lồi bất kỳ thỏa $\mathcal{C} \subseteq \mathcal{B}$, thì $\mathbf{conv} \mathcal{C} \subseteq \mathcal{B}$.

1.1.4. Một số ví dụ về tập lồi

Định nghĩa 1.1.5. (*Siêu phẳng - Hyperplane*) Một *siêu phẳng* trong không gian n -chiều là tập hợp các điểm thỏa mãn phương trình

$$a_1 x_1 + a_2 x_2 + \cdots + a_n x_n = \mathbf{a}^T \mathbf{x} = b,$$

trong đó $b, a_i \in \mathbb{R}$, $i = 1, 2, \dots, n$.

Định nghĩa 1.1.6. (*Nửa không gian - Halfspace*) Một *nửa không gian* trong không gian n -chiều là tập hợp các điểm thỏa mãn bất phương trình

$$a_1 x_1 + a_2 x_2 + \cdots + a_n x_n = \mathbf{a}^T \mathbf{x} \leq b,$$

trong đó $b, a_i \in \mathbb{R}$, $i = 1, 2, \dots, n$.

Định nghĩa 1.1.7. (*Hình cầu theo chuẩn - Norm ball*) Cho một tâm x_c , một bán kính $r > 0$, và một chuẩn (norm) dùng để xác định khoảng cách giữa các điểm. Hình cầu theo chuẩn tương ứng là tập hợp các điểm thỏa mãn:

$$B(x_c, r) = \{ x \mid \|x - x_c\|_2 \leq r \} = \{ x_c + ru \mid \|u\|_2 \leq 1 \}.$$

Định nghĩa 1.1.8. (*Đa diện - Polyhedra*) Một *đa diện* được định nghĩa là tập nghiệm của một số hữu hạn các phương trình và bất phương trình tuyến tính:

$$P = \{x \mid a_j^T x \leq b_j, j = 1, \dots, m, c_j^T x = d_j, j = 1, \dots, p\}. \quad (2.5)$$

Có thể thấy một đa diện chính là giao của hữu hạn các nửa không gian và siêu phẳng. Các *tập affine* (ví dụ: không gian con tuyến tính, siêu phẳng, đường thẳng), *tia*, *đoạn thẳng*, và *nửa không gian* đều là các *đa diện*.

1.1.5. Các phép toán bảo toàn tính lồi

1.1.5.1. Phép giao

Tính lồi được bảo toàn dưới phép giao, nếu S_1 và S_2 là các tập lồi, thì $S_1 \cap S_2$ cũng là tập lồi. Tính chất này được mở rộng cho giao của vô hạn tập hợp: nếu mỗi S_α là tập lồi với mọi $\alpha \in A$, thì $\bigcap_{\alpha \in A} S_\alpha$ là tập lồi (các *không gian con tuyến tính*, *tập affine*, cũng đều đóng dưới phép giao tùy ý).

Ví dụ, một *đa diện* (polyhedron) là giao của các *nửa không gian* (halfspace) và *siêu phẳng* (hyperplane), vốn đều là các tập lồi, do đó đa diện cũng là một tập lồi.

1.1.5.2. Hàm affine

Định nghĩa 1.1.9. (*Hàm affine*) Một hàm $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ được gọi là *hàm affine* nếu nó là tổng của một *hàm tuyến tính* và một *hằng số*, tức là nó có dạng $f(x) = Ax + b$, trong đó $A \in \mathbb{R}^{m \times n}$ và $b \in \mathbb{R}^m$.

Giả sử $S \subseteq \mathbb{R}^n$ là một *tập lồi*, và $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ là một hàm affine. Khi đó,

ảnh của tập $\mathcal{S}$ qua ánh xạ f được định nghĩa là

$$f(\mathcal{S}) = \{f(x) \mid x \in \mathcal{S}\}.$$

là tập lồi. Tương tự, nếu $f : \mathbb{R}^k \rightarrow \mathbb{R}^n$ là một hàm affine, *nghịch ảnh* của tập $\mathcal{S}$ qua ánh xạ f được định nghĩa là

$$f^{-1}(\mathcal{S}) = \{x \mid f(x) \in \mathcal{S}\}.$$

cũng là tập lồi.

1.2. Siêu phẳng phân chia và siêu phẳng hỗ trợ

1.2.1. Định lý siêu phẳng phân chia

Định lý 1.2.1. Giả sử $\mathcal{C}$ và $\mathcal{D}$ là hai tập lồi khác rỗng và rời nhau, tức là $\mathcal{C} \cap \mathcal{D} = \emptyset$. Khi đó tồn tại $\mathbf{a} \neq 0$ và b sao cho

$$\mathbf{a}^T \mathbf{x} \leq b, \quad \forall \mathbf{x} \in \mathcal{C}$$

và

$$\mathbf{a}^T \mathbf{x} \geq b, \quad \forall \mathbf{x} \in \mathcal{D}.$$


Nói cách khác, hàm affine $\mathbf{a}^T \mathbf{x} - b$ là không dương trên $\mathcal{C}$ và không âm trên $\mathcal{D}$. Siêu phẳng $\{\mathbf{x} \mid \mathbf{a}^T \mathbf{x} = b\}$ được gọi là **siêu phẳng phân chia** hai tập $\mathcal{C}$ và $\mathcal{D}$.

Hes lo a^2

CHƯƠNG 2: THUẬT TOÁN SVM VỚI ÁNH XẠ ĐẶC TRƯNG TUYẾN TÍNH TỪNG PHẦN

2.1. Thuật toán SVM (Support Vector Machine)


SVM là một thuật toán học máy có giám sát được sử dụng cho các tác vụ phân loại và hồi quy. *SVM* hoạt động bằng cách tìm một siêu phẳng trong không gian nhiều chiều để phân loại dữ liệu thành các lớp khác nhau. *SVM* có thể xử lý cả các vấn đề phân loại tuyến tính và phi tuyến tính bằng cách sử dụng các đặc trưng *hạt nhân* - *kernel* khác nhau. Nó được sử dụng rộng rãi trong các tác vụ như phân loại hình ảnh, phân loại văn bản, . . .



Hình 1: Một ví dụ với hai lớp có thể phân tách bằng siêu phẳng. Đường màu cam là nghiệm bình phương tối thiểu, phân loại sai một trong các điểm huấn luyện. Ngoài ra còn có hai siêu phẳng phân tách màu xanh được tìm thấy bởi thuật toán học perceptron với các điểm khởi đầu ngẫu nhiên khác nhau.

Xét bài toán phân chia hai lớp dữ liệu, giả sử rằng có hai lớp dữ liệu được mô tả bởi các điểm (véctơ đặc trưng) trong không gian nhiều chiều, hơn nữa, hai lớp dữ liệu này là có thể phân tách tuyến tính, tức là tồn tại một siêu phẳng

phân chia chính xác hai lớp đó. Hãy tìm một siêu phẳng phân chia hai lớp đó, tức tất cả các điểm thuộc một lớp nằm về cùng một phía của siêu phẳng đó và ngược phía với toàn bộ các điểm thuộc lớp còn lại. Hình 1 cho ta ví dụ về vô số nghiệm (tức đường thẳng phân chia) cho bài toán phân loại trên.



Hình 2: *Lề (Margin)* của một lớp được định nghĩa là khoảng cách từ các điểm gần nhất của lớp đó tới mặt phân chia. **(a)** Minh họa về một phân loại chưa tốt khi khoảng cách từ điểm màu đỏ tới mặt phân chia là ngắn hơn. **(b)** Minh họa về một phân loại tốt (đường màu đen liền nét) với các điểm màu xanh và đỏ nằm ở hai bên mặt phân chia, và lề của hai lớp là bằng nhau.

2.1.1. Xây dựng bài toán tối ưu cho SVM

Giả sử rằng các cặp dữ liệu trong tập huấn luyện là $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_n, y_n)$ với vectơ $\mathbf{x}_i \in \mathbb{R}^d$ thể hiện đầu vào của một điểm dữ liệu và y_i là nhãn của điểm dữ liệu đó, d là số chiều của dữ liệu và n là số điểm dữ liệu. Giả sử rằng nhãn của mỗi điểm dữ liệu được xác định bởi $y_i = 1$ hoặc $y_i = -1$. Thêm nữa, giả sử mặt phân chia có phương trình là $\mathbf{w}^T \mathbf{x} + b = 0$, với cặp dữ liệu $(\mathbf{x}_n, y_n)$ bất kỳ, khoảng cách từ điểm đó tới mặt phân chia là:

$$\frac{y_n(\mathbf{w}^T \mathbf{x}_n + b)}{\|\mathbf{w}\|_2}, \quad (2.1.1)$$

Từ đó, lề (margin) của mặt phân chia được định nghĩa là khoảng cách từ điểm

gần nhất tới mặt phân chia (tính ở cả hai lớp), tức là:

$$\min_n \frac{y_n(\mathbf{w}^T \mathbf{x}_n + b)}{\|\mathbf{w}\|_2}, \quad (2.1.2)$$

Bài toán tối ưu của SVM tức là tìm $\mathbf{w}$ và b sao cho lề đạt giá trị lớn nhất:

$$\arg \max_{\mathbf{w}, b} \left\{ \min_n \frac{y_n(\mathbf{w}^T \mathbf{x}_n + b)}{\|\mathbf{w}\|_2} \right\}, \quad (2.1.3)$$

Có thể thấy rằng nếu thay vectơ hệ số $\mathbf{w}$ bởi $k\mathbf{w}$ và b bởi kb với $k > 0$ thì mặt phân chia không thay đổi. Do đó, ta có thể giả sử rằng với những điểm nằm gần mặt phân chia nhất, ta có:

$$y_n(\mathbf{w}^T \mathbf{x}_n + b) = 1 \quad (2.1.4)$$

Như vậy, với mọi n ta luôn có: $y_n(\mathbf{w}^T \mathbf{x}_n + b) \geq 1$

Do đó, bài toán tối ưu này có thể đưa về dạng

$$\begin{aligned} & \arg \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 \\ & \text{thỏa mãn: } 1 - y_n(\mathbf{w}^T \mathbf{x}_n + b) \leq 0, \forall n = 1, 2, \dots, n \end{aligned} \quad (2.1.5)$$

Không mất tính tổng quát, ta có thể lấy nghịch đảo hàm mục tiêu, bình phương nó để được một hàm khả vi, và nhân với $\frac{1}{2}$ để công thức đạo hàm đẹp hơn.


2.1.2. *Lề cứng (Hard margin) và lề mềm - (Soft margin)*

2.2. SVM với ánh xạ đặc trưng tuyến tính từng phần

2.2.1. *Biên tuyến tính từng phần*

Trong vấn đề phân loại hai lớp, miền thường được phân chia thành hai phần bởi một biên, ví dụ như một siêu phẳng được tạo ra bởi các phương pháp phân loại tuyến tính, theo dữ liệu đầu vào $x \in \mathbb{R}^n$ và nhãn tương ứng $y \in \{+1, -1\}$. Các bộ phân loại tuyến tính đã được nghiên cứu trong nhiều năm, tuy nhiên, khả năng phân loại của chúng quá hạn chế và cần có các bộ phân loại phi tuyến. Trong đề án này, thuật ngữ khả năng phân loại của một bộ phân loại có nghĩa là tính linh hoạt của các loại và hình dạng có thể có của biên phân loại. Ví dụ, một bộ phân loại tuyến tính chỉ có thể cung cấp một biên tuyến tính, đó là một tập hợp affine, tức là một siêu phẳng, và do đó khả năng phân loại của nó không đủ cho nhiều ứng dụng. Theo một số quan điểm, mở rộng đơn giản nhất cho một tập hợp affine là một tập hợp tuyến tính từng phần, cung cấp một biên tuyến tính từng phần. Như tên gọi, một tập hợp tuyến tính từng phần bằng với một tập hợp affine trong mỗi vùng con của miền, và các vùng con phân chia miền.

Xét tập dữ liệu hai mặt trăng được hiển thị trong Hình 3, trong đó các điểm thuộc hai lớp được đánh dấu bằng các ngôi sao màu xanh lá cây và các dấu chéo màu đỏ. Hai lớp này không thể được phân tách bởi một biên tuyến tính và chúng ta có thể sử dụng một biên tuyến tính từng phần (PWL), được hiển thị bằng các đường màu đen, để phân loại hai tập dữ liệu này rất tốt. Tập hợp PWL này, được ký hiệu là $\mathcal{B}$, bao gồm ba đoạn. Mỗi đoạn có thể được định nghĩa là một đường thẳng bị giới hạn trong một vùng con. Ví dụ, chúng ta có thể phân chia miền thành $\Omega_1 = \{x : 0 \leq x(2) \leq \frac{1}{3}\}$,



Hình 3: Tập dữ liệu hình mặt trăng. Các điểm trong hai lớp được đánh dấu bằng các ngôi sao và các dấu chéo, tương ứng; ranh giới phân loại được hiển thị bằng các đường liền nét.

$\Omega_2 = \{x : \frac{1}{3} \leq x(2) \leq \frac{2}{3}\}$, $\Omega_3 = \{x : \frac{2}{3} \leq x(2) \leq 1\}$, trong đó $x(i)$ là thành phần thứ i của x . Sau đó, $\mathcal{B}$ có thể được định nghĩa là


$$\mathcal{B} = \bigcup_{k=1}^3 \{x : c_k^T x + d_k = 0, x \in O_k\},$$

trong đó $c_k \in \mathbb{R}^2$, $d_k \in \mathbb{R}$ định nghĩa đường thẳng trong mỗi vùng con, như được hiển thị trong Hình 4.

Để thuận tiện cho việc diễn đạt, định nghĩa của tập hợp tuyến tính từng phần được đưa ra dưới đây.

Định nghĩa 2.2.1. Nếu một tập hợp $\mathcal{B}$ được định nghĩa trong miền $\Omega \subseteq \mathbb{R}^n$ thỏa mãn hai điều kiện sau:

- (i) Miền Ω được phân chia thành các đa diện hữu hạn $\Omega_1, \Omega_2, \dots, \Omega_K$, tức



Hình 4: Biên phân loại bị giới hạn trong mỗi vùng con, ranh giới tuyến tính từng phần tương ứng với một đường thẳng.

là $\Omega = \bigcup_{k=1}^K \Omega_k$ và $\overset{\circ}{\Omega}_k \cap \overset{\circ}{\Omega}_l = \emptyset, \forall k \neq l$, trong đó $\overset{\circ}{\Omega}_k$ là phần trong của Ω_k .

- (ii) Trong mỗi vùng con, $\mathcal{B}$ bằng với một tập hợp tuyến tính, tức là với mỗi k , tồn tại $c_k \in \mathbb{R}^n, d_k \in \mathbb{R}$ sao cho $\mathcal{B} \cap \Omega_k = \{x : c_k^T x + d_k = 0\}$.

Một tập hợp affine cung cấp một bộ phân loại tuyến tính, có thể được viết như là nghiệm của một phương trình tuyến tính $f(x) = 0$. Do đó, trong một vấn đề phân loại tuyến tính, người ta thường tìm kiếm một hàm tuyến tính $f(x)$ để phân loại một điểm bằng dấu của giá trị hàm, tức là, $\text{sign}\{f(x)\}$. Tương tự, một tập hợp **tuyến tính từng phần (PWL)** cung cấp một biên tuyến tính từng phần và nó có thể được biểu diễn như là tập nghiệm của một phương trình tuyến tính từng phần, được đảm bảo bởi định lý sau:

Định lý 2.2.1. Mọi tập hợp tuyến tính từng phần $\mathcal{B}$ đều có thể được biểu diễn

như là nghiệm của một phương trình tuyến tính từng phần.

Chứng minh. Theo các ký hiệu trong Định nghĩa 2.2.1, giả sử số các đa diện xác định $\mathcal{B}$ là K và các đa diện này được biểu diễn dưới dạng $\Omega_k = \{x : a_{ki}^T x + b_{ki} \leq 0, \forall 1 \leq i \leq I_k\}$, trong đó I_k là số các bất đẳng thức tuyến tính xác định Ω_k . Sau đó, ta xây dựng hàm sau:

$$f(x) = \min_{1 \leq k \leq K} \left\{ \max \left\{ |c_k^T x + d_k|, \max_{1 \leq i \leq I_k} \{a_{ki}^T x + b_{ki}\} \right\} \right\}. \quad (2.2.1)$$

Vì hàm $\max$ và hàm giá trị tuyệt đối đều liên tục và tuyến tính từng phần, ta có thể xác nhận rằng hàm (2.2.1) là một hàm PWL liên tục. Tiếp theo, ta cần chứng minh rằng $\mathcal{B} = \{x : f(x) = 0\}$.

Đầu tiên, ta phải chứng minh $\mathcal{B} \subseteq \{x : f(x) = 0\}$. Lấy một điểm tùy ý trong $\mathcal{B}$, ký hiệu là x_0 . Theo định nghĩa của tập hợp tuyến tính từng phần, ta có thể tìm một chỉ số k_0 sao cho $x_0 \in \Omega_{k_0}$ và $c_{k_0}^T x_0 + d_{k_0} = 0$. Lại có

$$\max_{1 \leq i \leq I_{k_0}} \{a_{k_0 i}^T x_0 + b_{k_0 i}\} \leq 0,$$

Do đó

$$\max \left\{ |c_k^T x + d_k|, \max_{1 \leq i \leq I_k} \{a_{ki}^T x + b_{ki}\} \right\} = 0,$$

trong đó I_{k_0} là số các ràng buộc xác định đa diện Ω_{k_0} . Vì $\Omega_1, \Omega_2, \dots, \Omega_K$ tạo thành một phân hoạch của miền nên $\overset{\circ}{\Omega}_k \cap \overset{\circ}{\Omega}_l = \emptyset, \forall k \neq l$. Do đó, $x_0 \notin \overset{\circ}{\Omega}_k, \forall k \neq k_0$, tức là

$$\max_{1 \leq i \leq I_k} \{a_{ki}^T x_0 + b_{ki}\} \geq 0, \forall k \neq k_0,$$

từ đó suy ra

$$\begin{aligned} & \max \left\{ |c_k^T x_0 + d_k|, \max_{1 \leq i \leq I_k} \{a_{ki}^T x_0 + b_{ki}\} \right\} \\ & \geq \max \left\{ |c_{k_0}^T x_0 + d_{k_0}|, \max_{1 \leq i \leq I_{k_0}} \{a_{k_0 i}^T x_0 + b_{k_0 i}\} \right\} = 0, \end{aligned}$$

và

$$f(x_0) = \max \left\{ |c_{k_0}^T x_0 + d_{k_0}|, \max_{1 \leq i \leq I_{k_0}} \{a_{k_0 i}^T x_0 + b_{k_0 i}\} \right\} = 0$$

Suy ra $\mathcal{B} \subseteq \{x : f(x) = 0\}$.

Tiếp theo, ta chứng minh rằng $\{x : f(x) = 0\} \subseteq B$. Giả sử $x_0 \in \{x : f(x) = 0\}$, tức là $f(x_0) = 0$. Khi đó tồn tại ít nhất một chỉ số $k_0 \in \{1, 2, \dots, K\}$ sao cho

$$\max \left\{ |c_{k_0}^T x_0 + d_{k_0}|, \max_{1 \leq i \leq I_{k_0}} \{a_{k_0 i}^T x_0 + b_{k_0 i}\} \right\} = 0.$$

Rõ ràng, $c_{k_0}^T x_0 + d_{k_0} = 0$ và $a_{k_0 i}^T x_0 + b_{k_0 i} \leq 0, \forall 1 \leq i \leq I_{k_0}$, tức là $x_0 \in \Omega_{k_0}$. Từ đó, có thể kết luận rằng $x_0 \in \mathcal{B} \cap \Omega_{k_0} \subseteq \mathcal{B}$ và do đó $\{x : f(x) = 0\} \subseteq \mathcal{B}$.

Cuối cùng, ta được $\mathcal{B} = \{x : f(x) = 0\}$, tức là bất kỳ tập hợp tuyến tính từng phần nào cũng có thể được biểu diễn như là tập nghiệm của một phương trình tuyến tính từng phần liên tục. $\square$

2.2.2. Phương trình tuyến tính từng phần

Từ các công thức $|t| = \max\{t, -t\}, \forall t \in \mathbb{R}$ và $\max\{t_1, \max\{t_2, t_3\}\} = \max\{t_1, t_2, t_3\}, \forall t_1, t_2, t_3 \in \mathbb{R}$, ta viết lại (2.2.1) dưới dạng công thức min-max như sau:

$$\min_{1 \leq k \leq K} \left\{ \max \{c_k^T x + d_k, -c_k^T x - d_k, a_{k1}^T x + b_{k1}, \dots, a_{kI_k}^T x + b_{kI_k}\} \right\}.$$

Sử dụng công thức min-max, một bộ phân loại tuyến tính từng phần có thể được xây dựng. Vấn đề xác định các tham số có thể được đặt ra như một bài toán tối ưu không lồi và không khả vi của việc tối thiểu hóa hàm mất mát của các điểm bị phân loại sai. Tuy nhiên, vì bài toán tối ưu liên quan rất khó giải, số lượng các vùng con bị giới hạn ở một số nhỏ. Ví dụ, trong [8], chỉ các trường hợp với $K \leq 5$ được xem xét trong thí nghiệm số. Để thu được các tham số một cách hiệu quả và đạt được khả năng tổng quát hóa tốt, trong đề án này, chúng tôi áp dụng kỹ thuật **Máy vector hỗ trợ (SVM)**. Để xây dựng một SVM mong muốn, ta cần một công thức khác được biến đổi từ (2.2.1) dựa trên những điều sau:

Bổ đề 2.2.1 (Định lý 1, Wang and Sun (18)). *Cho hàm số $f(x) : \mathbb{R}^n \rightarrow \mathbb{R}$*

$$f(x) = \max_{1 \leq k \leq K} \left\{ \min_{1 \leq i \leq I_k} \{a_{ki}^T x + b_{ki}\} \right\}$$

tồn tại M hàm cơ sở $\phi_m(x)$ với các tham số $w_m \in \mathbb{R}$, $p_{mi} \in \mathbb{R}^n$ và $q_{mi} \in \mathbb{R}$ sao cho

$$f(x) = \sum_{m=1}^M w_m \phi_m(x),$$

trong đó

$$\phi_m(x) = \max\{p_{m0}^T x + q_{m0}, p_{m1}^T x + q_{m1}, \dots, p_{mn}^T x + q_{mn}\}.$$

Theo Bổ đề 2.2.1, Định lý 2.2.1 và công thức $\min_k \max_i \{t_{ik}\} = -\max_k \min_i \{-t_{ik}\}$, ta nhận được một công thức các hàm số tuyến tính từng phần khác. Kết quả này được mô tả trong Định lý sau đây, điều này làm cho SVM có thể áp dụng để xây dựng các bộ phân loại tuyến tính từng phần.

Định lý 2.2.2. Mọi tập tuyến tính từng phần $\mathcal{B}$ đều có thể được biểu diễn như là nghiệm của phương trình tuyến tính từng phần, tức là $\mathcal{B} = \{x : f(x) = 0\}$, trong đó, $f(x)$ thỏa

$$f(x) = \sum_{m=1}^M w_m \phi_m(x), \quad (2.2.2)$$

và

$$\phi_m(x) = \max\{p_{m0}^T x + q_{m0}, p_{m1}^T x + q_{m1}, \dots, p_{mn}^T x + q_{mn}\}. \quad (2.2.3)$$

2.2.3. SVM với ánh xạ đặc trưng tuyến tính từng phần

Biểu diễn bộ phân loại tuyến tính từng phần như một tổ hợp tuyến tính của các hàm cơ sở cho phép sử dụng kỹ thuật SVM để xác định các hệ số tuyến tính của (2.2.2). SVM với ánh xạ đặc trưng tuyến tính từng phần cũng có thể được coi là một mạng nơ-ron nhiều lớp (MLP) với các lớp ẩn. Mối quan hệ giữa ánh xạ đặc trưng của SVM và lớp ẩn của MLP đã được mô tả trong [20]. Sử dụng hàm tuyến tính từng phần (2.2.3) làm ánh xạ đặc trưng, chúng ta có thể thiết lập một SVM cung cấp biên phân loại tuyến tính từng phần. Ký hiệu $\tilde{p}_{mi} = p_{mi} - p_{m0}$, $\tilde{q}_{mi} = q_{mi} - q_{m0}$. Công thức (2.2.3) có thể được biến đổi tương đương thành

$$\phi_m(x) = p_{m0}^T x + q_{m0} + \max\{0, \tilde{p}_{m1}x + \tilde{q}_{m1}, \dots, \tilde{p}_{mn}x + \tilde{q}_{mn}\}.$$

Ký hiệu thành phần thứ i của x là $x(i)$, chúng ta sử dụng ánh xạ đặc trưng tuyến tính từng phần sau đây trong không gian n chiều:

$$\phi(x) = [\phi_1(x), \phi_2(x), \dots, \phi_M(x)]^T,$$

trong đó

$$\phi_m(x) = \begin{cases} x(m), & m = 1, \dots, n, \\ \max\{0, p_{m1}^T x + q_{m1}, \dots, p_{mn}^T x + q_{mn}\}, & m = n + 1, \dots, M. \end{cases} \quad (2.2.4)$$

Ta có thể xây dựng một loạt các SVM với ánh xạ đặc trưng tuyến tính từng phần, được gọi là PWL-SVMs. Ví dụ, một ánh xạ đặc trưng tuyến tính từng phần có thể được áp dụng trong C-SVM [21] và ta có công thức sau, được gọi là PWL-C-SVM:

$$\min_{\mathbf{w}, \mathbf{w}_0, e} \quad \frac{1}{2} \sum_{m=1}^M \mathbf{w}_m^2 + \gamma \sum_{k=1}^N e_k$$

sao cho:

$$y_k \left[\mathbf{w}_0 + \sum_{m=1}^M \mathbf{w}_m \phi_m(x_k) \right] \geq 1 - e_k, \quad \forall k,$$

$$e_k \geq 0, \quad k = 1, 2, \dots, N, \quad (2.2.5)$$

trong đó $x_k \in \mathbb{R}^n, k = 1, 2, \dots, N$ là các dữ liệu đầu vào, $y_k \in \{+1, -1\}$ là các nhãn tương ứng, và ánh xạ đặc trưng $\phi(x) = [\phi_1(x), \phi_2(x), \dots, \phi_M(x)]^T$ có dạng như trong (2.2.4). Để tránh nhầm lẫn với các tham số trong ánh xạ đặc trưng, trong đề án này, ta sử dụng ký hiệu w_0 để chỉ *bias term* trong SVMs.

Bài toán đối ngẫu là:

$$\max_{\alpha} \quad -\frac{1}{2} \sum_{k=1}^N \sum_{l=1}^N y_k y_l \kappa(x_k, x_l) \alpha_k \alpha_l + \sum_{k=1}^N \alpha_k$$

sao cho

$$\sum_{k=1}^N \alpha_k y_k = 0, \quad 0 \leq \alpha_k \leq \gamma, \quad k = 1, 2, \dots, N. \quad (2.2.6)$$

trong đó α là biến đối ngẫu và hạt nhân là

$$\kappa(x_k, x_l) = \phi(x_k)^T \phi(x_l) = \sum_{m=1}^M \phi_m(x_k) \phi_m(x_l). \quad (2.2.7)$$

Từ bài toán nguyên thủy (2.2.5), ta có bộ phân loại tuyến tính từng phần

$$\text{sign}(\mathbf{w}^T \phi(x) + \mathbf{w}_0). \quad (2.2.8)$$

Số lượng biến trong (2.2.5) là $M + N + 1$, trong khi ở bài toán đối ngẫu (2.2.6) số lượng biến là N , do đó ta ưu tiên giải (2.2.6) để có bộ phân loại sau

$$\text{sign} \left(\sum_{k=1}^N \alpha_k y_k \kappa(x, x_k) + \mathbf{w}_0 \right).$$

Để xây dựng bộ phân loại sử dụng dạng đối ngẫu trên, cần lưu trữ $\alpha_k, x_k, \mathbf{w}_0$ và đối với (2.2.8) ta chỉ cần nhớ $\mathbf{w}_m, \mathbf{w}_0$. Do đó, ta giải (2.2.6) để thu được các biến đối ngẫu và sau đó tính $\mathbf{w}$ bằng

$$\mathbf{w}_m = \sum_{k=1}^N \alpha_k y_k \phi_m(x_k)$$

và sử dụng (2.2.8) để phân loại.

Sử dụng ánh xạ đặc trưng tuyến tính từng phần trong SVM, ta có một bộ phân loại cung cấp biên phân loại tuyến tính từng phần và hưởng lợi từ các ưu điểm của SVMs. Trong [13], các nhà nghiên cứu đã xây dựng một bộ phân loại tuyến tính từng phần sử dụng SVM và thu được kết quả tốt. Tuy nhiên, phương pháp của họ chỉ xử lý được các trường hợp phân tách được và còn một số vấn đề quan trọng chưa được giải quyết, bao gồm "*làm thế nào để định nghĩa biên mềm (soft margins) hợp lý?*" và "*làm thế nào để mở rộng cho tập dữ liệu không phân tách?*" như đã đề cập trong [13]. Sử dụng ánh xạ đặc trưng tuyến tính từng phần, chúng ta đã thành công xây dựng một PWL-SVM, cung cấp biên phân loại tuyến tính từng phần và có thể xử lý bất kỳ loại dữ liệu nào.

Tương tự, ta có thể sử dụng ánh xạ đặc trưng tuyến tính từng phần trong SVM bình phương tối thiểu (LS-SVM [22–24]) và thu được PWL-LS-SVM sau:

$$\min_{\mathbf{w}, \mathbf{w}_0, e} \quad \frac{1}{2} \sum_{m=1}^M \mathbf{w}_m^2 + \gamma \frac{1}{2} \sum_{k=1}^N e_k^2$$

sao cho:

$$y_k \left[\mathbf{w}_0 + \sum_{m=1}^M \mathbf{w}_m \phi_m(x_k) \right] = 1 - e_k, \quad k = 1, 2, \dots, N. \quad (2.2.9)$$

Bài toán đối ngẫu của (2.2.9) là một phương trình tuyến tính của α , $\mathbf{w}_0$, tức là

$$\begin{bmatrix} 0 & y^T \\ y & K + \frac{\mathbf{I}}{\gamma} \end{bmatrix} \begin{bmatrix} \mathbf{w}_0 \\ \alpha \end{bmatrix} = \begin{bmatrix} 0 \\ \mathbf{1} \end{bmatrix}, \quad (2.2.10)$$

trong đó $\mathbf{I} \in \mathbb{R}^{N \times N}$ là ma trận đơn vị, $\mathbf{1} \in \mathbb{R}^N$ là vector với các thành phần

bằng một, $\alpha \in \mathbb{R}^N$ là biến đối ngẫu, $K_{kl} = y_k y_l \kappa(x_k, x_l)$ và hạt nhân giống như (2.2.7). Số lượng biến liên quan trong bài toán nguyên thủy (2.2.9) và bài toán đối ngẫu (2.2.10) là $M + 1$ và $N + 1$, tương ứng. Do đó, chúng ta ưu tiên giải (2.2.9) để xây dựng bộ phân loại khi $M \leq N$. Ngược lại, tức là khi $M > N$, chúng ta giải (2.2.10) để thu được các biến đối ngẫu α_k , sau đó tính các hệ số w_m và sử dụng dạng nguyên thủy làm bộ phân loại.

2.2.4. Khả năng phân loại của ánh xạ đặc trưng tuyến tính từng phần

SVM với ánh xạ đặc trưng tuyến tính từng phần (PWL) tạo ra một ranh giới tuyến tính từng phần và thừa hưởng các đặc tính tốt của SVM. Khả năng phân loại của PWL-SVM liên quan đến công thức cụ thể của $\phi_m(x)$.

Công thức đơn giản nhất là

$$\phi_m(x) = \max\{0, x(i_m) - q_m\}, \quad (2.2.11)$$

trong đó $q_m \in \mathbb{R}$ và $i_m \in \{1, \dots, n\}$ biểu thị thành phần được sử dụng trong $\phi_m(x)$. Sử dụng (2.2.11) làm ánh xạ đặc trưng, một bộ phân loại tuyến tính từng phần cộng có thể được xây dựng. Các điểm thay đổi của ranh giới phân loại tuyến tính từng phần nên được đặt tại các ranh giới của các vùng con và các ranh giới được cung cấp bởi (2.2.11) bị giới hạn là các đường song song với một trong các trục.

Vì các ranh giới của các vùng con được định nghĩa bởi (2.2.11) không đủ linh hoạt, một số bộ phân loại mong muốn không thể đạt được. Để mở rộng khả năng phân loại, ta nên mở rộng (2.2.11) thành

$$\phi_m(x) = \max\{0, p_m^T x - q_m\}, \quad (2.2.12)$$

trong đó $p_m \in \mathbb{R}^n, q_m \in \mathbb{R}$. Công thức này được gọi là một siêu phẳng bản lề - Hinging Hyper Plane (HH [16]) và các ranh giới của các vùng con được cung cấp bởi siêu phẳng là các đường xuyên suốt miền, linh hoạt hơn so với (2.2.11). Để có được một bộ phân loại tuyến tính từng phần với khả năng phân loại mạnh mẽ hơn, ta có thể thêm nhiều hàm tuyến tính theo cách sau

$$\phi_m(x) = \max\{0, p_{m1}^T x - q_{m1}, p_{m2}^T x - q_{m2}, \dots\}.$$


Khả năng phân loại được mở rộng cùng với sự gia tăng của các hàm tuyến tính được sử dụng trong $\max\{\}$. Như đã chứng minh trong Định lý 2.2.2, một ranh giới tuyến tính từng phần bất kỳ trong không gian n -chiều có thể được thực hiện bằng cách sử dụng n hàm tuyến tính, tức là

$$\phi_m(x) = \max\{0, p_{m1}^T x - q_{m1}, p_{m2}^T x - q_{m2}, \dots, p_{mn}^T x - q_{mn}\}, \quad (2.2.13)$$

Theo ký hiệu trong [18], chúng ta gọi (2.2.13) là ánh xạ đặc trưng siêu phẳng bản lề tổng quát - Generalized Hinging HyperPlane (GHH).

2.2.5. Tham số trong ánh xạ đặc trưng tuyến tính từng phần

Giống như các ánh xạ đặc trưng phi tuyến hoặc các hạt nhân khác, ánh xạ đặc trưng tuyến tính từng phần có một số tham số phi tuyến, có ảnh hưởng lớn đến hiệu suất phân loại nhưng khó điều chỉnh tối ưu. Để có được các tham số hợp lý cho ánh xạ đặc trưng tuyến tính từng phần, ta nghiên cứu ý nghĩa hình học của các tham số. Từ định nghĩa của một tập tuyến tính từng phần, miền được chia thành các vùng con Ω_k , trong mỗi vùng con đó tập tuyến tính từng phần bằng một siêu phẳng. Nói chung, các tham số trong ánh xạ đặc trưng tuyến tính từng phần xác định cấu trúc vùng con và siêu phẳng trong



Hình 5: Các ranh giới của các vùng con cho (2.2.11) và các ranh giới phân loại liên quan.

mỗi vùng con được thu được bằng kỹ thuật SVM.

Xét lại tập dữ liệu hai mặt trăng được hiển thị trong Hình 3. Ranh giới bao gồm ba đoạn nằm trong vùng con Ω_k như minh họa trong Hình 4. Để xây dựng bộ phân loại mong muốn, ta đặt

$$\phi_1(x) = x(1), \quad \phi_2(x) = x(2),$$

$$\phi_3(x) = \max\{0, x(2) - \frac{1}{3}\}, \quad \phi_4(x) = \max\{0, x(2) - \frac{2}{3}\},$$

tức là, ta sử dụng ánh xạ đặc trưng (2.2.11) với $i_1 = 1, q_1 = 0, i_2 = 2, q_2 = 0, i_3 = 2, q_3 = \frac{1}{3}$, và $i_4 = 2, q_4 = \frac{2}{3}$. Tiếp theo giải PWL-C-SVM hoặc PWL-LS-SVM dẫn đến $w_0, \dots, w_4$, xác định một ranh giới tuyến tính từng phần $w_0 + \sum_{m=1}^4 w_m f_m(x) = 0$. Trong ví dụ này, dựa vào một số kiến thức trước đó đã được biết, các tham số hợp lý cho một ánh xạ đặc trưng tuyến tính

từng phần có thể được tìm thấy một cách hiệu quả. Trong các vấn đề hộp đen, chúng ta đặt các tham số của (2.2.11) bằng cách chia đều miền trên mỗi trục thành nhiều đoạn.

Đối với các ánh xạ đặc trưng tuyến tính từng phần khác, chúng ta sử dụng các tham số ngẫu nhiên. Các ranh giới của các đoạn được cung cấp bởi (2.2.12) là các siêu phẳng $p_m^T x + q_m = 0$. Để có được $p_m \in \mathbb{R}^n$ và $q_m \in \mathbb{R}$, trước tiên chúng ta tạo ra n điểm trong miền với phân phối đều, sau đó chúng ta chọn $p_m(1)$ từ $\{1, -1\}$ với xác suất bằng nhau, và tính q_m và các thành phần khác của p_m sao cho các điểm được tạo ra nằm trong $p_m^T x + q_m = 0$. Các tham số thu được theo cách này có thể cung cấp các ranh giới phân loại linh hoạt.

Hình 5 cho thấy các ranh giới của các vùng con cho liên quan đến ánh xạ đặc trưng tuyến tính từng phần được tạo ngẫu nhiên. Bốn đường nét đứt tương ứng với $f_3(x) = 0$, $f_4(x) = 0$, $f_5(x) = 0$, và $f_6(x) = 0$, tương ứng. Ranh giới phân loại là $\mathcal{B} = \{x : w_0 + \sum_{m=1}^6 w_m f_m(x) = 0\}$. $\mathcal{B}_1$ với $w_0 = -1.5$, $w_1 = 0.5$, $w_2 = 0.9$, $w_3 = 0.7$, $w_4 = 0.8$, $w_5 = 0.1$, $w_6 = 0.33$, $\mathcal{B}_2$ với $w_0 = -0.5$, $w_1 = -0.5$, $w_2 = 1$, $w_3 = -1$, $w_4 = 0.8$, $w_5 = -0.25$, $w_6 = 0.33$, và $\mathcal{B}_3$ với $w_0 = -0.5$, $w_1 = 1$, $w_2 = -2$, $w_3 = 1$, $w_4 = 4$, $w_5 = -0.75$, $w_6 = 0.67$ được minh họa bằng các đường màu đỏ, xanh dương, và xanh lá cây, cho thấy sự linh hoạt của ranh giới phân loại, có thể là lỗi ($\mathcal{B}_1$), không lỗi ($\mathcal{B}_2$), và

không kết nối ($\mathcal{B}_3$).

$$\begin{aligned}
 f_1(x) &= x(1), & f_2(x) &= x(2), \\
 f_3(x) &= \max\{0, x(1) + 1.5x(2) - 1.0\}, \\
 f_4(x) &= \max\{0, x(1) + 2x(2) - 1.0\}, \\
 f_5(x) &= \max\{0, -x(1) + 0.25x(2) + 0.25\}, \\
 f_6(x) &= \max\{0, -x(1) + 0.67x(2) + 0.33\}.
 \end{aligned} \tag{2.2.14}$$

Ba ranh giới phân loại có thể tương ứng với các nhóm w_m khác nhau được hiển thị. Có thể thấy sự linh hoạt của các bộ phân loại tiềm năng, từ đó bộ phân loại tối ưu có thể được chọn ra bằng SVM. Trong hầu hết các trường hợp, hiệu suất phân loại là thỏa đáng, nếu không, chúng ta có thể tạo ra một nhóm tham số khác. Tương tự, các tham số của (2.2.13) có thể được tạo ra và các vùng con kết quả cung cấp các ranh giới phân loại linh hoạt.